

Sommario

Questo lavoro di tesi punta a migliorare le previsioni dei valori di dati multi-variati migliorando il trade-off tra accuratezza ed efficienza.

Indice

1	Introduzione	11
1.1	Scenario applicativo	12
1.2	Obiettivi e contributi	14
2	Stato dell'arte	15
2.1	Smoothing	15
2.1.1	Exponential Smoothing	17
2.2	Vector Autoregressive Model	21
2.2.1	Modelli teorici	22
2.2.2	Implementazione in R	26
2.3	Clustering	31
2.3.1	Clustering partizionale	31
2.3.2	Clustering gerarchico	31
2.3.3	Clustering concettuale e interpolativo	33
2.4	VARForecaster 1.0/2.0	34
2.4.1	VARForecaster 1.0	34
2.4.2	VARForecaster 2.0	35
3	VARForecaster 2.1/2.2	39
3.1	VARForecaster 2.1	39
3.1.1	Progettazione	44
3.2	VARForecaster 2.2	54
3.2.1	Progettazione	57
4	Analisi sperimentale	68
4.1	Obiettivi e metriche	68
4.2	Dati	70
4.3	Risultati e discussione	71
4.3.1	Ecotexas	71
4.3.2	UnitedStatesPacific	112

<i>INDICE</i>	3
5 Conclusioni	138
6 Appendice	139
6.1 Guida per l'esecuzione di VARForecaster 2.1/2.2	139
Bibliografia	140

Elenco delle tabelle

4.1	Parametri per Ecotexas	71
4.2	Ecotexas VARForecaster 2.1 - Metrica (1), temperatura	72
4.3	Ecotexas VARForecaster 2.1 - Metrica (1), velocità del vento .	72
4.4	Ecotexas VARForecaster 2.1 - Metrica (1), Ozono	72
4.5	Ecotexas VARForecaster 2.1 - Metrica (1), radiazioni solari .	73
4.6	Ecotexas VARForecaster 2.1 - Metrica (2), temperatura	74
4.7	Ecotexas VARForecaster 2.1 - Metrica (2), Velocità del vento .	74
4.8	Ecotexas VARForecaster 2.1 - Metrica (2), Ozono	74
4.9	Ecotexas VARForecaster 2.1 - Metrica (2), radiazioni solari .	75
4.10	Ecotexas VARForecaster 2.1 - Riassunto Ahead 1	76
4.11	Ecotexas VARForecaster 2.1 - Riassunto Ahead 2	76
4.12	Ecotexas VARForecaster 2.1 - Riassunto Ahead 3	76
4.13	Ecotexas VARForecaster 2.1 - Riassunto Ahead 4	76
4.14	Ecotexas VARForecaster 2.1 - Riassunto Ahead 5	76
4.15	Ecotexas VARForecaster 2.1 - Riassunto Ahead 6	77
4.16	Ecotexas VARForecaster 2.1 - Metrica (4)	77
4.17	Ecotexas VARForecaster 2.1 - Metrica (5)	77
4.18	Ecotexas VARForecaster 2.1 - Metrica (6)	77
4.19	Ecotexas VARForecaster 2.2 - Metrica (1), temperatura, $\alpha = 0.4$	79
4.20	Ecotexas VARForecaster 2.2 - Metrica (1), temperatura, $\alpha = 0.5$	80
4.21	Ecotexas VARForecaster 2.2 - Metrica (1), temperatura, $\alpha = 0.6$	80
4.22	Ecotexas VARForecaster 2.2 - Metrica (1), velocità del vento, $\alpha = 0.4$	80
4.23	Ecotexas VARForecaster 2.2 - Metrica (1), velocità del vento, $\alpha = 0.5$	81
4.24	Ecotexas VARForecaster 2.2 - Metrica (1), velocità del vento, $\alpha = 0.6$	81
4.25	Ecotexas VARForecaster 2.2 - Metrica (1), ozono, $\alpha = 0.4$. .	81

4.26 Ecotexas VARForecaster 2.2 - Metrica (1), ozono, $\alpha = 0.5$	82
4.27 Ecotexas VARForecaster 2.2 - Metrica (1), ozono, $\alpha = 0.6$	82
4.28 Ecotexas VARForecaster 2.2 - Metrica (1), radiazioni solari, $\alpha = 0.4$	82
4.29 Ecotexas VARForecaster 2.2 - Metrica (1), radiazioni solari, $\alpha = 0.5$	83
4.30 Ecotexas VARForecaster 2.2 - Metrica (1), radiazioni solari, $\alpha = 0.6$	83
4.31 Ecotexas VARForecaster 2.2 - Metrica (2), temperatura, $\alpha = 0.4$	84
4.32 Ecotexas VARForecaster 2.2 - Metrica (2), temperatura, $\alpha = 0.5$	84
4.33 Ecotexas VARForecaster 2.2 - Metrica (2), temperatura, $\alpha = 0.6$	84
4.34 Ecotexas VARForecaster 2.2 - Metrica (2), velocità del vento, $\alpha = 0.4$	85
4.35 Ecotexas VARForecaster 2.2 - Metrica (2), velocità del vento, $\alpha = 0.5$	85
4.36 Ecotexas VARForecaster 2.2 - Metrica (2), velocità del vento, $\alpha = 0.6$	85
4.37 Ecotexas VARForecaster 2.2 - Metrica (2), ozono, $\alpha = 0.4$	86
4.38 Ecotexas VARForecaster 2.2 - Metrica (2), ozono, $\alpha = 0.5$	86
4.39 Ecotexas VARForecaster 2.2 - Metrica (2), ozono, $\alpha = 0.6$	86
4.40 Ecotexas VARForecaster 2.2 - Metrica (2), radiazioni solari, $\alpha = 0.4$	87
4.41 Ecotexas VARForecaster 2.2 - Metrica (2), radiazioni solari, $\alpha = 0.5$	87
4.42 Ecotexas VARForecaster 2.2 - Metrica (2), radiazioni solari, $\alpha = 0.6$	87
4.43 Ecotexas VARForecaster 2.2 - Tabella riassuntiva	88
4.44 Ecotexas VARForecaster 2.2 - Riassunto Ahead 1	89
4.45 Ecotexas VARForecaster 2.2 - Riassunto Ahead 2	90
4.46 Ecotexas VARForecaster 2.2 - Riassunto Ahead 4	91
4.47 Ecotexas VARForecaster 2.2 - Riassunto Ahead 4	92
4.48 Ecotexas VARForecaster 2.2 - Riassunto Ahead 5	93
4.49 Ecotexas VARForecaster 2.2 - Riassunto Ahead 6	94
4.50 Ecotexas VARForecaster 2.2 - Metrica (3)	94
4.51 Ecotexas VARForecaster 2.2 - Metrica (4)	96
4.52 Ecotexas VARForecaster 2.2 - Metrica (5)	96
4.53 Ecotexas VARForecaster 2.2 - Metrica (6)	96
4.54 Confronto versioni Ecotexas - Metrica (1), temperatura	97

4.55 Confronto versioni Ecotexas - Metrica (1), velocità del vento	98
4.56 Confronto versioni Ecotexas - Metrica (1), ozono	98
4.57 Confronto versioni Ecotexas - Metrica (1), radiazioni solari	98
4.58 Confronto versioni Ecotexas - Metrica (2), temperatura	99
4.59 Confronto versioni Ecotexas - Metrica (2), velocità del vento	99
4.60 Confronto versioni Ecotexas - Metrica (2), ozono	99
4.61 Confronto versioni Ecotexas - Metrica (2), radiazioni solari	100
4.62 Confronto versioni Ecotexas - Metrica (4)	100
4.63 Confronto versioni Ecotexas - Metrica (5)	100
4.64 Confronto versioni Ecotexas - Metrica (6)	100
4.65 Sommario confronto ahead 1	101
4.66 Sommario confronto ahead 2	101
4.67 Sommario confronto ahead 3	101
4.68 Sommario confronto ahead 4	101
4.69 Sommario confronto ahead 5	101
4.70 Sommario confronto ahead 6	102
4.71 Parametri per UnitedStatesPacific	112
4.72 UnitedStatesPacific VARForecaster 2.1 - Metrica (1), dewp	113
4.73 UnitedStatesPacific VARForecaster 2.1 - Metrica (1), pres	113
4.74 UnitedStatesPacific VARForecaster 2.1 - Metrica (1), temp	113
4.75 UnitedStatesPacific VARForecaster 2.1 - Metrica (1), wind	114
4.76 UnitedStatesPacific VARForecaster 2.1 - Metrica (2), dewp	115
4.77 UnitedStatesPacific VARForecaster 2.1 - Metrica (2), pres	115
4.78 UnitedStatesPacific VARForecaster 2.1 - Metrica (2), temp	115
4.79 UnitedStatesPacific VARForecaster 2.1 - Metrica (2), wind	116
4.80 UnitedStatesPacific VARForecaster 2.1 - Riassunto Ahead 1	117
4.81 UnitedStatesPacific VARForecaster 2.1 - Riassunto Ahead 2	117
4.82 UnitedStatesPacific VARForecaster 2.1 - Riassunto Ahead 3	117
4.83 UnitedStatesPacific VARForecaster 2.1 - Riassunto Ahead 4	117
4.84 UnitedStatesPacific VARForecaster 2.1 - Riassunto Ahead 5	117
4.85 UnitedStatesPacific VARForecaster 2.1 - Riassunto Ahead 6	118
4.86 UnitedStatesPacific VARForecaster 2.1 - Metrica (4)	118
4.87 UnitedStatesPacific VARForecaster 2.1 - Metrica (5)	118
4.88 UnitedStatesPacific VARForecaster 2.1 - Metrica (6)	118
4.89 UnitedStatesPacific VARForecaster 2.2 - Metrica (1), dewp, α = 0.4	120
4.90 UnitedStatesPacific VARForecaster 2.2 - Metrica (1), dewp, α = 0.5	121
4.91 UnitedStatesPacific VARForecaster 2.2 - Metrica (1), dewp, α = 0.6	121

4.92 UnitedStatesPacific VARForecaster 2.2 - Metrica (1), pres, α = 0.4	121
4.93 UnitedStatesPacific VARForecaster 2.2 - Metrica (1), pres, α = 0.5	122
4.94 UnitedStatesPacific VARForecaster 2.2 - Metrica (1), pres, α = 0.6	122
4.95 UnitedStatesPacific VARForecaster 2.2 - Metrica (1), temp, α = 0.4	122
4.96 UnitedStatesPacific VARForecaster 2.2 - Metrica (1), temp, α = 0.5	123
4.97 UnitedStatesPacific VARForecaster 2.2 - Metrica (1), temp, α = 0.6	123
4.98 UnitedStatesPacific VARForecaster 2.2 - Metrica (1), wind, α = 0.4	123
4.99 UnitedStatesPacific VARForecaster 2.2 - Metrica (1), wind, α = 0.5	124
4.100 UnitedStatesPacific VARForecaster 2.2 - Metrica (1), wind, α = 0.6	124
4.101 UnitedStatesPacific VARForecaster 2.2 - Metrica (2), dewp, α = 0.4	125
4.102 UnitedStatesPacific VARForecaster 2.2 - Metrica (2), dewp, α = 0.5	125
4.103 UnitedStatesPacific VARForecaster 2.2 - Metrica (2), dewp, α = 0.6	125
4.104 UnitedStatesPacific VARForecaster 2.2 - Metrica (2), pres, α = 0.4	126
4.105 UnitedStatesPacific VARForecaster 2.2 - Metrica (2), pres, α = 0.5	126
4.106 UnitedStatesPacific VARForecaster 2.2 - Metrica (2), pres, α = 0.6	126
4.107 UnitedStatesPacific VARForecaster 2.2 - Metrica (2), temp, α = 0.4	127
4.108 UnitedStatesPacific VARForecaster 2.2 - Metrica (2), temp, α = 0.5	127
4.109 UnitedStatesPacific VARForecaster 2.2 - Metrica (2), temp, α = 0.6	127
4.110 UnitedStatesPacific VARForecaster 2.2 - Metrica (2), wind, α = 0.4	128
4.111 UnitedStatesPacific VARForecaster 2.2 - Metrica (2), wind, α = 0.5	128

4.112UnitedStatesPacific VARForecaster 2.2 - Metrica (2), wind, α = 0.6	128
4.113Ecotexas VARForecaster 2.2 - Tabella riassuntiva	129
4.114UnitedStatesPacific VARForecaster 2.2 - Riassunto Ahead 1 .	130
4.115UnitedStatesPacific VARForecaster 2.2 - Riassunto Ahead 2 .	131
4.116UnitedStatesPacific VARForecaster 2.2 - Riassunto Ahead 4 .	132
4.117UnitedStatesPacific VARForecaster 2.2 - Riassunto Ahead 4 .	133
4.118UnitedStatesPacific VARForecaster 2.2 - Riassunto Ahead 5 .	134
4.119UnitedStatesPacific VARForecaster 2.2 - Riassunto Ahead 6 .	135
4.120Ecotexas VARForecaster 2.2 - Metrica (3)	135
4.121Ecotexas VARForecaster 2.2 - Metrica (4)	136
4.122Ecotexas VARForecaster 2.2 - Metrica (5)	136
4.123Ecotexas VARForecaster 2.2 - Metrica (6)	136

Elenco delle figure

2.1	Esempio di utilizzo della funzione VARSelect	28
2.2	Esempio di utilizzo della funzione VAR	29
2.3	Output della funzione in fig. 2.2	30
2.4	Dendrogramma	32
3.1	RealAggregate Package Diagram	44
3.2	RealAggregate Tree Class Diagram	45
3.3	RealAggregate Forecast Class Diagram	47
3.4	Run VARForecaster 2.1	49
3.5	Riapprendimento CT VARForecaster 2.1	50
3.6	Apprendimento aggregato con media	51
3.7	Apprendimento aggregato con mediana	52
3.8	Apprendimento modello VAR VARForecaster 2.1	53
3.9	Exponential Smoothing Class Diagram	57
3.10	Tree Class Diagram VARForecaster 2.2	59
3.11	Run VARForecaster 2.2	61
3.12	Apprendimento CT VARForecaster 2.2	62
3.13	Potatura VARForecaster 2.2	63
3.14	Riapprendimento CT 1/2 VARForecaster 2.2	64
3.15	Riapprendimento CT 2/2 VARForecaster 2.2	65
3.16	Algoritmo per lo smoothing esponenziale	66
3.17	Algoritmo per lo smoothing del singolo sensore	67
4.1	Temperatura ahead 1	103
4.2	Temperatura ahead 2	103
4.3	Temperatura ahead 3	104
4.4	Temperatura ahead 4	104
4.5	Temperatura ahead 5	104
4.6	Temperatura ahead 6	105
4.7	Velocità vento ahead 1	105
4.8	Velocità vento ahead 2	105

4.9	Velocità vento ahead 3	106
4.10	Velocità vento ahead 4	106
4.11	Velocità vento ahead 5	106
4.12	Velocità vento ahead 6	107
4.13	Ozono ahead 1	107
4.14	Ozono ahead 2	107
4.15	Ozono ahead 3	108
4.16	Ozono ahead 4	108
4.17	Ozono ahead 5	108
4.18	Ozono ahead 6	109
4.19	Radiazioni ahead 1	109
4.20	Radiazioni ahead 2	109
4.21	Radiazioni ahead 3	110
4.22	Radiazioni ahead 4	110
4.23	Radiazioni ahead 5	110
4.24	Radiazioni ahead 6	111

Capitolo 1

Introduzione

La rapida evoluzione, vissuta negli ultimi decenni, per la scienza e la tecnica ci porta oggi a collezionare moli di dati impressionanti. È proprio in questi casi che soluzioni di analisi innovative che combinino informatica e statistica si rendono necessarie.

In questi termini si presenta la problematica di dover effettuare previsioni accurate di ciò che sarà l'andamento futuro di un flusso di dati multi-variati e continuo nel tempo.

Al fine di risolvere tale problematica si utilizzano tecniche di data mining capaci di gestire tali flussi e di fornirne una rappresentazione funzionale all'applicazione di modelli di regressione che sono utili ad effettuare previsioni sull'andamento futuro dei dati in osservazione.

In questo lavoro di tesi, partendo da un algoritmo che effettua previsione dopo aver applicato una tecnica di clustering incrementale e aver appreso un modello di regressione chiamato “Vector Autoregressive Model”, si investiga l'utilizzo della tecnica dello smoothing esponenziale e la costruzione di aggregati dei dati osservati in tempo reale, al fine di ottenere un bilanciamento tra accuratezza e efficienza nella costruzione di un modello di previsione multi-variato in reti di sensori.

In questo capitolo vengono descritti lo scenario applicativo all'interno del quale questo lavoro di tesi si colloca e si riporta una sintetica descrizione degli obiettivi prefissati.

1.1 Scenario applicativo

L'ormai diffuso uso delle reti di sensori ha portato a dover gestire sistemi informatizzati in grado di misurare e organizzare dati multi-variati in tempo reale. Tali sistemi si avvalgono dei cosiddetti geosensori, ovvero di dispositivi in grado di eseguire rilevazioni temporali multiple di fenomeni fisici quali per esempio temperatura, umidità, velocità del vento e livello delle radiazioni solari.

Il fine ultimo di tali rilevazioni è senza dubbio quello di dover effettuare previsioni accurate di ciò che potrà essere l'andamento futuro di tali fenomeni, ma utilizzare queste informazioni non è semplice, non perché sia complicato leggerle, ma piuttosto perché è difficile interpretarle.

È in questo contesto che l'algoritmo VARForecaster trova spazio, infatti utilizza una tecnica che ci aiuta a raffinare le informazioni derivanti dai geosensori proveniente dall'insieme di tecniche e metodologie definito data mining e che si chiama analisi dei cluster. L'utilizzazione di questa tecnica ci permette di raggruppare i geosensori in base alla loro vicinanza spaziale e alla similarità delle loro osservazioni.

Per ognuno di questi gruppi distinti, si possono costruire modelli di regressione, ovvero è possibile definire un modello secondo il quale “una variabile dipendente è modellata come una funzione delle variabili indipendenti più un termine d'errore” [2].

A causa della natura delle rilevazioni, per avere delle previsioni valide e accurate è necessario che esse siano ripetute nel tempo, portando infine ad avere una serie temporale multi-variata (che considera più di un fenomeno) e georeferenziata (cioè geograficamente distribuita).

La previsione in un serie temporale multi-variata è realizzata con l'apprendimento di un modello VAR che restituisce un modello di regressione per ciascuna variabile. Tale modello di regressione predice i valori attesi per la variabile dipendente in funzione delle osservazioni storiche collezionate tanto per la variabile dipendente, cioè da predire, quanto per le variabili indipendenti, ovvero quelle rimanenti nel sistema di variabili misurate [3]. L'apprendimento di un modello VAR per sensore è computazionalmente costoso. La alternativa è l'apprendimento di un modello VAR per gruppi cluster di sensori.

In [1] si presenta un algoritmo, VARForecaster che combina modello di clustering e modello VAR. Il clustering è realizzato in maniera incrementale sulla base di approssimazioni dei valori osservati, ovvero si forma incrementalmente una gerarchia di cluster, partendo da un nodo radice inizialmente vuoto e aggiungendo istanze una alla volta aggiornando l'albero appropri-

tamente ad ogni passaggio, anche se questo comporta la ristrutturazione dell'albero [4].

In questo lavoro di tesi si presenta una variante di tale algoritmo che: (1) valuta l'uso del meccanismo di smoothing esponenziale per determinare il modello di clustering sulla base dei valori geofisici attesi nella rete all'istante $t+1$ piuttosto che sulla base dei valori geofisici osservati all'istante t ; (2) calcola aggregati dei dati in tempo reale (media o mediana) piuttosto che ricorrere ad approssimazioni degli stessi. Lo scopo è identificare la soluzione che realizza il miglior bilanciamento tra accuratezza e efficienza.

1.2 Obiettivi e contributi

Questo lavoro di tesi considera un algoritmo incrementale di clustering spazio-temporale multi-variato e lo estende nelle seguenti direzioni:

- definizione, nell'albero binario rappresentante il clustering, di un nuovo criterio di ricalcolo della media dei nodi creati ex-novo in fase di riapprendimento (in [1] si era definito un calcolo basato sulla media del padre per ognuno di essi);
- utilizzo, per il riapprendimento dell'albero suddetto, dell'algoritmo di smoothing esponenziale, al fine di fornire un mezzo più efficace per la previsione dei valori futuri della serie di dati (in [1] tale albero era appreso solo in base ai valori ricevuti dai sensori, presenti all'interno della finestra temporale di ogni nodo).

Capitolo 2

Stato dell'arte

2.1 Smoothing

Come definito in precedenza, a causa della natura delle rilevazioni, al fine di migliorare l'accuratezza delle previsioni è indispensabile che queste siano ripetute nel tempo, e che quindi sia fornita una serie temporale di esse.

In questo lavoro di tesi si considera il caso in cui la serie temporale è multi-variata, ovvero prende in considerazione più variabili, e geo-referenziata, cioè i valori sono rilevati da sensori geograficamente distribuiti.

Una serie temporale, quindi, altro non è che una sequenza di osservazioni le quali sono state ripetute nel tempo.

In una serie temporale, così come in una qualsiasi collezione di dati temporalmente distribuita, i valori assunti dalle variabili hanno una certa variazione random.

Esistono delle tecniche per ridurre gli effetti dovuti a tali variazioni, e che se utilizzate appropriatamente, rivelano con più chiarezza i pattern nascosti presenti tra i dati. Queste sono dette tecniche di "smoothing" [5].

Lo smoothing è un processo che viene usato per la previsione di valori futuri in una serie temporale e, in statistica e nel campo dell'elaborazione digitale delle immagini, per evidenziare i pattern significativi presenti all'interno dei dati, attenuando il rumore generato da artefatti ambientali, informatici o elettronici.

Nella pratica esso è un processo in cui i valori presenti in un dataset sono mediati con i loro vicini spaziali o temporali in una serie, tipo una serie temporale, o un'immagine [6].

Ci sono diversi tipi di smoothing:

- Media mobile semplice: per la previsione vengono considerate tutte le osservazioni precedenti, alle quali viene dato lo stesso peso, indipenden-

temente dall'istante temporale in cui ci troviamo. La relativa formula per il calcolo è la seguente

$$Y_{t+1} = Y_t + Y_{t-1} + Y_{t-2} + \dots + Y_{t-n+1} \text{ n}$$

- Media mobile ponderata: è una variante dello smoothing a virgola mobile ed in questo caso i valori precedenti non hanno tutti lo stesso peso, bensì viene assegnato ad ognuno di essi un fattore, chiamato peso, che varierà l'influenza di tale termine all'interno della sommatoria. La formula è così definita

$$Y_{t+1} = p_1 Y_t + p_2 Y_{t-1} + p_3 Y_{t-2} + \dots + p_n Y_{t-n+1}$$

dove $p_i > 0$ e $\sum_{i=1}^{i=n} p_i = 1$

- Esponenziale.

Nella seguente sezione è descritto lo smoothing esponenziale nel dettaglio.

2.1.1 Exponential Smoothing

Lo smoothing esponenziale nacque alla fine degli anni '50 (i pionieri furono Holt nel 1957, Brown nel 1959 e Winters nel 1960) e motivò alcuni dei metodi di previsione (forecast) di maggior successo. Le previsioni ottenute con i metodi di smoothing esponenziale sono medie ponderate delle osservazioni passate, con i pesi che diminuiscono in modo esponenziale con l'andare avanti delle osservazioni.

In altri termini, le osservazioni più recenti hanno un peso associato più alto.

Questo modo di operare genera previsioni accurate in modo più veloce e per un ampio spettro di serie temporali, il che è un grande vantaggio per le applicazioni in campo industriale [7].

Essendo l'idea di base quella di "pesare" maggiormente le osservazioni più recenti rispetto a quelle più remote nel passato, i metodi di smoothing sono capaci di adeguarsi rapidamente a variazioni improvvise nel valore della serie storica a causa di eventi che modificano la regolarità del fenomeno osservato, come per es. può essere un giorno con elevata umidità oppure particolarmente ventoso.

Esistono diversi metodi di smoothing esponenziale, che tengono conto o meno dell'esistenza di componenti tendenziali e stagionali nella serie storica in esame e sono:

- Metodo di Brown;
- Metodo di Holt;
- Metodo di Winters.

Metodo di Brown

Il **metodo di Brown** è il più semplice e la sua formula è la seguente:

$$Y_t = \alpha x_t + (1 - \alpha) Y_{t-1}$$

dove α è il fattore di smoothing, con $0 \leq \alpha \leq 1$. In altre parole Y_t è la media pesata dell'osservazione corrente x_t ed il precedente termine a cui era stato applicato lo smoothing Y_{t-1} . Il fattore di smoothing è il termine, all'interno dell'equazione, che indica quanto peso dare al fattore precedente o all'osservazione corrente.

Infatti se $\alpha = 1$ la serie in uscita allo smoothing è sempre quella ricevuta in ingresso, mentre man mano che si abbassa il valore di questo fattore si ha minor adattamento ai dati correnti fino a quando, con $\alpha = 0$, si avrà in output sempre la serie di partenza.

In questo metodo il valore Y_1 è uguale al valore della prima osservazione effettuata x_1 .

Questo tipo di smoothing esponenziale è molto facile da applicare, infatti basta che due osservazioni siano disponibili per poterlo utilizzare e non tiene conto né di eventuali trend né di stagionalità all'interno della serie temporale.

Metodo di Holt

Il **metodo di Holt** migliora il modello di Brown, infatti tiene conto dei trend presenti all'interno della serie temporale (ma non della stagionalità). La formula per calcolare la previsione con il suddetto metodo è la seguente:

$$Y_{t+1} = Y_t + m_t \quad (1)$$

dove:

- $Y_t = \alpha x_t + (1 - \alpha)(Y_{t-1} + m_{t-1}) \quad \forall t \geq 2$

$$(2)$$

- $m_t = \beta (Y_t - Y_{t-1}) + (1 - \beta) m_{t-1} \quad \forall t \geq 2$

$$(3)$$

- $Y_1 = x_1$

- $m_1 = x_2 - x_1$

L'equazione (1) è definita equazione di predizione, la (2) equazione di livello e la (3) come equazione di trend.

Y_t denota lo stimatore della serie temporale all'istante t , m_t è uno stimatore del trend della serie all'istante t , α è, come nel modello di Brown, il parametro di smoothing per la serie e può essere $0 \leq \alpha \leq 1$ e β invece è il parametro di smoothing per il trend e può anch'esso assumere valori $0 \leq \beta \leq 1$. β deve essere ottimizzato minimizzando lo scarto quadratico medio.

Metodo di Winters

Il **metodo di Winters**, infine, è il metodo di smoothing esponenziale con più alta complessità ma che si preoccupa di tenere in considerazione, oltre che dei trend presenti all'interno della serie temporale, anche di una stagionalità di periodo L nota. Esso si calcola come segue:

$$Y_{t+1} = (Y_t + m_t) q_{t-L+1} \quad (1)$$

dove:

- $Y_t = \alpha \frac{Y_t}{q_{t-L}} + (1 - \alpha)(Y_{t-1} + m_{t-1}) \forall t \geq 2$ (2)

- $m_t = \beta (Y_t - Y_{t-1}) + (1 - \beta)m_{t-1} \forall t \geq 2$ (3)

- $q_t = \gamma \frac{x_t}{Y_t} + (1 - \gamma) q_{t-L} \forall t \geq L + 1$ (4)

- $q_t = \frac{x_t}{\sum_{\tau=1}^L \frac{x_\tau}{L}} \forall t = 1, \dots, L$ (5)

- $Y_1 = x_1$
- $m_1 = x_2 - x_1$

L'equazione (1) è definita equazione di predizione, la (2) equazione di livello, la (3) equazione di trend, mentre la (4) e la (5) sono chiamate equazioni di periodo.

Y_t denota lo stimatore della serie temporale all'istante t , m_t è uno stimatore del trend della serie all'istante t e q_t indica uno stimatore della periodicità della serie all'istante t , il quale deve essere calcolato in due modi diversi che dipendono dall'istante temporale in cui ci si trova rispetto all'intera durata del periodo.

α è il parametro di smoothing per la serie e può essere $0 \leq \alpha \leq 1$, allo stesso modo β , che è il parametro di smoothing del trend della serie temporale, deve essere $0 \leq \beta \leq 1$, invece γ è il parametro di smoothing del periodo e può essere $0 \leq \gamma \leq 1$.

γ deve essere ottimizzato minimizzando lo scarto quadratico medio.

È possibile, nel caso lo si desideri, eliminare da una serie temporale la componente di tendenza o di stagionalità. Innanzitutto bisogna determinare la tendenza con un'analisi di regressione e la componente di stagionalità tramite scomposizione della serie, successivamente è possibile calcolare la media mobile per rimuovere la tendenza e, per differenziazioni successive ($B_t(h) = y_t - y_{t-h}$), è possibile rimuovere la tendenza [8].

2.2 Vector Autoregressive Model

Il modello VAR (Vector Autoregressive Model) è uno dei modelli più flessibili, facili da usare e di successo per l'analisi di serie temporali multivariate. È un'estensione naturale del modello autoregressivo univariato verso il dinamismo delle serie temporali multivariate. Il modello VAR ha dimostrato di essere molto utile per descrivere il comportamento dinamico delle serie storiche economiche e finanziarie e per le previsioni. Esso fornisce previsioni spesso più accurate rispetto a quelle dei modelli univariati, infatti queste possono essere condizionate da potenziali percorsi futuri che le variabili nel modello possono prendere. Oltre alla descrizione dei dati e la previsione, il modello VAR può essere usato per l'inferenza struttura e per l'analisi della linea di condotta [13].

L'analisi del modello VAR può essere affrontata da due punti di vista:

- dal punto di vista teorico: è in questa sezione descritta la storia di tale modello e la teoricità sulla quale è basato;
- dal punto di vista implementativo: è invece qui descritta la tecnica di utilizzazione del modello VAR in base alle necessità di questo progetto di tesi.

2.2.1 Modelli teorici

I modelli VAR sono stati definiti da Christopher Sims in uno storico articolo pubblicato su Econometria nel 1980, che proponeva una critica dei modelli strutturali di equazioni simultanee, allora il principale strumento di analisi eometrica nell'ambito della macroeconomia.

In particolare, i modelli VAR risultano nel complesso più semplici rispetto ai modelli strutturali, e la loro performance in termini di capacità previsiva di variabili macroeconomiche appare migliore.

Tutte le n variabili date in input al modello, vengono trattate simmetricamente in senso strutturale dove ognuna di essa sarà ricavata da un'equazione che spiega la sua evoluzione in base ai ritardi di se stessa e ai ritardi di tutte le altre variabili.

Le variabili che vengono date in input al modello VAR, prendono il nome di variabili endogene e vengono raccolte in un vettore Y_t di dimensione $n \times 1$ che ha come i-esimo elemento Y_{it} e dove quest'ultimo rappresenta l'osservazione della variabile i-esima al tempo t. Ad esempio se la variabile i-esima è la velocità del vento, allora Y_{it} è il valore della velocità del vento al tempo t [9] [10].

Un modello VAR, in generale, è un sistema di equazioni simultanee che può essere descritto mediante tre modelli teorici: reduced form (o forma ridotta), structural form (o forma strutturale) e companion form.

Reduced form

Il modello VAR in forma ridotta si presenta nella forma:

$$Y_t = \mathbf{c} + \Phi(\mathbf{L})Y_{t-1} + \varepsilon_t = \mathbf{c} + \Phi_1 T_{t-1} + \dots + \Phi_p Y_{t-p} + \varepsilon_t$$

dove, per un VAR(p) $\Phi(\mathbf{L}) = \sum_{i=0}^{p-1} \Phi_i L^i$ è un polinomio matriciale di ordine p nell'operatore di ritardo \mathbf{L} (ossia, l'operatore tale che $L^i Y_t = Y_{t-i}$), con Φ_i che è una matrice di dimensione $n \times n$;

Y_t è il vettore delle variabili endogene e si presenta nella forma:

$$Y_t = \begin{bmatrix} Y_{1t} \\ \vdots \\ Y_{nt} \end{bmatrix}$$

e ε_t è un vettore conforme di disturbi stocastici del tipo:

$$\varepsilon_t = \begin{bmatrix} \varepsilon_{1t} \\ \vdots \\ \varepsilon_{nt} \end{bmatrix}$$

tali che $E_{\varepsilon_t} = \mathbf{0}$ (ogni termine di disturbo ha media pari a zero) e $\mathbf{E}(\varepsilon_{it}^2) = \sigma_i^2$ con $\mathbf{i} = \mathbf{1}, \dots, \mathbf{n}$ dove σ_i^2 è la varianza i-esima ed E la media. Si osservi che gli elementi del vettore ε_t non sono necessariamente non correlati, cioè che in generale $\mathbf{E}(\varepsilon_{it} \varepsilon_{jt}) = \sigma_{ij} \neq \mathbf{0}$ (la deviazione standard fra due elementi di ε_t può essere diversa da zero) per elementi di ε indicizzati da \mathbf{i}, \mathbf{j} con $\mathbf{j} \neq \mathbf{i}$; per contro, per ipotesi nessuna delle componenti del vettore ε esibisce correlazione seriale, ossia $\mathbf{E}(\varepsilon_{it} \varepsilon_{i\tau}) = \mathbf{0}, \forall i$ e $\forall \tau \neq t$.

Infine, resta da indicare il vettore \mathbf{c} , ossia il vettore delle costanti (o intercetta) che si presenta nella seguente forma:

$$\mathbf{c} = \begin{bmatrix} c_1 \\ \vdots \\ c_n \end{bmatrix}$$

Per capire ancora meglio la reduced form, consideriamo il modello VAR dal punto di vista della stima dei coefficienti, in modo tale da poterlo scrivere anche nel seguente modo:

$$\begin{aligned} y_{1t} &= c_1 + \varphi_{11}^{(1)} y_{1t-1} + \dots + \varphi_{1p}^{(p)} y_{nt-p} + \varepsilon_{1t} \\ &\quad \vdots \\ y_{nt} &= c_n + \varphi_{n1}^{(1)} y_{1t-1} + \dots + \varphi_{np}^{(p)} y_{nt-p} + \varepsilon_{nt} \end{aligned}$$

Osservando che al secondo membro di ogni equazione figurano le stesse variabili, il VAR(p) risulta equivalente ad un modello SURE (Seemingly Unrelated Regression Equations), i cui coefficienti possono essere stimati considerando ogni equazione come una regressione lineare standard, indipendente dalle altre. In particolare, gli stimatori OLS (Ordinary Least Squares) ottenuti con il metodo dei minimi quadrati, risultano consistenti e cioè che all'aumentare dell'informazione, la distribuzione di probabilità di ognuna di esso, si concentra in corrispondenza del valore del parametro da stimare [11].

Structural form

La structural form di un modello VAR(p) è formalizzata da un'equazione del tipo:

$$A_o Y_t = \mathbf{m} + A(\mathbf{L}) Y_{t-1} + u_t$$

dove \mathbf{m} è simile al vettore di costanti \mathbf{c} della reduced form, A_0 è la matrice $n \times n$ che identifica le relazioni strutturali contemporanee tra le diverse componenti di Y_t , mentre il vettore u_t è chiamato rumore bianco ed è un vettore di disturbi che in particolare ha componenti tra loro correlate: $\mathbf{E}(u_{it} u_{ij}) = \mathbf{0}$ per $\mathbf{j} \neq \mathbf{i}$.

Come si può notare, la forma strutturale è molto simile a quella ridotta con la differenza di avere la matrice A_0 al primo membro: all'interno di essa, e precisamente, sulla sua diagonale principale, si avranno elementi tutti pari a 1 e quindi vuol dire che il valore 1 lo si avrà alla variabile i-esima in corrispondenza dell'equazione i-esima.

La structural form è una forma di supporto per la reduced form, e questo perché possiamo passare dalla prima forma alla seconda pre-moltiplicando a sinistra di ambo i membri l'inversa della matrice A_0 :

$$\mathbf{Y}_t = A_0^{-1} \mathbf{m} + A_0^{-1} A(L) \mathbf{Y}_{t-1} + A_0^{-1} u_t = \mathbf{c} + \Phi(L) \mathbf{Y}_{t-1} + \varepsilon$$

Quest'ultima la si può riscrivere in questo modo:

$$(I - \Phi(L)L) \mathbf{Y}_t = \mathbf{c} + A_0^{-1} u_t$$

da cui si ottiene una forma detta forma finale del modello VAR(p) o rappresentazione di Wold:

$$\mathbf{Y}_t = (I - \Phi(L)L)^{-1} \mathbf{c} + (I - \Phi(L)L)^{-1} A_0^{-1} u_t = \mu + \Psi(\mathbf{L}) u_t$$

dove \mathbf{I} è la matrice identica, $\Psi(\mathbf{L})$ è un polinomio matriciale nell'operatore L di ordine finito, e μ è il valore atteso non condizionato di Y_t . In altre parole, il VAR(p), processo vettoriale autoregressivo di ordine finito, è equivalente a un processo in media mobile di ordine infinito.

Companion form

La companion form di un modello VAR(p) è la riscrittura della sua reduced form con l'accorpamento di p espressioni vettoriali. L'equazione rappresentante questa nuova forma è la seguente:

$$\begin{bmatrix} \mathbf{Y}_t \\ \mathbf{Y}_{t-1} \\ \vdots \\ \mathbf{Y}_{t-p+1} \end{bmatrix} = \begin{bmatrix} \mathbf{c} \\ \mathbf{0} \\ \vdots \\ \mathbf{0} \end{bmatrix} + \begin{bmatrix} \Phi_1 & \Phi_2 & \cdots & \Phi_{p-1} & \Phi_p \\ I & \mathbf{0} & \cdots & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & I & \cdots & \mathbf{0} & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ \mathbf{0} & \mathbf{0} & \cdots & I & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{Y}_{t-1} \\ \mathbf{Y}_{t-2} \\ \vdots \\ \mathbf{Y}_{t-p} \end{bmatrix} + \begin{bmatrix} A_0^{-1} u_t \\ \mathbf{0} \\ \vdots \\ \mathbf{0} \end{bmatrix}$$

Seguendo la notazione prima descritta, si possono identificare, in questa equazione, quattro vettori di vettori e una matrice di matrici, dove gli zeri presenti nei vettori e nella matrice rappresentano rispettivamente vettori nulli di dimensione $n \times 1$ e matrici nulle di dimensioni $n \times n$.

È possibile riscrivere l'equazione nel seguente modo:

$$Z_t = \lambda + F|Z_{t-1} + \xi_t$$

dove $E(\xi_t) = 0$, ed essendo $\xi_t = [\xi'_1, \dots, \xi'_T]'$, si ha $E(\xi \xi') = \sum \otimes I_t$ dove \sum è la matrice varianze-covarianze dei disturbi ε e \otimes indica il prodotto di Kroenecker.

È importante sottolineare, infine, che la forma adottata generalmente da un modello VAR per effettuare analisi statistiche dei dati, è la **reduced form**.

2.2.2 Implementazione in R

R è un linguaggio e un ambiente di sviluppo per l'analisi statistica e grafica.

È un progetto GNU simile al linguaggio e ambiente di sviluppo S, il quale fu sviluppato ai laboratori Bell (Bell Laboratories) da John Chambers e i suoi colleghi. R può essere considerato come una diversa implementazione di S. Ci sono importanti differenze, ma molto del codice scritto in S può essere eseguito senza dover apporre modifiche in R.

R fornisce un'ampia varietà di tecniche statistiche (modellazione lineare e non, test statistici classici, analisi di serie temporali, classificazione, clustering, ...) e grafiche ed è molto estendibile.

Le sue caratteristiche principali sono:

- semplicità nella gestione e manipolazione dei dati;
- disponibilità di una suite di strumenti per calcoli su vettori, matrici, ed altre operazioni complesse;
- accesso ad un vasto insieme integrati per l'analisi statistica;
- produzione di numerose potenzialità grafiche particolarmente flessibili;
- possibilità di adoperare un vero e proprio linguaggio di programmazione orientato ad oggetti che consente l'uso di strutture condizionali e cicliche, nonché di funzioni create dall'utente;

È distribuito gratuitamente sotto i vincoli GPL (General Public License) ed è disponibile per diverse architetture hardware e sistemi operativi: Unix, Linux, Windows, MacOS. Sul sito della CRAN (<<http://www.r-project.org>>) è possibile scaricare, oltre che il programma base, anche una serie di moduli aggiuntivi e un'ampia manualistica sull'ambiente, che va dall'installazione del software al suo utilizzo all'analisi dei dati [12].

Sono di seguito descritte le due funzioni in R considerate nella realizzazione di questo progetto di tesi:

- VARselect;
- VAR;

VARSelect

```
VARselect(y, lag.max = value1, type = value2, season = value3,
          exogen = value4)
```

dove:

- y è la matrice delle variabili endogene (cap. 2.1);
- lag.max, ossia il valore value1, è il massimo ordine di ritardo che si potrà avere nel modello VAR;
- type, nonché value2, rappresenta il tipo di regressori deterministici da includere nel modello VAR e uno dei possibili valori che può essere assegnato è: "const" (costante), "trend" (tendenza), "both" (entrambi, cioè costante e tendenza) e "none" (nessuno);
- season è la frequenza stagionale (periodicità) dei dati. Se value3 = 4 vorrebbe dire che si avranno dei dati trimestrali. Può assumere valore "NULL" e in questo caso indicherebbe un'assenza di stagionalità;
- exogen, ovvero value 4, rappresenta la matrice delle variabili esogene, cioè delle variabili indipendenti. Può assumere valore "NULL" e sta ad indicare che non ci sono variabili esogene.

Gli output sono:

- selection. È il vettore degli ordini ottimali ottenuti ognuno da ogni criterio possibile. I criteri sono delle funzioni avente un solo input e i criteri possibili sono quattro;
- criteria. È la matrice di dimensione 4 x lag.max contenente i valori ottenuti da ogni criterio attribuendo input che vanno da 1 fino a lag.max.

È di seguito riportato un esempio d'uso di questa funzione, con l'utilizzo del dataset "Canada" predefinito in R [20].

Questo dataset riporta le rilevazioni ottenute su quattro attributi effettuate trimestralmente dal 1980 al 2000. Tali attributi sono:

- e
- prod
- rw
- U

```
> data(Canada)
> select <- VARselect(Canada, lag.max = 5, type = "none", season = 3, exogen = NULL)
> select
$selection
AIC(n)  HQ(n)  SC(n)  FPE(n)
      3        2        2        3

$criteria
      1          2          3          4          5
AIC(n) -5.558469444 -6.15197629 -6.228779625 -6.054786702 -5.853594337
HQ(n)  -5.270082618 -5.67133158 -5.555877031 -5.189626223 -4.796175974
SC(n)  -4.838637185 -4.95225586 -4.549171021 -3.895289925 -3.214209388
FPE(n) 0.003859193  0.00214093  0.002001913  0.002424274  0.003048318
```

Figura 2.1: Esempio di utilizzo della funzione VARSelect

VAR

```
VAR(y, p = value1, type = value2, season = value3, exogen =
    value4, lag.max = value5, ic = value6)
```

dove i parametri già specificati per la funzione VARselect valgono anche qui mentre:

- p, nonché value1, rappresenta l'ordine di ritardo scelto per il modello VAR;
- ic, cioè value6, è l'informazione sul criterio utilizzato. I possibili criteri sono: "AIC" (Akaike), "HQ" (Hannan-Quinn), "SC" (Schwarz), "FPE" (Forecast Predict Error).

Gli output invece sono:

- p. È l'ordine di ritardo dato in input;
- K. Rappresenta la dimensione del modello VAR (cioè è il numero di attributi della matrice y data in input alla funzione VAR);
- varresult. È la lista di oggetti di regressione, dove ogni oggetto sarà associato al rispettivo attributo della matrice y data in input alla funzione VAR. Ad ognuno di questi oggetti è associato un vettore di coefficienti stimati tramite la regressione che si chiama coefficients. Questo vettore avrà un numero di coefficienti pari a p x K [13].

Come esempio di utilizzo di questa funzione si mostra la continuazione dell'apprendimento del modello VAR sul dataset Canada.

```
> p <- as.numeric(select$selection[2])
> result <- VAR(Canada, p = p, type = "none", ic = "HQ")
> result
```

Figura 2.2: Esempio di utilizzo della funzione VAR

In fig. 2.2, dalla posizione scelta all'interno del vettore in output dalla funzione "VARselect", "selection", per la lettura di p, è possibile notare come il criterio utilizzato sia "HQ".

Inoltre è ben visibile l'utilizzo di soli quattro parametri per il corretto utilizzo della funzione VAR, e ciò è possibile perché in precedenza è stata

utilizzata la funzione *VARselect* per la determinazione degli ordini di ritardo ottimali per ogni criterio.

```

VAR Estimation Results:
=====
Estimated coefficients for equation e:
=====
Call:
e = e.11 + prod.11 + rw.11 + U.11 + e.12 + prod.12 + rw.12 + U.12

      e.11      prod.11      rw.11      U.11      e.12      prod.12      rw.12      U.12
1.62046761  0.17973134 -0.04425592  0.11310425 -0.64815156 -0.11683270  0.04475537 -0.06581206

Estimated coefficients for equation prod:
=====
Call:
prod = e.11 + prod.11 + rw.11 + U.11 + e.12 + prod.12 + rw.12 + U.12

      e.11      prod.11      rw.11      U.11      e.12      prod.12      rw.12      U.12
-0.19389053  1.16559603  0.07426648 -0.66412399  0.20141693 -0.19089450 -0.06904805  0.77427171

Estimated coefficients for equation rw:
=====
Call:
rw = e.11 + prod.11 + rw.11 + U.11 + e.12 + prod.12 + rw.12 + U.12

      e.11      prod.11      rw.11      U.11      e.12      prod.12      rw.12      U.12
-0.273036691 -0.078046604  0.900047886 -0.024808893  0.331264372 -0.008858991  0.062587364 -0.175795886

Estimated coefficients for equation U:
=====
Call:
U = e.11 + prod.11 + rw.11 + U.11 + e.12 + prod.12 + rw.12 + U.12

      e.11      prod.11      rw.11      U.11      e.12      prod.12      rw.12      U.12
-0.561791776 -0.091739246 -0.001960487  0.785638638  0.574926136  0.068715871 -0.002926763  0.145852929

```

Figura 2.3: Output della funzione in fig. 2.2

In fig. 2.3 è possibile notare che il modello VAR appreso combina i valori presenti all'interno del dataset con una serie di coefficienti in modo tale da costruire una combinazione lineare necessaria per il calcolo dei valori futuri di ogni attributo. Si specifica che la struttura di ogni addendo all'interno delle equazioni è definita come:

- nome dell'attributo;
- .l;
- la quantità di istanti temporali di cui bisogna spostarsi indietro per recuperare il valore da moltiplicare con il rispettivo coefficiente.

Si noti inoltre che ogni attributo è messo in relazione con tutti gli altri (anche con se stesso) e che il modello si sposta di due elementi indietro nella finestra temporale. Tale valore è determinato dall'ordine di ritardo ottimale per il criterio scelto (che ricordiamo essere due).

2.3 Clustering

Il *clustering* è una tecnica di apprendimento non supervisionato la quale organizza un’insieme di istanze in gruppi di similarità.

Tali gruppi, che contengono al loro interno istanze simili tra loro ma dissimili con le istanze contenute negli altri gruppi, vengono definiti *cluster*.

Le istanze all’interno di un gruppo sono chiamate *oggetti* o *data point* e l’istanza centrale del cluster è definito *centroide*.

L’obiettivo di un clustering è quindi quello di scoprire il raggruppamento dei dati attraverso l’uso di un algoritmo di clustering e di una funzione che calcola la similarità (/dissimilarità) tra essi [16].

Sono di seguito descritte le principali tecniche di clustering:

- Clustering partizionale;
- Clustering gerarchico;
- Cluster concettuale e interpolativo.

2.3.1 Clustering partizionale

Il clustering partizionale è una tecnica di clustering che punta a suddividere le istanze di un dataset in k cluster. Tale numero è a discrezione dell’utente e può essere $1 \leq k \leq |n|$ con $|n|$ cardinalità massima dell’insieme delle istanze [17].

L’algoritmo più utilizzato in letteratura che implementa questa tecnica è il k-means.

Il passo base della procedura prevede la costruzione di k cluster, ognuno contenente un solo oggetto, scelto in base ad alcuni criteri. Esso è il *textit{centroide}* del cluster e ne è rappresentativo. Per definire a quale gruppo appartengono gli oggetti rimanenti viene calcolata la distanza fra ognuno di questi e ogni centroide. L’oggetto viene quindi raggruppato nel cluster il cui centroide minimizza la distanza dall’oggetto in questione.

2.3.2 Clustering gerarchico

Il clustering gerarchico ([18]) è una tecnica di apprendimento non supervisionato che si occupa di raggruppare i dati a diversi livelli di profondità, stabilendo così una gerarchia fra i gruppi di oggetti simili. Possiamo rappresentare le relazioni fra i gruppi tramite una struttura dati ad albero chiamata dendrogramma (fig. 2.4).

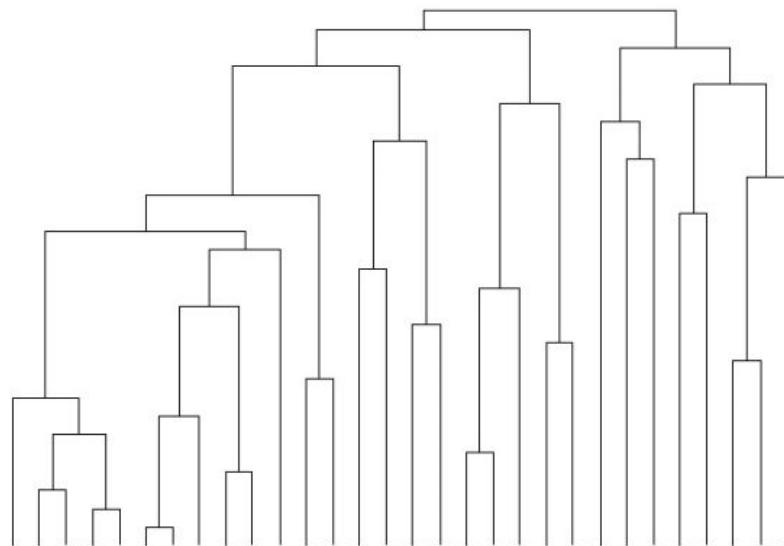


Figura 2.4: Dendrogramma

Esistono due tipi di clustering gerarchico:

- clustering divisivo: approccio di tipo top-down che parte dall'analisi dell'intero dataset, rappresentato come il nodo radice del dendrogramma e si occupa di scomporlo ricorsivamente in nodi figli, fino ad arrivare al massimo ad aggiungere nodi impossibili da partizionare ulteriormente, cioè nodi foglia costituiti ognuno da un solo oggetto.
- clustering agglomeratito: approccio di tipo bottom-up che parte dall'analisi delle foglie dell'albero, cioè le singole istanze, e costruisce un nuovo nodo, cioè il padre, degli oggetti fra loro simili entro una certa soglia. Il processo si conclude quando due o più nodi della struttura si agglomereranno in un unico nodo, che è definito *radice*, corrispondente all'intero insieme dei dati di partenza.

Il clustering gerarchico, a differenza del clustering partizionale in cui è utilizzata solo una funzione di dissimilarità tra le istanze per la costruzione di esso, necessita di una funzione di distanza al fine di calcolare quanto "distanzano" tra loro due insieme di oggetti, sottoinsiemi dell'insieme iniziale di dati. Questo calcolo è necessario ogni volta che si vogliono confrontare due nodi dello stesso dendrogramma allo stesso livello di profondità diverso dall'ultimo. Sono di seguito elencati (e descritti concettualmente) i principali metodi per calcolare la distanza tra due insiemi:

- Metodo single-link: la distanza fra due cluster è uguale alla distanza fra i due oggetti più vicini dei due cluster (un data point per cluster). Matematicamente, questo metodo, considerando la distanza tra i cluster X e Y , è descritto tramite l'espressione:

$$D(X, Y) = \min_{x \in X, y \in Y} d(x, y)$$

- Metodo complete-link: la distanza fra due cluster è uguale alla distanza fra i due oggetti più lontani dei due cluster. Sempre considerando la distanza tra i cluster X e Y , la descrizione matematica di tale metodo è:

$$D(X, Y) = \max_{x \in X, y \in Y} d(x, y)$$

- Metodo average-link: la distanza fra due cluster è data dalla media delle distanze calcolate fra tutte le coppie di oggetti appartenenti a cluster diversi. La formula per il calcolo matematico di tale metodo è la seguente:

$$D(X, Y) = \frac{1}{|X||Y|} \sum_{x \in X} \sum_{y \in Y} d(x, y)$$

- Metodo dei centroidi: la distanza fra due cluster è uguale alla distanza fra i centroidi dei due cluster (X e Y). L'espressione matematica che descrive tale metodo è:

$$D(X, Y) = d(\hat{c}_x, \hat{c}_y)$$

2.3.3 Clustering concettuale e interpolativo

Le tecniche tradizionali di clustering permettono di raggruppare istanze di dati che sono tra loro simili. Nel clustering concettuale o *conceptual clustering* [19] invece si fornisce in più una interpretazione dei dati che sono stati raggruppati nello stesso insieme. Viene infatti associato a ciascun cluster la sua descrizione concettuale. In questa nuova tecnica di clustering, una nuova istanza viene confrontata con tutte le descrizioni associate ai cluster per stabilire il suo cluster di appartenenza.

Il clustering interpolativo (o *interpolative clustering*) è una forma di apprendimento supervisionato, differentemente del clustering concettuale. Oltre alla descrizione del clustering, viene associato anche un modello predittivo che sta a rappresentare un "riassunto" (*summarization*) dei dati contenuti nel cluster.

2.4 VARForecaster 1.0/2.0

In [1] sono descritte due versioni dell'algoritmo che, avuto in input un insieme di sensori (definito in seguito *dataset*), tramite applicazione del modello VAR effettuano predizione di quelli che potrebbero essere i valori assunti da tali sensori nel futuro.

2.4.1 VARForecaster 1.0

I sensori effettuano rilevazioni periodicamente e questo porta ad avere un flusso di dati multi-variato, rappresentato, per ogni istante di tempo, attraverso uno snapshot e l'insieme degli snapshot compone il dataset.

La versione VARForecaster 1.0 è caratterizzata dall'apprendimento di un modello VAR per ogni sensore appartenente alla rete, utilizzando come dati di training la serie storica multi-variata, la quale contiene le rilevazioni effettuate dal sensore.

Questo processo ([1]) avviene finché c'è uno snapshot da processare e nel dettaglio si compone di:

- (1) leggere lo snapshot e memorizzarne i dati;
- (2) aggiornare la serie storica multi-variata associata ad ogni sensore;
- (3) apprendere un modello VAR per sensore;
- (4) effettuare, se possibile, il forecast per ogni sensore.

Durante la terza fase, per ognuno dei sensori, in base ai rispettivi dati di training, viene associato un modello VAR ad ogni sensore, e ciò è possibile se e soltanto se siano stati esaminato un numero di istanti temporali sufficienti alla costruzione dello stesso. Il numero minimo di istanti per la costruzione di tale modello è parametrizzato e l'utente può deciderlo arbitrariamente. Una volta raggiunta la soglia sarà sempre possibile apprendere il modello VAR.

Se il modello VAR è stato appreso è possibile effettuare la previsione (forecast).

Questa si effettua applicando, per ogni sensore, al modello VAR la serie storica dello stesso. È possibile prevedere quanti istanti temporali si vuole, con la premessa che previsioni più "lontane" sono meno precise di quelle immediatamente successive all'istante temporale t in oggetto. Per le successive previsioni le equazioni vanno calcolate considerando come ultimo istante di tempo della serie storica la previsione precedentemente effettuata. La quantità di previsioni da effettuare sono a discrezione dell'utente [1].

Le fasi di lettura del nuovo snapshot e di aggiornamento delle serie storiche devono tenere conto della probabile presenza di sensori inattivi.

Per sensore inattivo [1] si intende un sensore appartenente alla rete che non ha effettuato alcuna rilevazione in quell'istante di tempo per un qualsiasi motivo (disattivazione manuale del sensore, guasto hardware, guasto software...) e per il quale deve comunque essere mantenuta la finestra di rilevazioni effettuate nel tempo.

Durante le fasi di esecuzione del sistema tale probabilità viene gestita in maniera diversa [1]. Infatti, durante la seconda fase, ovvero quella di aggiornamento delle serie temporali viene controllato se per il sensore, precedentemente, sia stata effettuata o meno previsione. Nel caso in cui l'esito sia positivo, si sostituisce la previsione effettuata con `ahead = 1` alla rilevazione (non avuta), in caso contrario si "contrassegna" tale sensore con il valore massimo che Java permette per la rappresentazione dei valori Double (definito in seguito "*MAX-VALUE*").

In base a questa strategia è naturale che se per un sensore è effettuata una volta previsione sarà sempre possibile effettuarne altre.

Durante la seconda fase il sistema deve invece verificare che la sua serie storica non contenga il valore significativo di non rilevazione "*MAX-VALUE*". Nel caso in cui tale valore sia presente, non è possibile effettuare apprendimento del modello VAR.

Durante la quarta ed ultima fase, il sistema deve solo controllare che per il sensore in oggetto sia stato appreso il modello VAR, in caso positivo effettuerà la previsione, altrimenti no.

2.4.2 VARForecaster 2.0

VARForecaster 2.0 ([1]) adatta il *clustering interpolativo* al fine di raggruppare sensori per i quali si mantiene un sommario relativamente alla finestra temporale da usare per la costruzione del modello VAR. Questa struttura, oltre ad includere le condizioni di split scelte in base alle autocorrelazioni spaziali che intercorrono tra i sensori, è dinamica nel tempo.

Per ciascun cluster è poi appreso un modello VAR in base alla serie storica multi-variata che lo rappresenta, determinata dalla media assunta da ciascuna variabile all'interno del cluster di appartenenza, e con la combinazione lineare tra quest'ultima ed il modello stesso è in seguito effettuata una predizione dei valori futuri per ciascuna delle istanze che ricadono all'interno di quel cluster [1].

L'autocorrelazione spaziale altro non è che un cluster territoriale di valori simili. Se a valori simili nelle istanze corrisponde una vicinanza spaziale si è in presenza di autocorrelazione spaziale positiva, al contrario l'autocorrelazione

viene definita come negativa. Tali valori sono fondamentali per la scelta del partizionamento ottimale dei sensori.

I punti cardine di questa versione sono:

- (1) fase di apprendimento della struttura Clustering Tree (CT in seguito);
- (2) fase di modifica incrementale del CT;
- (3) fase di apprendimento del modello VAR;
- (4) fase di forecast.

Fasi di apprendimento e modifica incrementale del CT

Un Clustering Tree ([1]) è una struttura ad albero utilizzata per rappresentare uno snapshot mediante un insieme di cluster organizzati gerarchicamente su di esso.

In questo modo per ogni sensore ricadente all'interno del nodo in oggetto esiste una sequenza di cluster $C_{i0}, C_{i1}, \dots, C_{ir}$ nei quali la partizione all'interno del quale si trova tale sensore è inclusa. Per permettere ciò, è necessaria che sia rispettata la condizione di inclusione $C_{i0} \supseteq C_{i1} \supseteq \dots \supseteq C_{ir}$.

Ogni cluster $C_{i0}, C_{i1}, \dots, C_{ir}$ è associato ad un nodo $n_{i0}, n_{i1}, \dots, n_{ir}$ e ogni nodo n_{ij} appartenente al CT è un figlio diretto del nodo n_{ij-1} ($j = 1, \dots, r$). Il nodo radice è definito da n_{i0} , dove 0 indica appunto il livello del nodo all'interno dell'albero.

Apprendere un CT quindi vuol dire effettuare un processo di clustering sullo snapshot ricevuto in ingresso e associare una struttura ad albero ad esso, in modo tale che ogni nodo corrisponda ad un cluster.

Nel dettaglio l'algoritmo per l'apprendimento del CT lavora in maniera ricorsiva secondo un approccio top-down, ricevendo in input uno snapshot, partizionandolo (in base ai valori assunti dai sensori e alle autocorrelazioni spaziali che intercorrono tra di essi) e fermandosi quando sono soddisfatti dei criteri di stop.

Essendo questo un algoritmo ricorsivo con criterio top-down, su ogni nuovo cluster(/nodo) c trovato, si tenta di apprendere altri sotto-alberi con radice c . Tale processo si ferma se ci sono troppe poche istanze in c oppure se c è troppo adattamento ai dati e quindi si rischia il problema dell'over-fitting dell'albero.

Il processo principale di questo algoritmo è la scelta delle condizioni di split. Essendo lo scopo fondamentale del clustering la massimizzazione della riduzione della varianza degli indicatori locali dell'autocorrelazione spaziale all'interno dei cluster, le condizioni di split indicano i migliori accoppiamenti

attributo-valore in grado di diminuire tale valore. La migliore tra tutte le condizioni è quella scelta e sarà utilizzata come decisione per dividere (partizionare) lo snapshot (o la partizione di esso se ci troviamo in un nodo che non sia la radice dell'albero).

Al termine di questa fase ad ogni nodo sarà stata associata una serie storica multi-variata, rappresentante i valori assunti nel tempo da tutti gli attributi, per ciascuna istanza che ricade nel cluster, contenente un solo valore per attributo. Tale valore è la media di tutti i valori assunti da quell'attributo da tutti i sensori presenti nel cluster.

La fase incrementale nell'apprendimento del CT lo adatta al nuovo snapshot ricevuto in input. Per fare ciò si avvale di un algoritmo ricorsivo con metodo top-down il quale attraversa l'albero e si preoccupa di trovare quei cluster che presentano un sostanziale cambiamento nella proprietà di autocorrelazione spaziale.

Questo processo di divide nella fase di pruning e nella fase di apprendimento di nuovi sotto-alberi.

La fase di pruning interessa solo i nodi di decisione e li pota se non riconosce un'effettiva convenienza nel mantenimento di tale split. Potare un nodo n significa cancellare i sotto-alberi che aveno n come radice e trasformare quindi n stesso in foglia. Tale procedimento non intacca la serie storica multi-variata associata al nodo ne tanto meno le istanze che ricadono al suo interno e quindi i valori medi, minimi e massimi assunti dalle feature nel cluster rimangono invariate.

La fase di apprendimento di nuovi sotto-alberi, successiva a quella di pruning, interessa invece soltanto i nodi foglia. Partendo da essi infatti, l'algoritmo ricorsivo cerca di capire se sia possibile e conveniente apprendere dei nuovi cluster. Nel caso in cui siano appresi nuovi cluster a partire dal nodo n , la radice del nuovo sotto-albero sarà n e le serie storiche multi-variate associate a questi nodi saranno, fino all'istante $t-1$ copiate dalla serie temporale multi-variata di n , mentre per l'istante temporale corrente, ovvero t , il valore sarà calcolato in base alle istanze che realmente ricadono all'interno del cluster.

Fasi di apprendimento del modello VAR e predizione

Nel momento in cui l'apprendimento incrementale di CT è terminato (per quello snapshot), per ogni cluster foglia, si prova ad apprendere un modello VAR. Questo viene appreso sulla base dei valori presenti all'interno della serie storica multi-variata ad esso associata e per poter avviare questo meccanismo vengono richiesti un minimo numero di istanti temporali all'interno di tale serie. Il numero minimo di medie multi-variate richieste all'interno della

serie è arbitrario ed è stato parametrizzato. Questo perché tale decisione dipende dalle necessità dell'utente. Tutto ciò implica che una volta raggiunta la soglia minima di istanti temporali processati è sempre possibile apprendere il modello VAR.

Nella fase di forecast vengono recuperati per ogni nodo il modello VAR ad esso associato e in base allo snapshot attuale, questo viene applicato all'istanza, quindi al sensore, corretto.

Per ciò che riguarda l'eventuale presenza di sensori inattivi, questa influenza soltanto sulla fase di previsione, in quanto, durante la fase di aggiornamento delle serie temporali ci si comporta come fatto in VARForecaster 1.0, per la fase di apprendimento dell'albero vengono considerati soltanti i sensori attivi e per l'apprendimento del modello VAR viene utilizzata la serie temporale associata al cluster e quindi eventuali valori non rilevati, non facendo parte di tale cluster, non ne influenzerebbero la costruzione.

L'applicazione, durante la fase di previsione, deve controllare, per ogni sensore, che la propria serie storica multi-variata non contenga valori non significativi (*MAX-VALUE*) negli istanti temporali coinvolti nella previsione. Nel caso in cui tale riscontro sia positivo per quel sensore sarà effettuato forecast, in alternativa no. In base a tale assunzione, se per un sensore viene effettuato forecast una volta, sarà sempre possibile effettuarne altri.

Capitolo 3

VARForecaster 2.1/2.2

In questo capitolo sono descritte le versioni dell'algoritmo (descritto nel par. 2.4) progettate ed implementate in questo lavoro di tesi.

Si ricorda che (come descritto nel par. 1.1) l'algoritmo è stato esteso al fine di calcolare gli aggregati dei dati in tempo reale (media o mediana) piuttosto che ricorrere ad approssimazione degli stessi e utilizzare un meccanismo di smoothing esponenziale per determinare il modello di clustering sulla base dei valori geofisici attesi nella rete all'istante $t+1$ piuttosto che sulla base dei valori osservati all'istante t . La motivazione è l'identificazione di una soluzione che realizza il miglior bilanciamento tra accuratezza e efficienza.

3.1 VARForecaster 2.1

L'albero è costruito in maniera incrementale (par. 2.4), ovvero, ad ogni nuovo snapshot di dati all'interno dello stream, l'algoritmo controlla che le condizioni di split in base alle quali è stato costruito il modello di clustering all'istante $t-1$ siano compatibili con i dati raccolti all'istante t .

A tale scopo, per ogni nuovo snapshot, l'albero è aggiornato eseguendo una fase di pruning e poi di ri-apprendimento dell'albero sulla base dei nuovi valori ricevuti.

Il pruning è un processo ricorsivo nel quale vengono analizzati i nodi di split, i quali sono potati se la loro condizione di split non porta ad una reale riduzione della varianza degli indicatori locali di autocorrelazione spaziale sui nuovi record.

Nel caso in cui venga applicata la potatura, il nodo di split viene sostituito con un nodo foglia, al cui interno ricadranno tutte le istanze precedentemente appartenenti al nodo di split.

La fase di ri-apprendimento dell'albero, al contrario di quella di pruning, prende in considerazione i nodi foglia, è infatti in questa fase che l'algoritmo VARForecaster tenta di apprendere nuovi sotto-alberi.

Secondo la versione 2.0 dell'algoritmo, nel momento in cui viene appreso un nuovo nodo, a questo viene assegnata, nella struttura dati che tiene traccia delle medie multi-variate assunte da ogni cluster (cioè la struttura dati *Feature Window*), la media precedente calcolata per il suo nodo padre (vedi par. 2.4).

Aggregazione in tempo reale

Al fine di migliorare la rappresentatività dei dati usati per l'apprendimento del modello VAR, si è pensato di ricostruire, per ogni nuovo nodo appreso, la media multi-variata ad esso associata, in modo tale da mantenere un'aggregato multi-variato calcolato sulla base dei reali valori assunti dalle istanze dei sensori che ricadono all'interno del cluster foglia.

Questo processo è realizzato all'interno della struttura dati *Node* e si sviluppa nei seguenti passi:

- Per ogni sensore appartenente al cluster foglia:
 - viene letta la serie storica multi-variata ad esso associato;
 - per ogni caratteristica (*Feature*) presente all'interno della serie:
 - * per ogni istante temporale precedente a t, viene letto il valore corrispondente e lo si somma agli altri valori letti per la caratteristica in esame;
 - * viene incrementato un contatore, il quale sarà necessario per definire quanti istanti temporali sono stati sommati.

Alla fine di tale procedimento, per ogni sensore, sono calcolati, in maniera separata, la somma ottenuta per ogni *Feature* ed il valore del contatore a quella caratteristica associata.

Questi valori rappresentano la media, per ogni *Feature*, delle rilevazioni effettuate fino all'istante t dall'insieme di sensori che ricadono all'interno del cluster foglia. Tali valori sono poi accodati all'insieme delle rilevazioni precedentemente effettuate dal sensore, per ogni singola *Feature*, nella struttura dati *Feature Window*.

Problematiche

Nel momento in cui si prova a definire un'aggregato multi-variato per un cluster si può incorrere in due inconvenienti:

- Sensori inattivi;
- Presenza di outliers;

Sono di seguito descritte le modalità secondo le quali è stato possibile risolvere entrambi i problemi.

Sensori inattivi

Nel calcolo della media, come specificato in precedenza, vengono considerate tutte le rilevazioni presenti all'interno della finestra temporale associata al sensore.

Se tale sensore in passato, anche per un singolo istante temporale t_x , non ha effettuato alcuna rilevazione, nella struttura dati *Feature Window* ad esso associata, per l'istante t_x , è salvato il valore massimo che Java permette per rappresentare una variabile di tipo Double (di seguito definito come "*MAX-VALUE*").

Se si prendesse in considerazione tale valore nel calcolo della media, quest'ultima risulterebbe definitivamente influenzata. Per evitare ciò, nel momento in cui si calcola la media, si controlla che il valore rilevato non sia "*MAX-VALUE*". Nel caso in cui si incorre in tale valore, il sensore incriminato, non viene considerato per il calcolo della media e il contatore non subisce alcuna modifica.

Presenza di outliers

Data la varietà di dati misurati e la distribuzione geografica dei sensori, è possibile che tra le rilevazioni effettuate possano esserci uno o più outliers.

Un outlier è un valore anomalo e aberrante; un valore quindi chiaramente distante dalle altre osservazioni disponibili [14]

Data la struttura di questi dati, che sarebbero assolutamente fuorvianti in caso di aggregati costruiti tramite l'utilizzo della media, è stato messa a disposizione dell'utente, come parametro per il lancio del software, la possibilità di scegliere se calcolare il suddetto aggregato con l'utilizzo della mediana.

In statistica, in particolare in statistica descrittiva, data una distribuzione di un carattere quantitativo oppure qualitativo ordinabile (ovvero le cui modalità possano essere ordinate in base a qualche criterio), si definisce la **mediana** (o **valore mediano**) come il valore assunto dalle unità statistiche che si trovano nel mezzo della distribuzione.

Se si procede al riordinamento delle unità in base ai valori crescenti del carattere da esso detenuto, in sostanza la mediana bipartisce la distribuzione in due sotto-distribuzioni: la prima a sinistra della mediana (costituita dalla

metà delle unità la cui modalità è minore o uguale alla mediana) e la seconda a destra della mediana costituita dalla metà delle unità la cui modalità è maggiore o uguale alla mediana). Tecnicamente si afferma che la mediana è il valore per il quale la frequenza relativa cumulata vale (o supera) 0,5.

Per calcolare la mediana di n dati [15]

- si ordinano gli n dati in ordine crescente;
- se il numero di dati è dispari la mediana corrisponde al valore centrale, ovvero al valore che occupa la posizione $\frac{n+1}{2}$;
- se il numero n di dati è pari, la mediana è stimata utilizzando i due valori che occupano la posizione $\frac{n}{2}$ e $(\frac{n}{2} + 1)$

A livello implementativo, la differenza fondamentale tra il calcolo degli aggregati multi-variati tramite media rispetto a farlo con la varianza, risiede nell'utilizzo di una struttura dati in cui vengono memorizzati i valori di ogni serie uni-variata per istante temporale t .

Da questa struttura si va poi a leggere il valore centrale, ovvero quello corrispondente alla mediana, per poi continuare ad operare come nel caso della media. Nel caso in cui invece il numero n di dati sia dispari, si provvede alla lettura dei due valori centrali e all'utilizzo della media per il calcolo del valore mediano.

Caso limite

Esiste, in maniera remota, la possibilità che tutti i sensori che ricadono in un cluster foglia, non abbiano mai effettuato alcuna rilevazione, fino all'istante temporale t in esame.

Per la gestione di questa casistica limite si è preferito quindi accodare un valore "*MAX-VALUE*", come quello presente in caso di sensore inattivo.

Così facendo è in seguito catturata e gestita un'eccezione che non permette il forecast.

Conseguenze

A causa della rielaborazione degli aggregati multi-variati in caso di apprendimento di un nuovo nodo, le serie storiche di ciascun cluster foglia risultano essere ora reali, ovvero adattate alle istanze che realmente ricadono all'interno di tale cluster. Come conseguenza primaria si ha quindi, che la costruzione del modello VAR rispecchierà in maniera maggiore la situazione reale del cluster.

La possibilità di scegliere se costruire gli aggregati con la media oppure con la varianza verrà data all'utente utilizzatore del software grazie ad una parametrizzazione della stessa.

Nella prossima sezione si riportano i diagrammi di classe e di sequenza relativi alla progettazione di VARForecaster 2.1.

3.1.1 Progettazione

In questa sezione sono illustrate, tramite diagrammi UML (Unified Modeling Language) le variazioni progettate in questo lavoro di tesi dell'algoritmo VARForecaster 2.1. Precisamente sono presenti: diagramma dei package, diagrammi delle classi e diagrammi di sequenza. Ognuno di essi è seguito da una descrizione.

Diagramma dei package

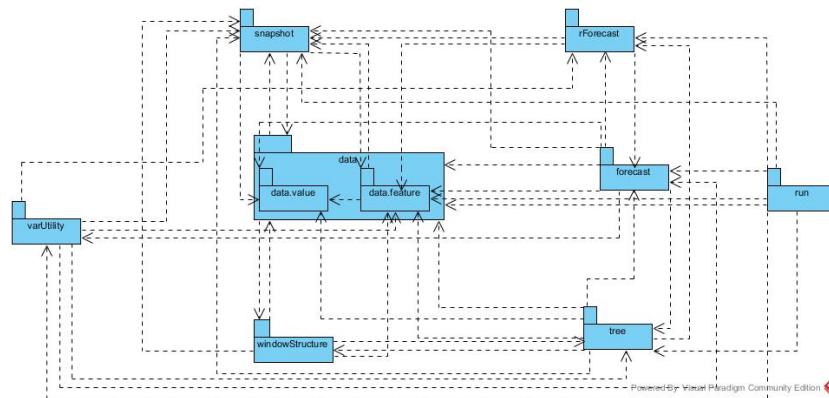


Figura 3.1: RealAggregate Package Diagram

Nella Fig. 3.1 sono descritti le principali relazioni che intercorrono tra i package presenti all'interno del software, ovvero come un package è in relazione con un altro.

A tali relazioni non è stata apportata alcuna modifica.

Diagrammi delle classi

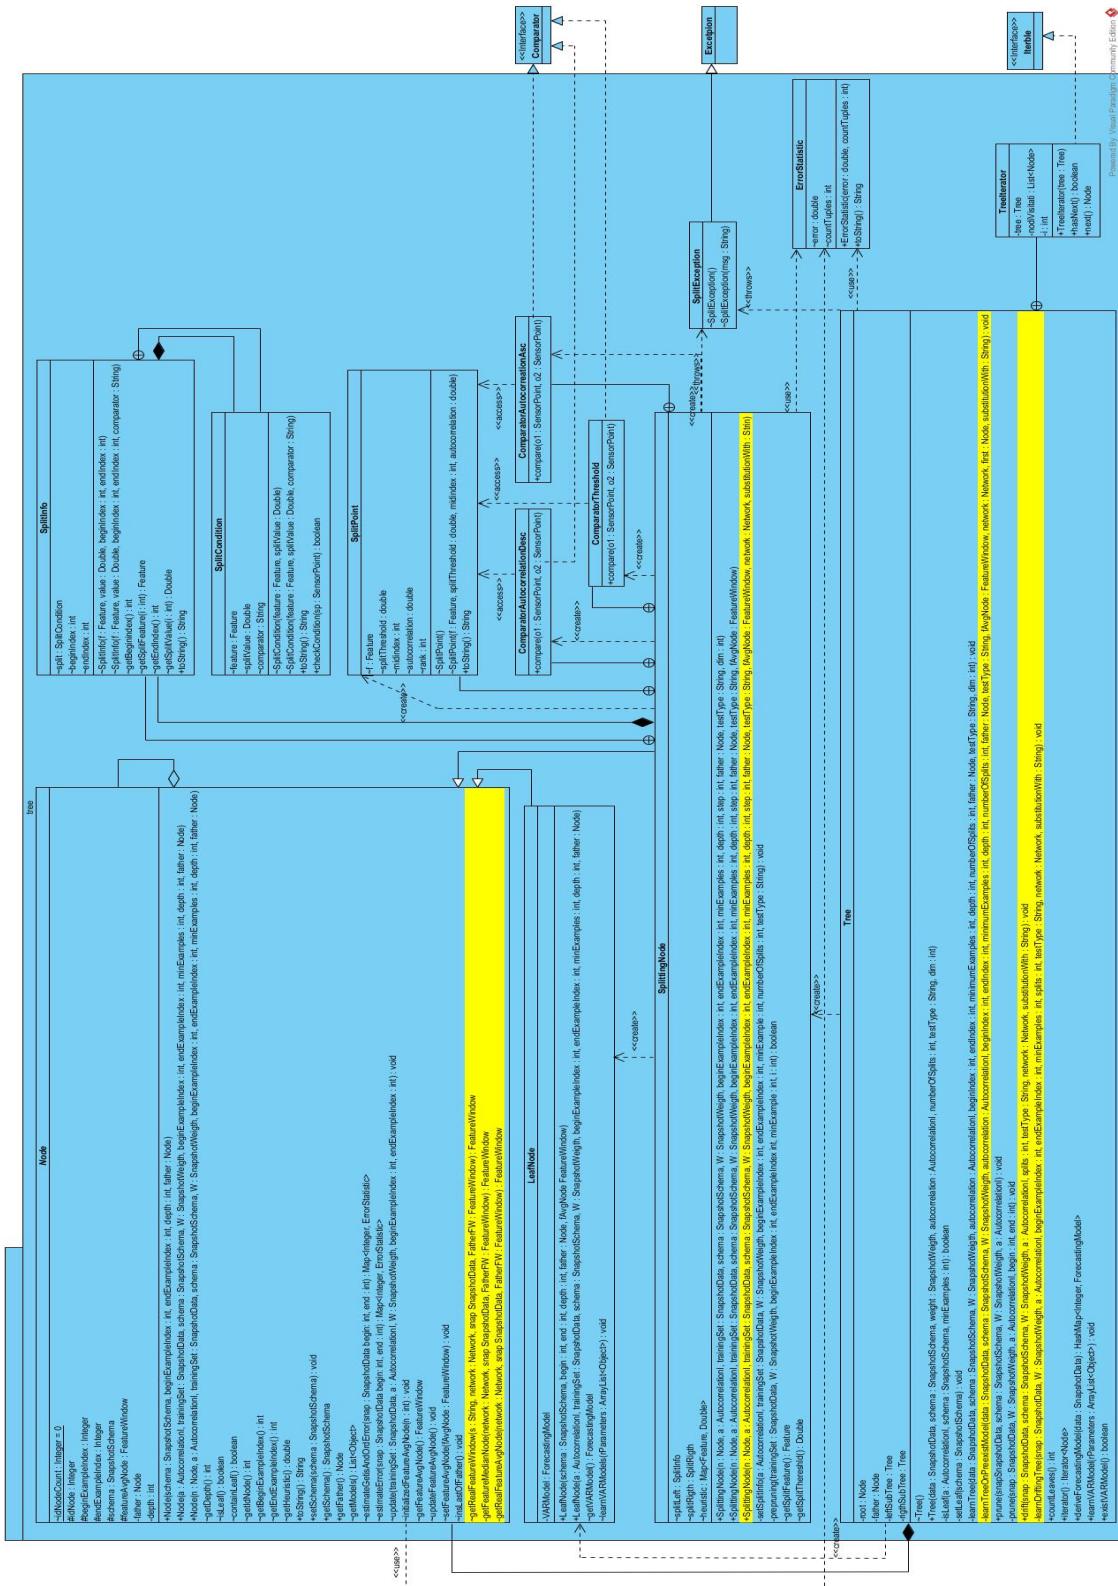


Figura 3.2: RealAggregate Tree Class Diagram

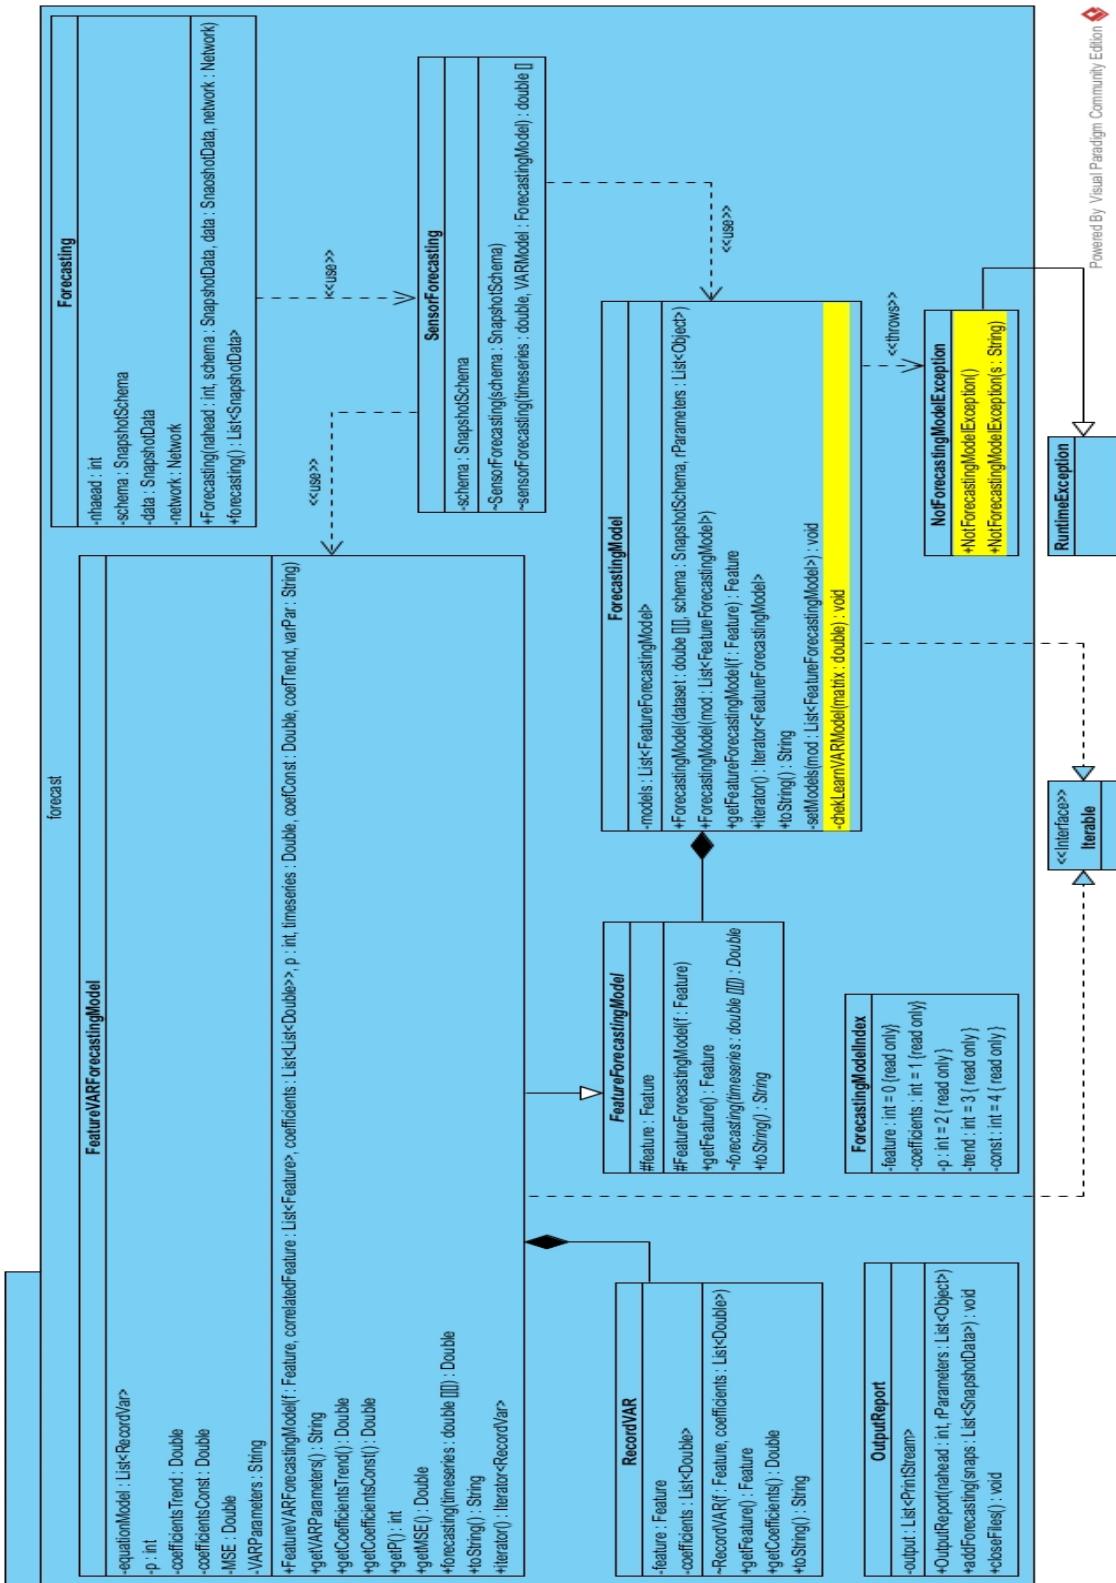
Come è possibile notare, in Fig. 3.2, ci sono dei metodi in giallo. Questi sono i metodi aggiunti rispetto alla versione VARForecaster 2.0.

Tali metodi hanno la responsabilità di calcolare gli aggregati reali e sono utilizzati vicendevolmente rispetto al parametro ricevuto in input dall'utente. Precisamente:

- `getRealFeatureWindow`: è il metodo che ha la responsabilità di leggere il parametro che determina il tipo di funzione da applicare per calcolare l'aggregato (media o mediana), di chiamare il metodo corretto e restituire la struttura contenente i dati aggregati aggiornati;
- `getFeatureMedianNode`: è il metodo che ha il compito di calcolare l'aggregato reale con la funzione "*mediana*";
- `getRealFeatureAvgNode`: è il metodo che ha la responsabilità di calcolare l'aggregare reale con la funzione "*media*".

Tali metodi sono utilizzati, come detto nel par. 3.1, nella fase di apprendimento incrementale del clustering, quindi per l'esattezza nel metodo privato `learnTreeOnPreexistModel` nella classe `Tree`.

Queste modifiche sono esplicitate chiaramente, nella seguente sotto-sezione, dai diagrammi di sequenza.



In Fig. 3.3 sono mostrate le modifiche al package *Forecast*. Esse sono state apportate in quanto è necessario controllare se nel modello VAR associato ad ogni nodo sono presenti "*MAX-VALUE*" i quali indicherebbero l'impossibilità di effettuare previsione.

Per gestire questa eventualità è stata aggiunta l'eccezione *NotForecasting-ModelException* la quale è catturata, nel caso in cui sia trovato il valore incriminato, dal metodo *checkLearnVARModel*.

Diagrammi di sequenza

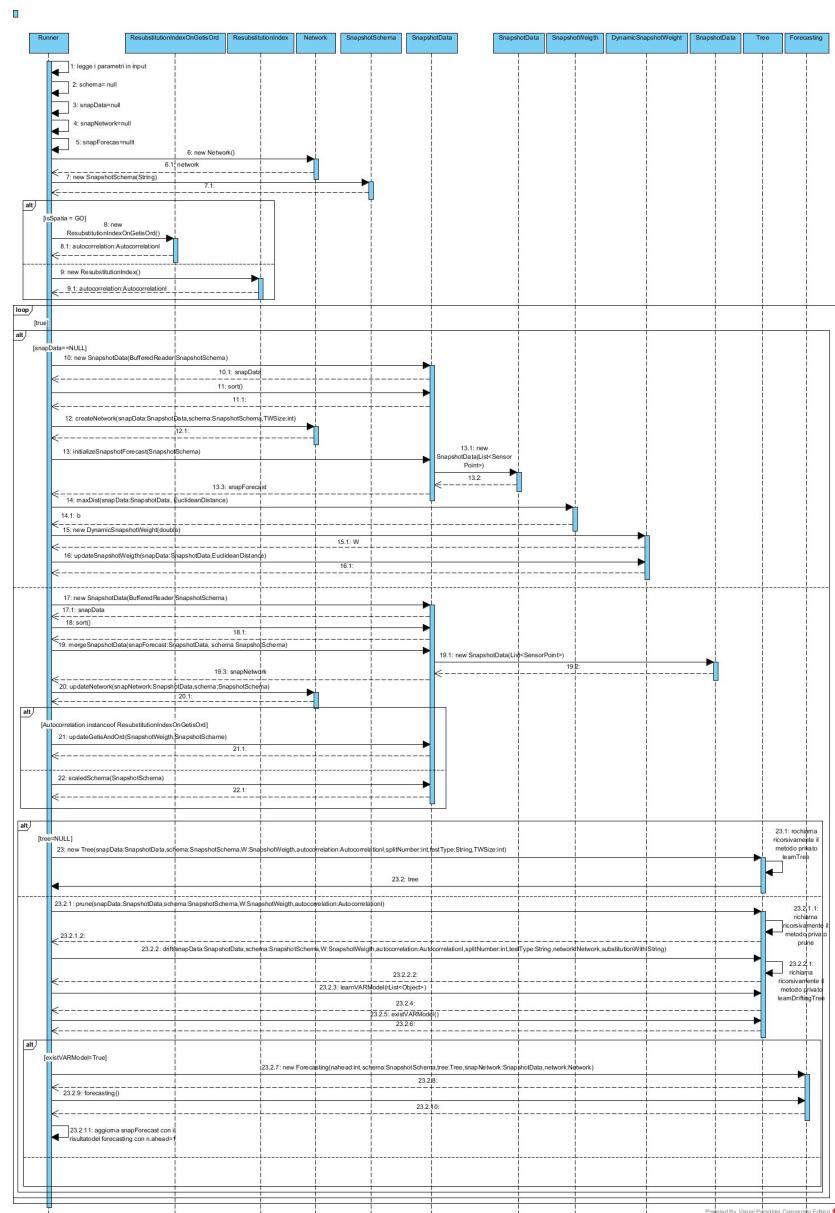


Figura 3.4: Run VARForecaster 2.1

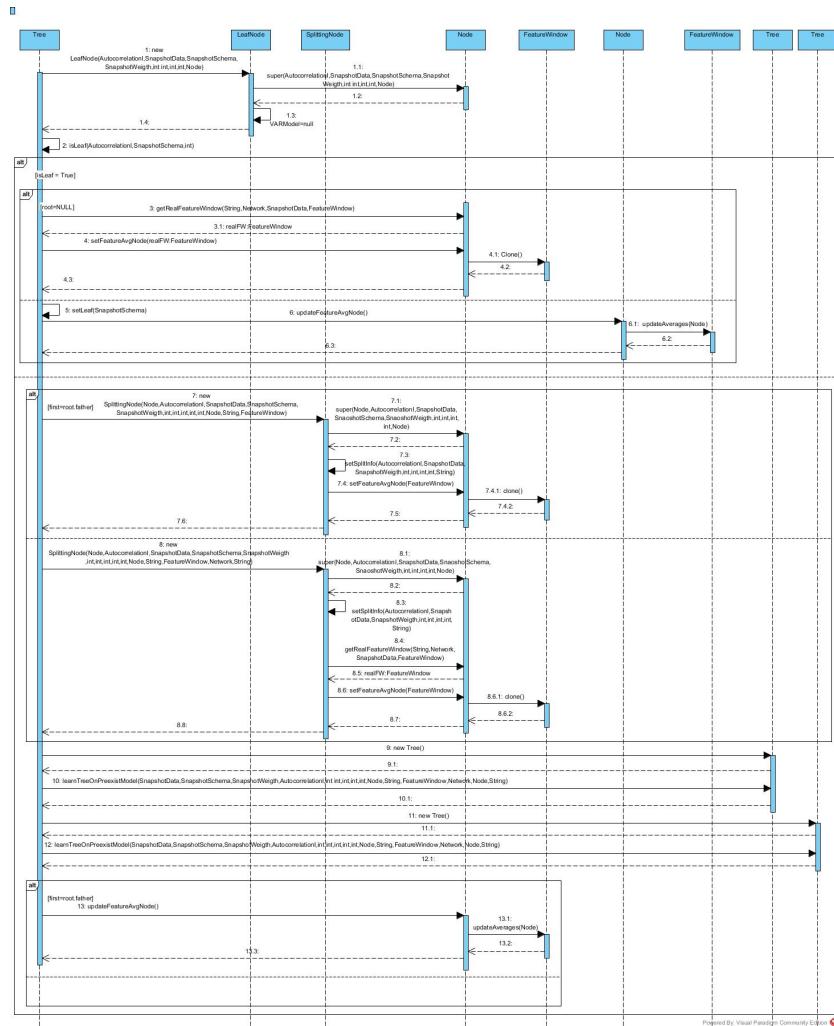


Figura 3.5: Riapprendimento CT VARForecaster 2.1

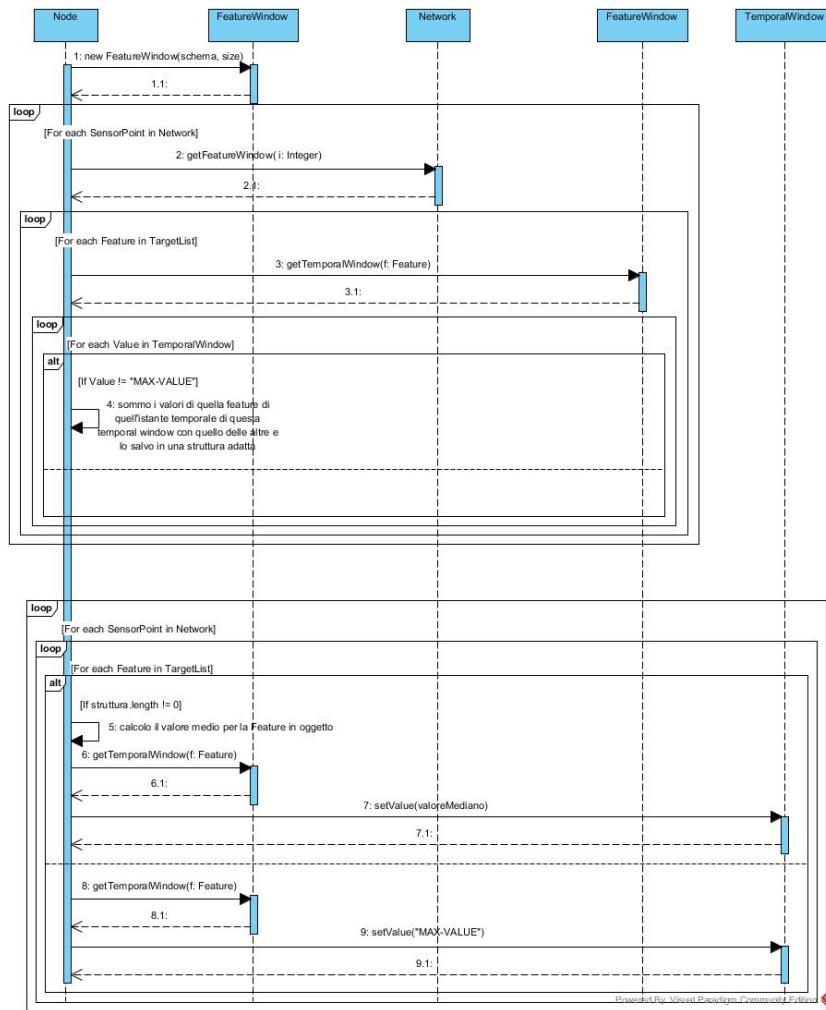


Figura 3.6: Apprendimento aggregato con media

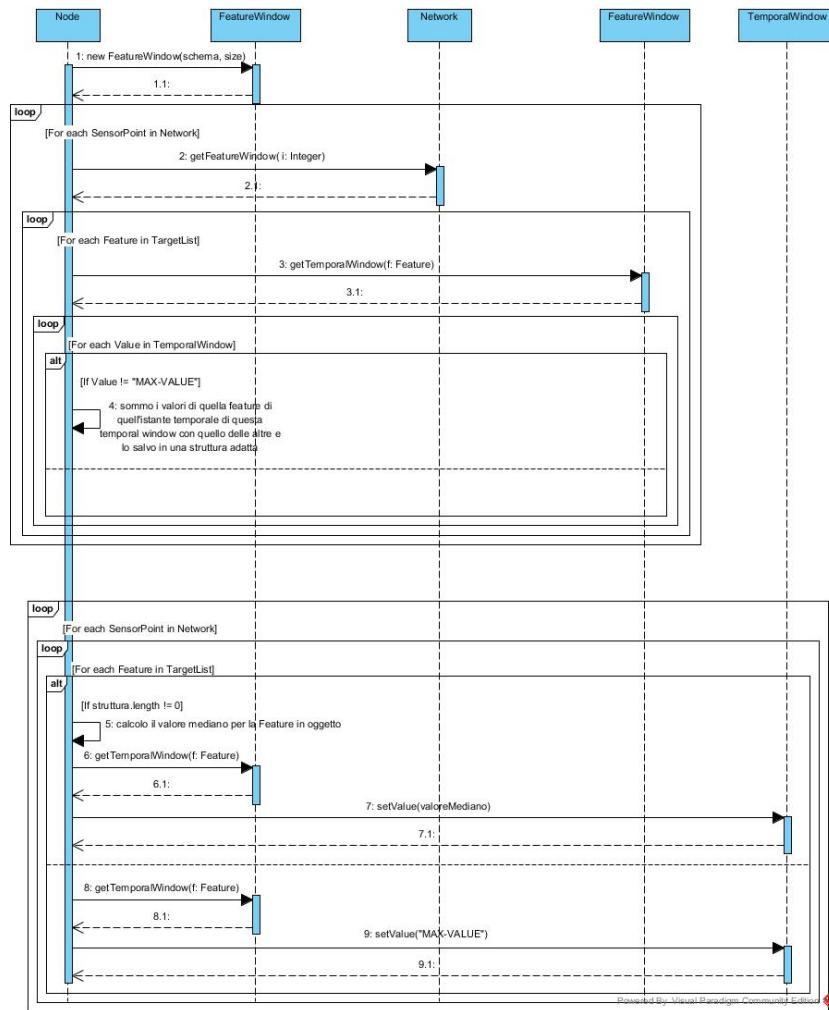


Figura 3.7: Apprendimento aggregato con mediana

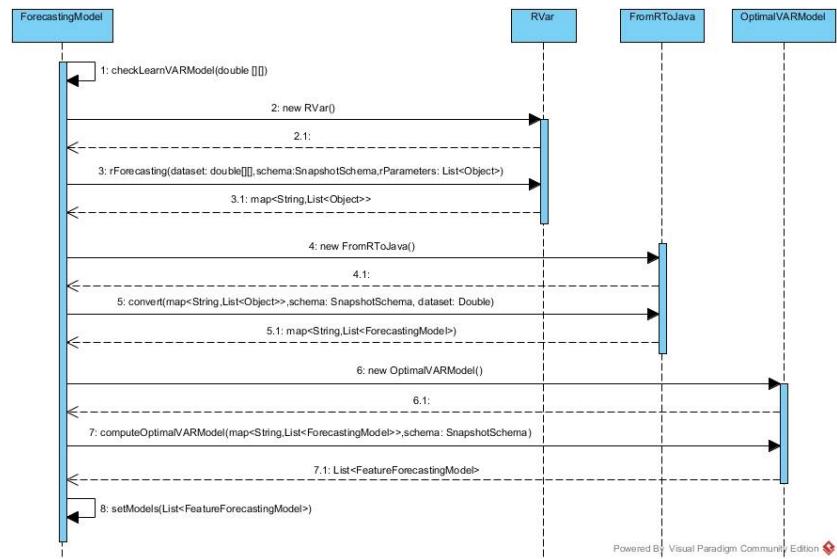


Figura 3.8: Apprendimento modello VAR VARForecaster 2.1

3.2 VARForecaster 2.2

VARForecaster 2.0 basa il partizionamento dei sensori sullo snapshot predetto usando un meccanismo di smoothing esponenziale.

L’albero, nelle versioni 2.0 e 2.1, viene appreso su ogni snapshot ricevuto in input all’istante temporale t mentre in questa versione è appreso sulla previsione effettuata sui dati avuti nell’istante $t-1$ tramite l’utilizzo della tecnica di smoothing esponenziale.

Per effettuare tale operazioni si sono rese necessarie alcune modifiche alla struttura del sistema che possono essere riassunte in 2 fasi:

- (1) creazione dello snapshot previsto attraverso lo smoothing esponenziale (in seguito def. *snapSmoot*);
- (2) apprendimento incrementale del *CT*;

Nei successivi paragrafi sono descritte entrambe le fasi con particolare attenzione alle modifiche effettuate.

Creazione dello *snapSmoot*

La fase di creazione dello *snapSmoot* avviene ogni qualvolta si processa un nuovo snapshot. Tale fase si preoccupa di leggere lo snapshot dell’istante temporale t in esame, precedentemente ricevuto in input, e processarlo al fine di produrre uno snapshot di previsioni di quelli che potrebbero essere i valori assunti da ciascuna feature di ciascuna istanza presente al suo interno.

Questo processo si compone di due casistiche:

- si tratta del primo istante temporale contenente i valori rilevati dai sensori;
- è un istante temporale successivo al primo, quindi abbiamo già applicato lo smoothing in precedenza.

Nel caso in cui sia stia analizzando il primo istante temporale, il sistema si preoccupa di clonare tutti i sensori ricevuti in input nello *snapSmoot*. Questo è dovuto al fatto che il passo base per il calcolo dello smoothing esponenziale è ottenuto con la copia dei dati ricevuti in ingresso.

Nel caso in cui invece si stia analizzando un istante temporale successivo al primo, il sistema ha la responsabilità di trovare, tra i sensori presenti nello *snapSmoot* di $t-1$, i sensori che nell’istante temporale t hanno effettivamente effettuato una rilevazione e combinarli applicando il metodo di *smoothing esponenziale di Brown*.

Sensori inattivi nella creazione dello *snapSmoot*

Come nel caso della versione VARForecaster 2.1, i sensori inattivi rappresentano un eventuale problematica da gestire.

Come precedentemente specificato, il sistema deve trovare tra i sensori presenti nello *snapSmoot* di $t-1$ quelli che hanno effettivamente rilevato dei dati nell'istante temporale t in considerazione. Ciò implica due conseguenze:

- (1) potrebbero esserci sensori presenti all'interno di *snapSmoot* ma non presenti all'interno dello snapshot attuale;
- (2) potrebbero esserci sensori presenti nello snapshot attuale ma non presenti nello *snapSmoot*.

Per la gestione di (1) è stato scelto di ignorare tali sensori in quanto il processo di smoothing, prendendo in considerazione gli istanti temporali precedenti a t avrebbe un valore mancante, il quale condizionerebbe tutto il meccanismo.

Per la gestione di (2), per lo stesso motivo appena citato, si è preferito far ripartire il processo di smoothing dal "passo base" e quindi di clonare il sensore reale.

Apprendimento incrementale del *CT*

In questa fase di progetto si è fatta molta attenzione a distinguere due processi:

- aggiornamento dei dati relativi ai cluster
- costruzione dell'albero

Per aggiornamento dei dati relativi ai cluster si intende quella fase in cui vengono aggiornati, per ogni nodo, relativamente al cluster a cui fanno riferimento, i valori delle feature di ogni sensore. Questo vuol dire che i dati presenti in ogni nodo sono riferiti ai valori realmente rilevati dai sensori che ricadono in quel cluster e non ai valori predetti con lo smoothing.

La costruzione dell'albero invece avviene sulla base dei valori predetti con lo smoothing. Ciò indica che l'albero sarà adattato ai valori previsti per quel gruppo di sensori che ricade nel nodo in oggetto.

Nella fase di crescita incrementale dell'albero questo vuol dire che non soltanto la fase di apprendimento ha subito modifiche ma anche quella di potatura.

In questa fase si applica l'operatore di pruning sulla base dei valori predetti per lo snapshot $t-1$ presenti in *snapSmoot* in quanto l'albero è stato appreso sulla base dei valori presenti in esso.

Tale processo avviene facendo attenzione, nella fase di aggiornamento dei dati in base ai valori ricevuti dal nuovo snapshot, a mantenere nel nodo i valori associati alle reali rilevazioni ottenute dai sensori che ricadono in quel nodo, mentre per il computo dell'autocorrelazione spaziale e per le decisioni di pruning, vengono utilizzati i valori presenti in *snapSmoot*.

La fase di apprendimento, detta anche *drift*, è la parte maggiormente modificata. Questo avviene perché le decisioni di split devono essere apprese in base allo *snapSmoot*, di conseguenza l'applicazione deve preoccuparsi di lavorare parallelamente su entrambi gli snapshot (*snapSmoot* e lo snapshot contenente i valori realmente rilevati).

Metodo scelto e parametrizzazione

Il metodo di smoothing utilizzato in questo progetto di tesi è il *metodo di Brown*. Si riporta la l'espressione matematica di tale metodo:

Passo ricorsivo

$$Y_t = \alpha x_t + (1 - \alpha) Y_{t-1}$$

Passo base

$$Y_t = x_t$$

dove, in questo progetto di tesi:

- x_t è lo snapshot contenente i valori realmente rilevati dai sensori;
- Y_{t-1} è lo *snapSmoot* ottenuto dall'applicazione della funzione di smoothing esponenziale sul precedente snapshot contenente i valori reali (x_{t-1});
- α è il parametro di smoothing.

La scelta del parametro di smoothing è arbitraria e affidata all'utente, ma per non adattare troppo i dati previsti a quelli reali o a quelli precedente previsti è consigliabile mantenersi entro $0.4 \leq \alpha \leq 0.6$.

3.2.1 Progettazione

In questa sezione sono presentati e descritti i diagrammi di classe e di sequenza che descrivono VARForecaster 2.2.

Diagrammi di classe

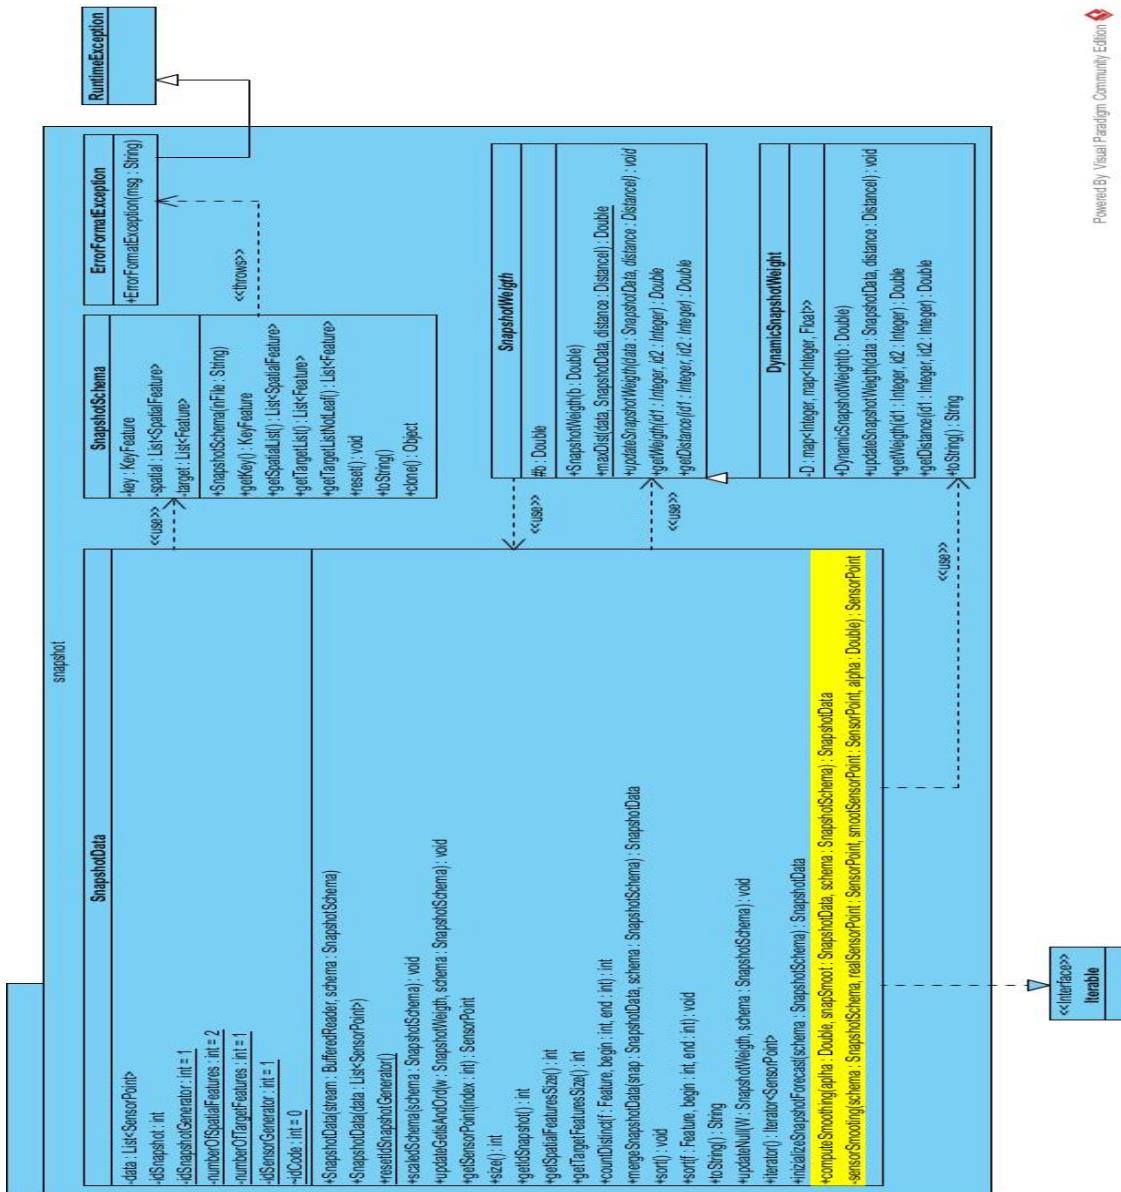


Figura 3.9: Exponential Smoothing Class Diagram

In Fig. 3.2.1 sono presentate le modifiche apportate al package *Snapshot*.

Queste modifiche interessano la classe *SnapshotData* e sono necessarie per modellare il meccanismo di smoothing esponenziale.

Sono stati aggiunti due metodi, i quali ricevuto in input uno snapshot (quello sul quale è stato applicato il metodo di smoothing all'istante temporale precedente) si preoccupano di crearne uno nuovo, che è la fusione tra lo snapshot reale e quello in input.

Tale snapshot è dato in input all'algoritmo di smoothing esponenziale.

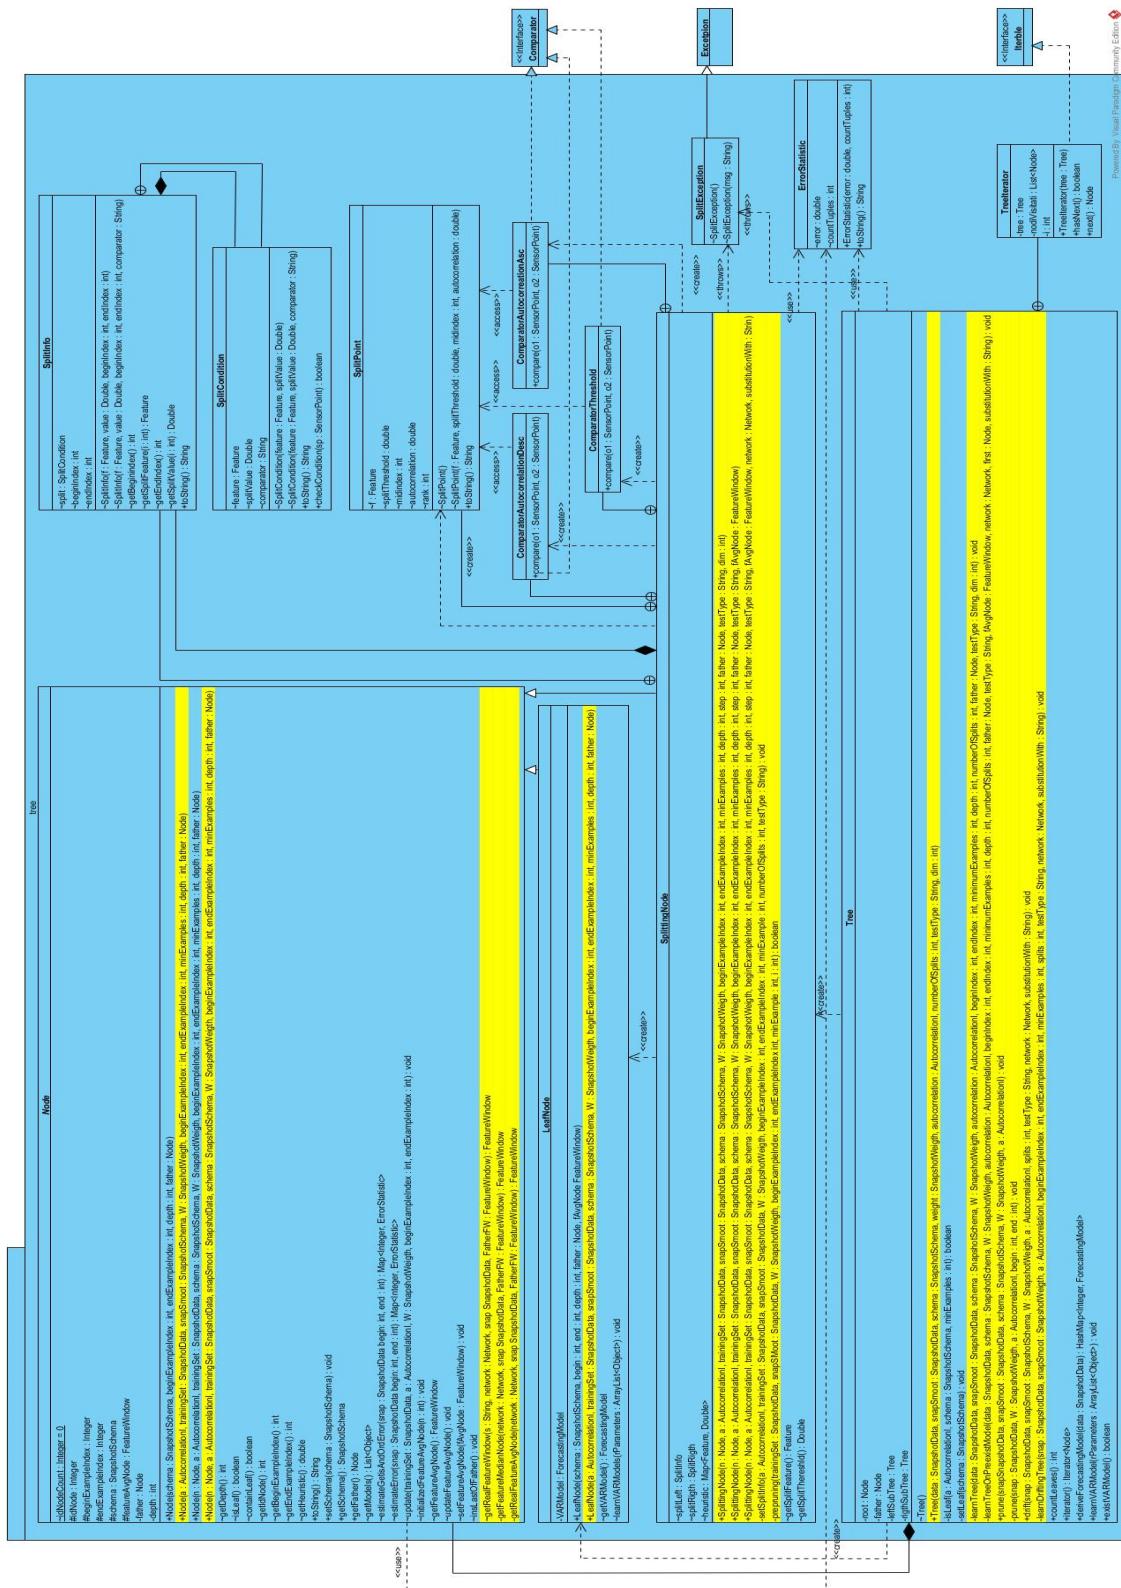


Figura 3.10: Tree Class Diagram VARForecaster 2.2

Quelle presentate in Fig. 3.2.1 sono le modifiche al package *Tree*.

Dal momento che l'albero è costruito sulla base dei valori a cui è stato applicato lo smoothing esponenziale, si è resa necessaria la modifica della maggior parte delle firme dei metodi che si preoccupano della creazione dei vari nodi e dei metodi principali per la creazione del *CT*.

Diagrammi di sequenza

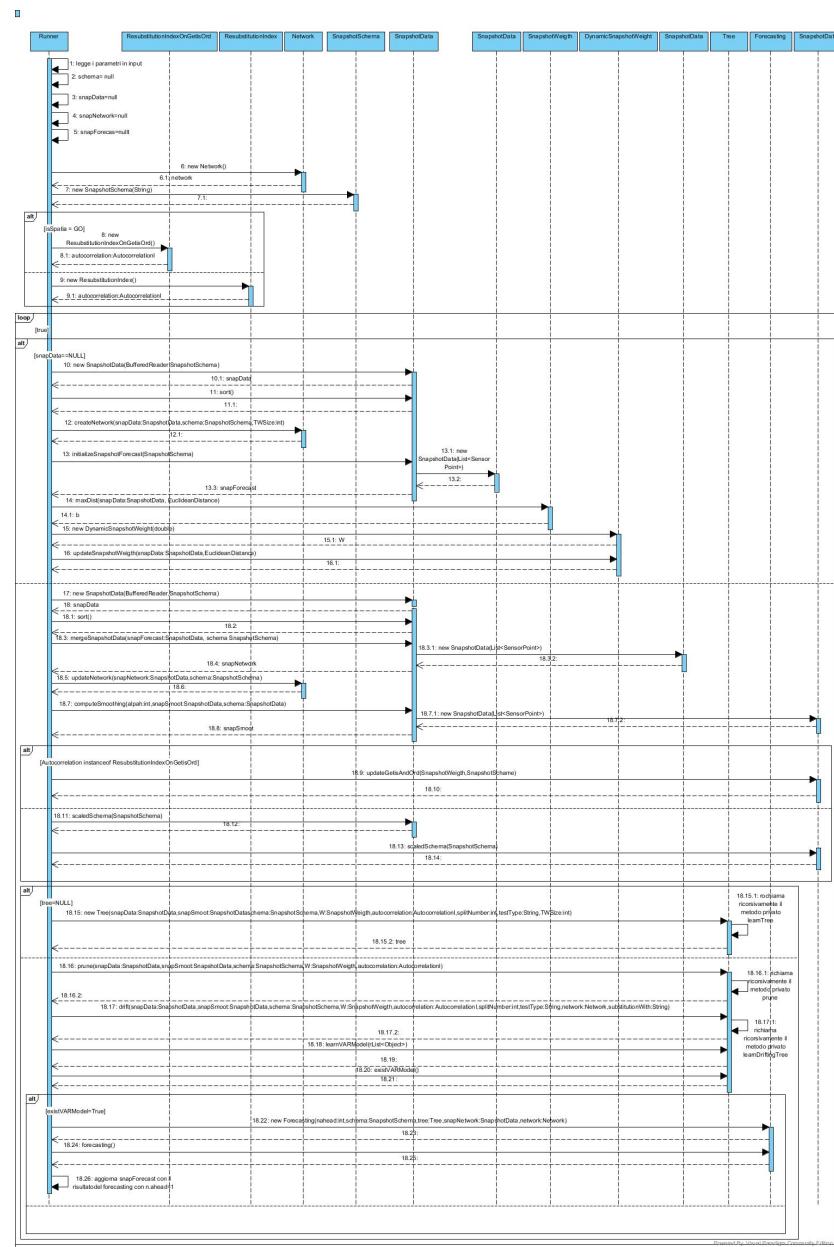


Figura 3.11: Run VARForecaster 2.2

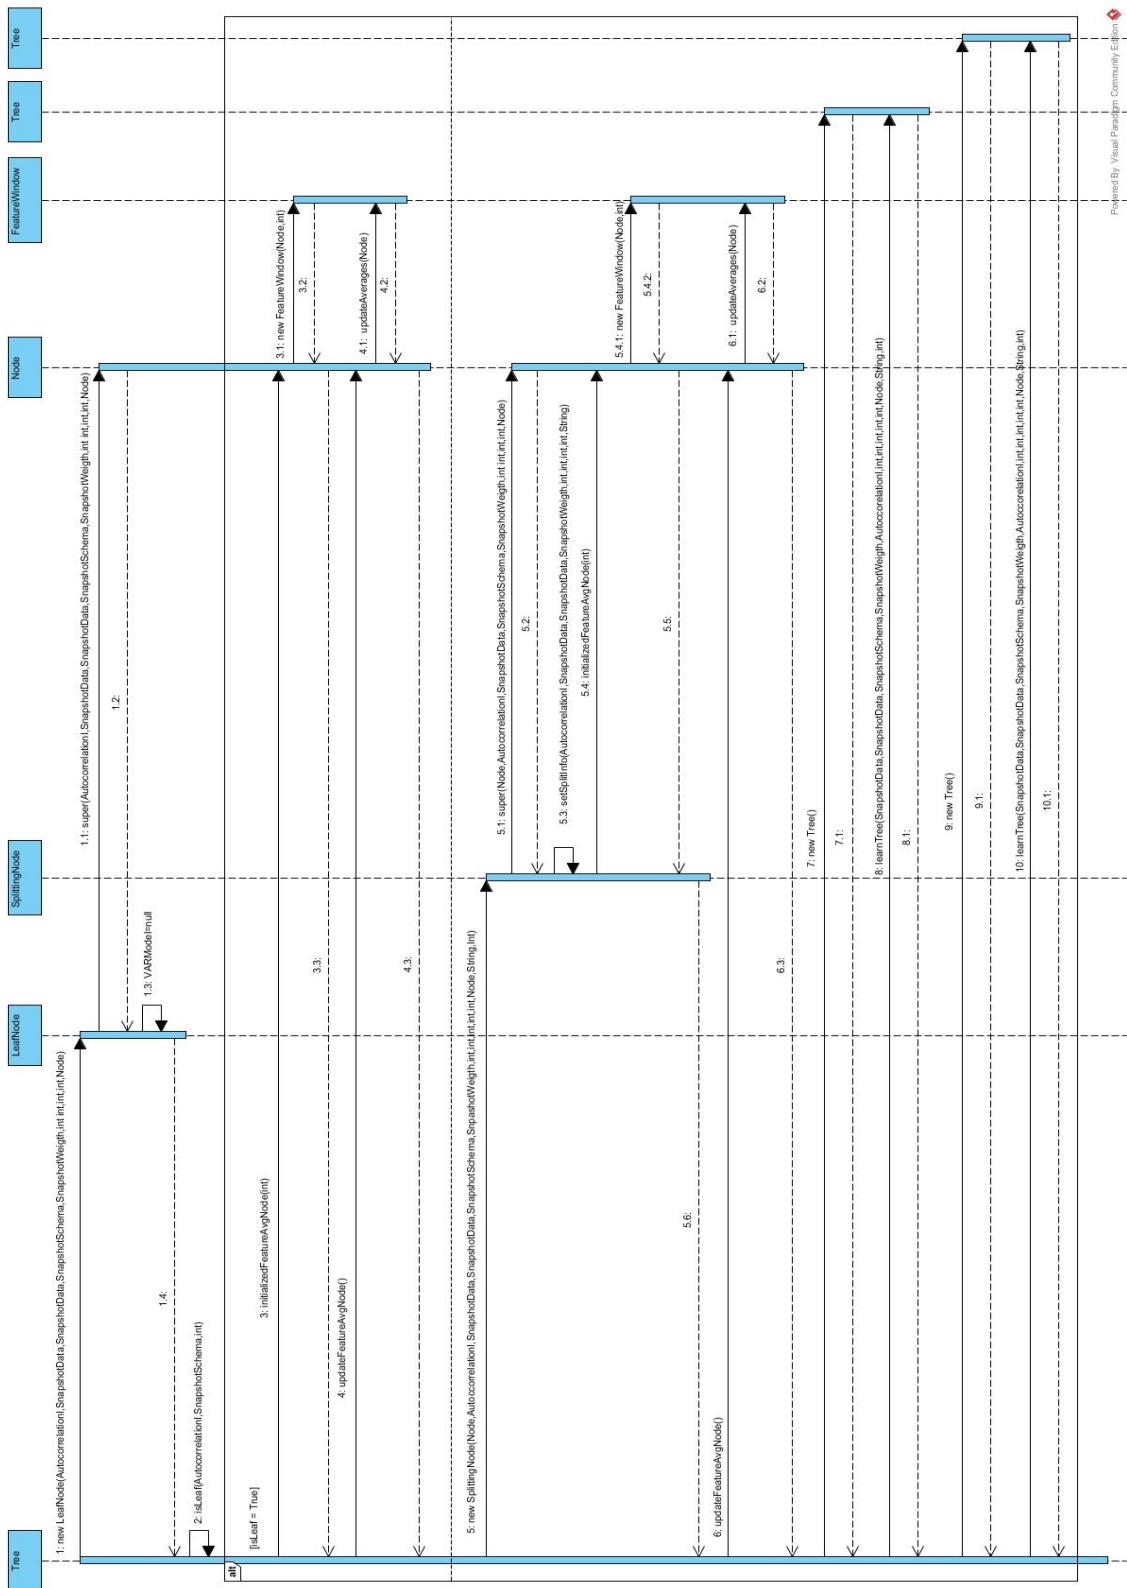


Figura 3.12: Apprendimento CT VARForecaster 2.2

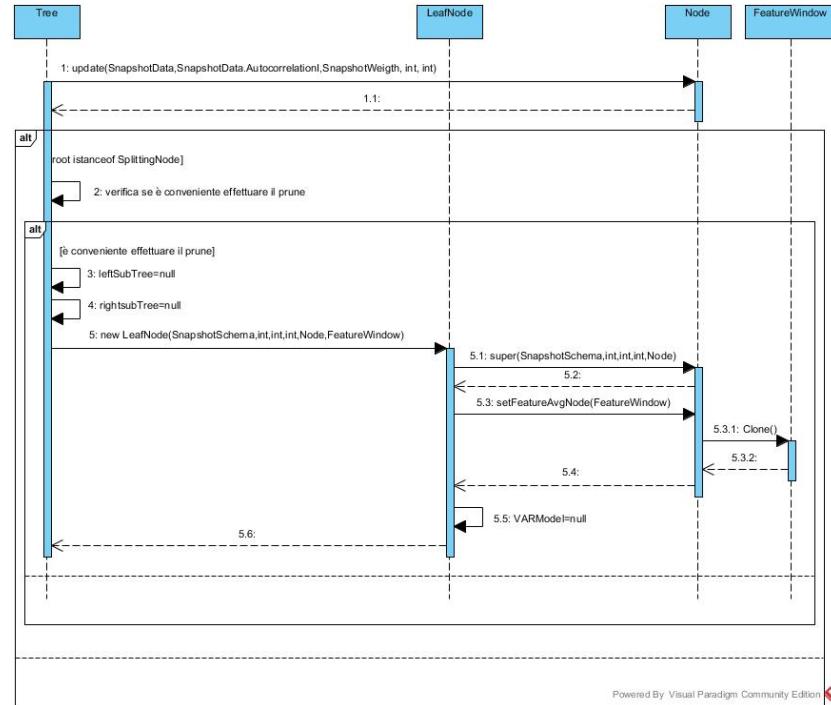


Figura 3.13: Potatura VARForecaster 2.2

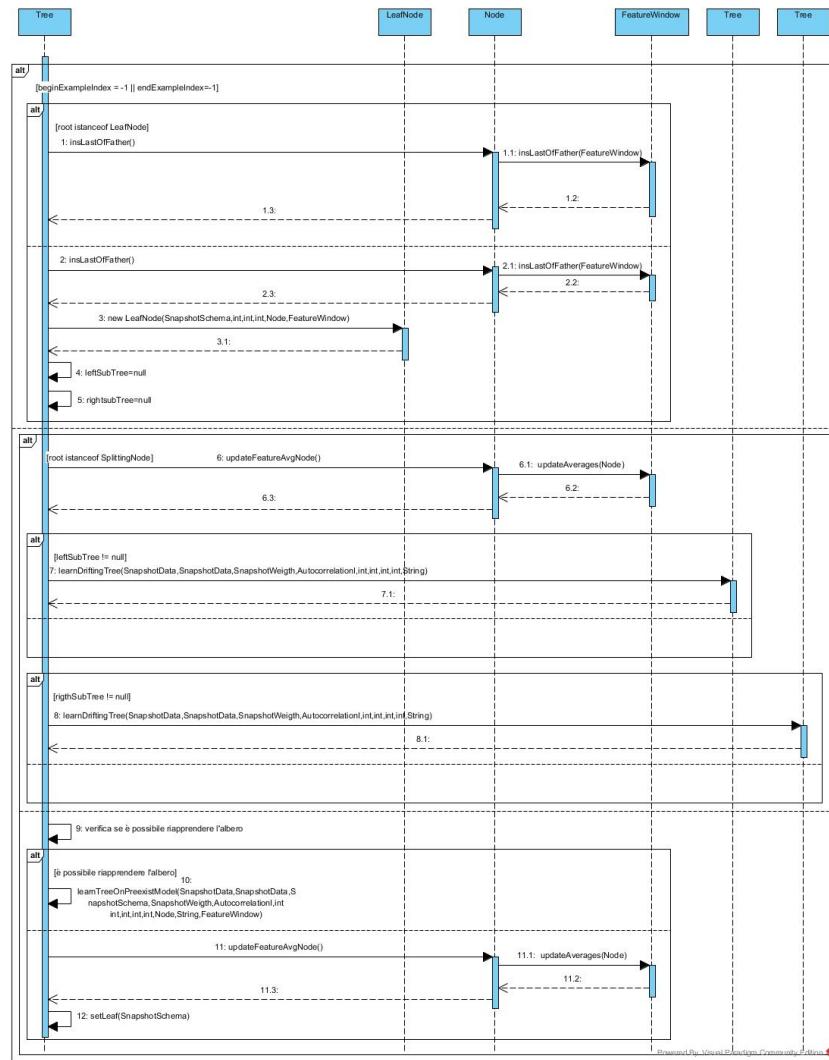


Figura 3.14: Riapprendimento CT 1/2 VARForecaster 2.2

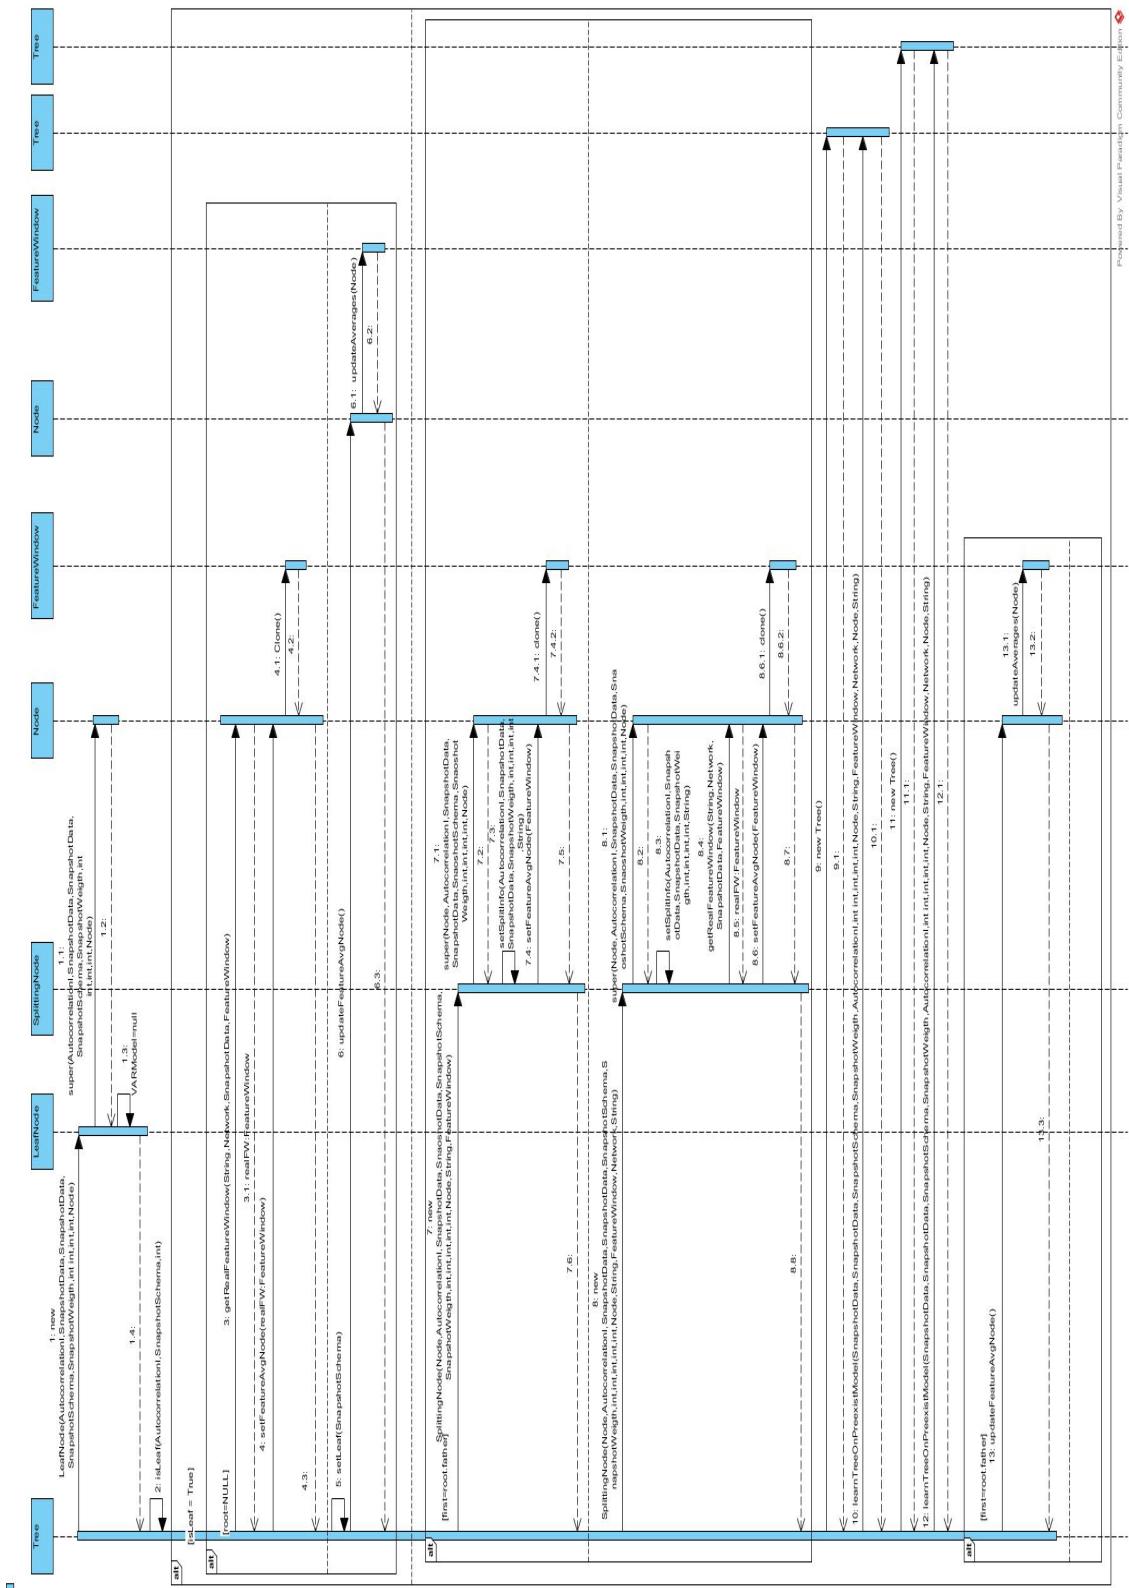


Figura 3.15: Riapprendimento CT 2/2 VARForecaster 2.2

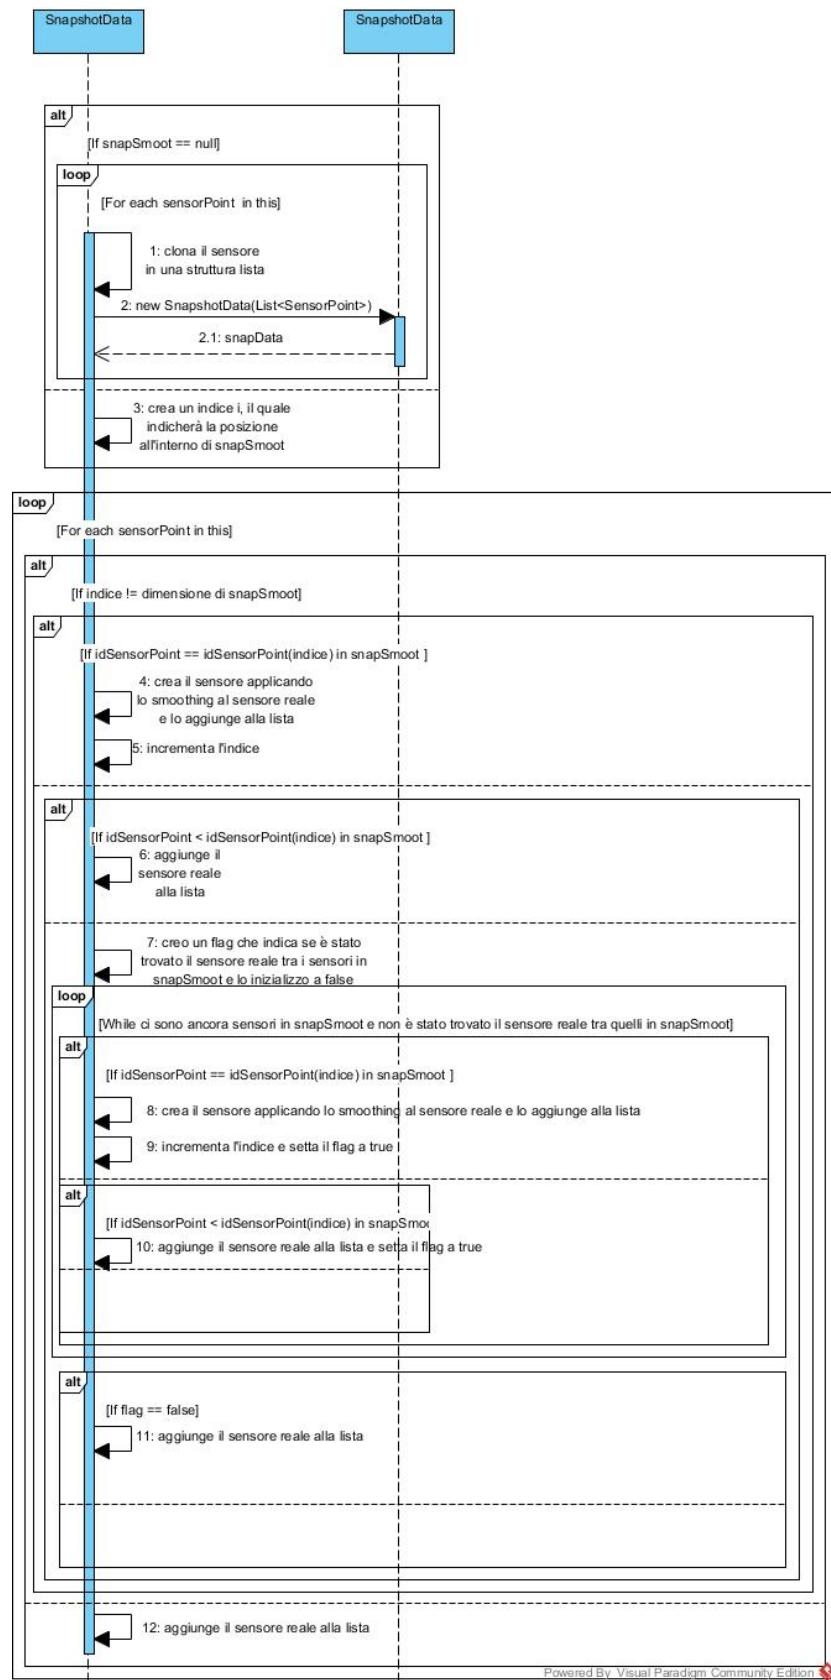


Figura 3.16: Algoritmo per lo smoothing esponenziale

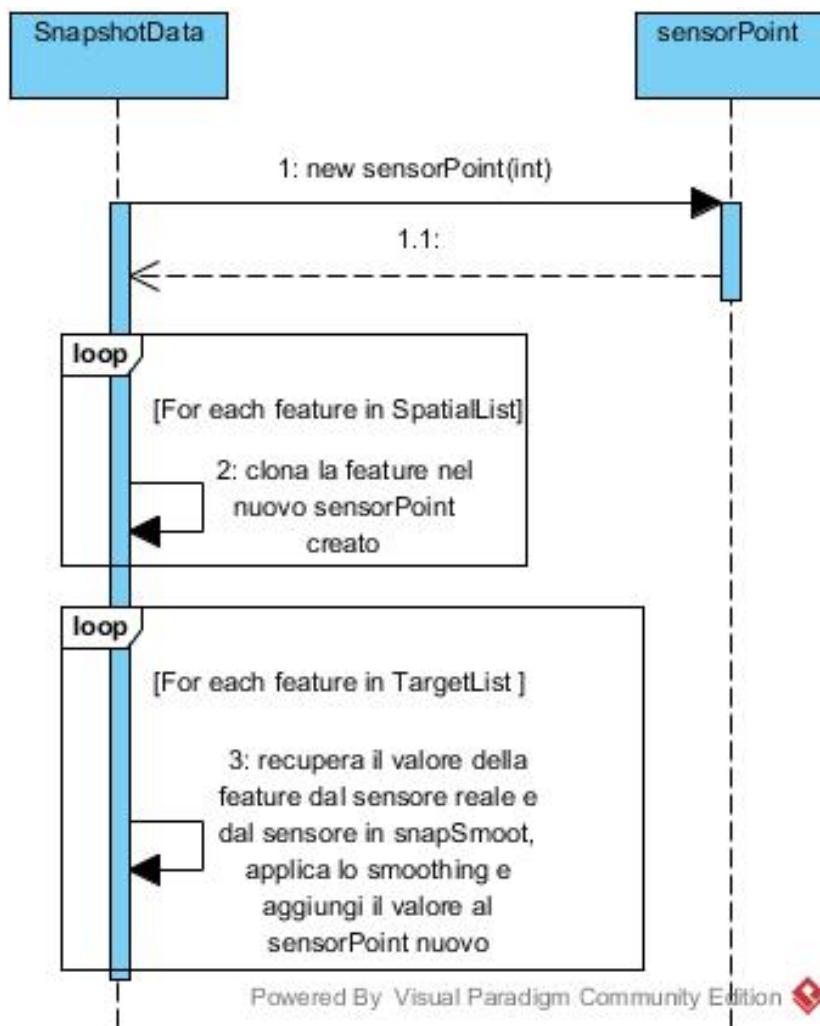


Figura 3.17: Algoritmo per lo smoothing del singolo sensore

Capitolo 4

Analisi sperimentale

In questa sezione sono descritti i risultati della valutazione empirica, condotta considerando due dataset di rilevazioni storiche. Questa valutazione è stata effettuata al fine di calcolare confrontare le prestazioni di VARForecaster 2.1 e VARForecaster 2.2, in termini di accuratezza della previsione ed efficienza della computazione.

4.1 Obiettivi e metriche

Si intende valutare:

- precisione nelle previsioni;
- tempo di computazione necessario al completamento delle singole operazioni di costruzione(/riapprendimento) del *CT*, apprendimento del modello VAR e previsione.

Tali obiettivi sono stati valutati mettendo a confronto i risultati ottenuti dalle sperimentazioni di [1] con quelle ottenute analizzando le versioni VARForecaster 2.1 e VARForecaster 2.2.

Al fine di valutare il raggiungimento di questi obiettivi sono state utilizzate le seguenti metriche:

- (1) Media dello RMSE per ogni istante di tempo predetto;
- (2) Deviazione standard dello RMSE per ogni istante di tempo predetto;
- (3) Numero di cluster generati dall'algoritmo di clustering in ogni istante di tempo;

- (4) Tempo medio di computazione per la costruzione(/riapprendimento) del CT ;
- (5) Tempo medio di computazione per l'apprendimento del modello VAR;
- (6) Tempo medio di computazione per la fase di previsione.

L'espressione matematica per il calcolo dello RMSE delle previsioni è:

$$RMSE_t = \sqrt{\frac{\sum_{i=1}^n (\hat{y}_{(t,i)} - y_{(t,i)})^2}{n}}$$

dove t indica l'istante temporale in analisi e i indica l'i-esimo sensore ed n il numero totale di sensori.

Per la versione VARForecaster 2.1, non è stata utilizzata la metrica (3) in quanto tale versione non implica alcuna variazione nell'algoritmo di clustering.

4.2 Dati

Per le rilevazioni sono state utilizzate due reti di sensori:

- *EcoTexas*;
- *UnitedStatesPacific*.

EcoTexas è un dataset comprendente 26 sensori situati in Texas e i suoi attributi misurano: *Temperatura, velocità del vento, livello di ozono, livello di radiazioni solari*.

UnitedStatesPacific invece è un dataset al cui interno ci sono le misurazioni di 190 sensori posizionati negli Stati Uniti d'America e in alcune isole del Pacifico. Queste rilevazioni riguardano: *dewp, pres, temp, wind*.

In entrambi i dataset sono effettuate rilevazioni a distanza di un ora una dall'altra e per ognuno di essi saranno considerati i primi 100 istanti temporali.

4.3 Risultati e discussione

Sono di seguito elencati i risultati ottenuti in ottemperanza delle metriche scelte divisi in due sezioni, una per ogni dataset.

Inizialmente si confrontano i risultati ottenuti utilizzando le diverse configurazioni del software realizzato. Tali risultati sono confrontati con i quelli riportati in [1].

4.3.1 Ecotexas

Per il dataset Ecotexas sono stati utilizzati i seguenti parametri:

Dimensione finestra temporale	48
bperc.	0.1f
lag.max	24
Season	NULL
Exogen	NULL
ic	ALL
type	ALL
n.ahead	6

Tabella 4.1: Parametri per Ecotexas

dove "ALL" indica che è il sistema a trovare il parametro ottimale tra quelli ammissibili per la costruzione del modello VAR.

VARForecaster 2.1

Nella versione VARForecaster 2.1 le configurazioni possibili sono:

- (1) Calcolo dell'aggregato con utilizzo della media e indice di autocorrelazione spaziale Getis and Ord;
- (2) Calcolo dell'aggregato con utilizzo della mediana e indice di autocorrelazione spaziale Getis and Ord;
- (3) Calcolo dell'aggregato con utilizzo della media e varianza;
- (4) Calcolo dell'aggregato con utilizzo della mediana e varianza;

Per le metriche (1) e (2) (definite in Sezione 4.1) i risultati sono stati analizzati attributo per attributo e sono di seguito riportati.

Metrica 1: Media dello RMSE per ogni istante di tempo pre-detto

Attributo: Temperatura

	Media+GO	Mediana+GO	Media+Var	Mediana+Var
ahead 1	7,727963	7,948522	6,872338	8,979301
ahead 2	12,11254	11,49216	10,90933	10,90759
ahead 3	14,88549	13,85234	14,0107	13,63754
ahead 4	16,50204	14,87442	17,18551	15,50205
ahead 5	17,89753	15,52931	19,55695	17,20633
ahead 6	19,80448	16,64003	22,31437	18,81037

Tabella 4.2: Ecotexas VARForecaster 2.1 - Metrica (1), temperatura

Attributo: Velocità del vento

	Media+GO	Mediana+GO	Media+Var	Mediana+Var
ahead 1	2,770909	3,04784	2,72581	3,282296
ahead 2	4,169788	4,121688	3,947481	4,3164
ahead 3	5,187269	5,153598	4,636164	6,193093
ahead 4	6,26087	5,828	5,452935	6,193093
ahead 5	7,165297	6,319675	6,445137	6,770449
ahead 6	7,529702	6,481377	6,870087	7,400426

Tabella 4.3: Ecotexas VARForecaster 2.1 - Metrica (1), velocità del vento

Attributo: Ozono

	Media+GO	Mediana+GO	Media+Var	Mediana+Var
ahead 1	2,238133	2,427748	2,40774	2,583126
ahead 2	4,243109	4,385498	4,698071	4,492118
ahead 3	6,156216	6,199482	7,354431	6,490697
ahead 4	7,911378	7,752754	9,885487	8,301946
ahead 5	9,570941	8,988501	12,61612	10,03399
ahead 6	10,9282	9,906673	15,1254	11,47112

Tabella 4.4: Ecotexas VARForecaster 2.1 - Metrica (1), Ozono

Attributo: Radiazioni solari

	Media+GO	Mediana+GO	Media+Var	Mediana+Var
ahead 1	0,286194	0,250383	0,273884	0,31357
ahead 2	0,526701	0,461626	0,514967	0,527801
ahead 3	0,70248	0,641239	0,741909	0,690238
ahead 4	0,827084	0,744024	0,901843	0,795779
ahead 5	0,910664	0,790287	1,098361	0,900938
ahead 6	0,987533	0,808239	1,274128	0,97393

Tabella 4.5: Ecotexas VARForecaster 2.1 - Metrica (1), radiazioni solari

Metrica 2: Deviazione standard dello RMSE per ogni istante di tempo predetto

Attributo: Temperatura

	Media+GO	Mediana+GO	Media+Var	Mediana+Var
ahead 1	3,263198	2,529772	1,565324	4,585758
ahead 2	5,858031	3,811666	2,713763	2,085918
ahead 3	7,294031	4,746114	3,654802	3,949568
ahead 4	7,876128	5,066172	4,780009	5,32213
ahead 5	9,245492	6,327062	5,223495	6,933482
ahead 6	12,30531	7,596333	10,00537	8,577916

Tabella 4.6: Ecotexas VARForecaster 2.1 - Metrica (2), temperatura

Attributo: Velocità del vento

	Media+GO	Mediana+GO	Media+Var	Mediana+Var
ahead 1	0,751254	1,051378	0,661512	1,301704
ahead 2	1,227334	1,340969	1,030355	1,183548
ahead 3	1,630038	1,661901	1,043562	1,718451
ahead 4	2,449047	1,859191	1,442913	2,132098
ahead 5	3,067828	2,258222	2,172139	2,589733
ahead 6	3,766907	2,412196	2,687215	2,957897

Tabella 4.7: Ecotexas VARForecaster 2.1 - Metrica (2), Velocità del vento

Attributo: Ozono

	Media+GO	Mediana+GO	Media+Var	Mediana+Var
ahead 1	1,327452	0,704212	1,126675	1,251867
ahead 2	2,076686	1,055576	1,566866	1,709158
ahead 3	2,125811	1,487432	3,604166	2,261353
ahead 4	2,317416	2,047489	5,101176	2,745594
ahead 5	2,75666	2,833415	11,58965	3,986299
ahead 6	3,687823	3,706639	19,3885	5,149975

Tabella 4.8: Ecotexas VARForecaster 2.1 - Metrica (2), Ozono

Attributo: Radiazioni solari

	Media+GO	Mediana+GO	Media+Var	Mediana+Var
ahead 1	0,090172	0,097816	0,073123	0,101597
ahead 2	0,175438	0,198805	0,129505	0,162625
ahead 3	0,24637	0,293015	0,286108	0,210677
ahead 4	0,307636	0,341056	0,394155	0,266356
ahead 5	0,346291	0,342398	0,950618	0,357383
ahead 6	0,433747	0,097816	1,41983	0,396003

Tabella 4.9: Ecotexas VARForecaster 2.1 - Metrica (2), radiazioni solari

Per entrambe le metriche sono riportati in **grassetto** gli RMSE più bassi ottenuti per ogni istante temporale previsto.

Per meglio comprendere questi risultati si riportano nel seguito le tabelle, una per ogni istante di tempo di previsione (ahead), riportanti il numero di volte che una configurazione è stata scelta come migliore.

Ahead = 1

	Totale				Metrica 1				Metrica 2			
Configurazioni	1	2	3	4	1	2	3	4	1	2	3	4
Occorrenze	1	2	5	0	1	1	2	0	0	1	3	0

Tabella 4.10: Ecotexas VARForecaster 2.1 - Riassunto Ahead 1

Ahead = 2

	Totale				Metrica 1				Metrica 2			
Configurazioni	1	2	3	4	1	2	3	4	1	2	3	4
Occorrenze	1	2	4	1	1	1	2	0	0	1	2	1

Tabella 4.11: Ecotexas VARForecaster 2.1 - Riassunto Ahead 2

Ahead = 3

	Totale				Metrica 1				Metrica 2			
Configurazioni	1	2	3	4	1	2	3	4	1	2	3	4
Occorrenze	1	2	3	2	1	1	1	1	0	1	2	1

Tabella 4.12: Ecotexas VARForecaster 2.1 - Riassunto Ahead 3

Ahead = 4

	Totale				Metrica 1				Metrica 2			
Configurazioni	1	2	3	4	1	2	3	4	1	2	3	4
Occorrenze	0	4	3	1	0	3	1	0	0	1	2	1

Tabella 4.13: Ecotexas VARForecaster 2.1 - Riassunto Ahead 4

Ahead = 5

	Totale				Metrica 1				Metrica 2			
Configurazioni	1	2	3	4	1	2	3	4	1	2	3	4
Occorrenze	1	5	2	0	1	4	0	0	1	1	2	0

Tabella 4.14: Ecotexas VARForecaster 2.1 - Riassunto Ahead 5

Ahead = 6

	Totale				Metrica 1				Metrica 2			
Configurazioni	1	2	3	4	1	2	3	4	1	2	3	4
Occorrenze	1	7	0	0	0	4	0	0	1	3	0	0

Tabella 4.15: Ecotexas VARForecaster 2.1 - Riassunto Ahead 6

Si noti che, in base alle metriche (1) e (2), utilizzate per valutare l'accuratezza di VARForecaster 2.1, la configurazione migliore per le prime 3 previsioni è la 3, nonché il calcolo dell'aggregato con uso di media e la varianza, mentre per le successive è di gran lunga migliore la configurazione 2, ovvero il calcolo dell'aggregato con l'utilizzo della mediana e indice di autocorrelazione spaziale Getis and Ord.

Metrica 4: Tempo medio di computazione per la costruzione(/riapprendimento) del CT.

Media+GO	Mediana+GO	Media+Var	Mediana+Var
4,43	3,67	4,20	3,36

Tabella 4.16: Ecotexas VARForecaster 2.1 - Metrica (4)

Metrica 5: Tempo medio di computazione per l'apprendimento del modello VAR.

Media+GO	Mediana+GO	Media+Var	Mediana+Var
6782	6782	7314	7299

Tabella 4.17: Ecotexas VARForecaster 2.1 - Metrica (5)

Metrica 6: Tempo medio di computazione per la fase di previsione.

Media+GO	Mediana+GO	Media+Var	Mediana+Var
1,59	1,30	1,60	1,88

Tabella 4.18: Ecotexas VARForecaster 2.1 - Metrica (6)

VARForecaster 2.2

Per la versione VARForecaster 2.2 le configurazioni possibili sono:

- (1) Apprendimento dell'albero con algoritmo di smoothing utilizzando un $\alpha = 0.4$, calcolo dell'aggregato con la mediana e indice di autocorrelazione spaziale Getis and Ord.
- (2) Apprendimento dell'albero con algoritmo di smoothing utilizzando un $\alpha = 0.4$, calcolo dell'aggregato con la media e indice di autocorrelazione spaziale Getis and Ord.
- (3) Apprendimento dell'albero con algoritmo di smoothing utilizzando un $\alpha = 0.4$, calcolo dell'aggregato con la mediana e varianza.
- (4) Apprendimento dell'albero con algoritmo di smoothing utilizzando un $\alpha = 0.4$, calcolo dell'aggregato con la media e varianza.
- (5) Apprendimento dell'albero con algoritmo di smoothing utilizzando un $\alpha = 0.5$, calcolo dell'aggregato con la mediana e indice di autocorrelazione spaziale Getis and Ord.
- (6) Apprendimento dell'albero con algoritmo di smoothing utilizzando un $\alpha = 0.5$, calcolo dell'aggregato con la media e indice di autocorrelazione spaziale Getis and Ord.
- (7) Apprendimento dell'albero con algoritmo di smoothing utilizzando un $\alpha = 0.5$, calcolo dell'aggregato con la mediana e varianza.
- (8) Apprendimento dell'albero con algoritmo di smoothing utilizzando un $\alpha = 0.5$, calcolo dell'aggregato con la media e varianza.
- (9) Apprendimento dell'albero con algoritmo di smoothing utilizzando un $\alpha = 0.6$, calcolo dell'aggregato con la mediana e indice di autocorrelazione spaziale Getis and Ord.
- (10) Apprendimento dell'albero con algoritmo di smoothing utilizzando un $\alpha = 0.6$, calcolo dell'aggregato con la media e indice di autocorrelazione spaziale Getis and Ord.
- (11) Apprendimento dell'albero con algoritmo di smoothing utilizzando un $\alpha = 0.6$, calcolo dell'aggregato con la mediana e varianza.
- (12) Apprendimento dell'albero con algoritmo di smoothing utilizzando un $\alpha = 0.6$, calcolo dell'aggregato con la media e varianza.

Per le metriche (1) e (2) i risultati sono stati analizzati attributo per attributo. Le tabelle sono organizzate in base ai livelli α . Ogni tabella, inoltre, include le seguenti quattro colonne:

- (1) Calcolo dell'aggregato con utilizzo della mediana e indice di autocorrelazione spaziale Getis and Ord;
- (2) Calcolo dell'aggregato con utilizzo della media e indice di autocorrelazione spaziale Getis and Ord;
- (3) Calcolo dell'aggregato con utilizzo della mediana e varianza;
- (4) Calcolo dell'aggregato con utilizzo della media e varianza;

Sono di seguito riportati i risultati.

Metrica 1: Media dello RMSE per ogni istante di tempo predetto

Attributo: Temperatura

	Smoothing $\alpha = 0.4$			
	1	2	3	4
ahead 1	9,02206	8,483192	9,617287	9,230679
ahead 2	11,74263	12,83586	12,1994	13,47861
ahead 3	13,42569	14,90105	13,57288	16,27871
ahead 4	14,68293	17,28901	15,09509	19,3797
ahead 5	15,70545	19,53582	16,34737	22,68712
ahead 6	16,76946	20,35719	17,25566	26,72587

Tabella 4.19: Ecotexas VARForecaster 2.2 - Metrica (1), temperatura, $\alpha = 0.4$

	Smoothing $\alpha = 0.5$			
	1	2	3	4
ahead 1	9,03935	7,755912	9,272419	8,858649
ahead 2	12,0037	12,59115	13,35981	14,01498
ahead 3	13,53915	15,10238	15,57883	16,76933
ahead 4	14,42594	16,811218	17,08853	18,59352
ahead 5	15,03058	17,7564	18,48882	20,60122
ahead 6	15,5948	18,30791	18,95518	21,3973

Tabella 4.20: Ecotexas VARForecaster 2.2 - Metrica (1), temperatura, $\alpha = 0.5$

	Smoothing $\alpha = 0.6$			
	1	2	3	4
ahead 1	9,051656	7,845343	8,4815551	7,983976
ahead 2	12,28307	12,52572	12,01534	13,06673
ahead 3	14,20874	14,86637	14,34806	16,98019
ahead 4	15,45715	15,9518	15,92537	19,46083
ahead 5	15,73302	17,83478	17,25861	21,5627
ahead 6	15,81711	18,77403	18,09892	24,41888

Tabella 4.21: Ecotexas VARForecaster 2.2 - Metrica (1), temperatura, $\alpha = 0.6$

Attributo: Velocità del vento

	Smoothing $\alpha = 0.4$			
	1	2	3	4
ahead 1	3,01268	2,893663	3,394852	3,3447959
ahead 2	4,143725	4,007819	4,041859	4,655479
ahead 3	4,952245	4,943684	4,731441	6,191785
ahead 4	5,620227	5,758045	5,506629	9,587068
ahead 5	6,061869	6,266921	6,224269	12,80314
ahead 6	6,167213	6,426425	6,634878	22,5346

Tabella 4.22: Ecotexas VARForecaster 2.2 - Metrica (1), velocità del vento, $\alpha = 0.4$

	Smoothing $\alpha = 0.5$			
	1	2	3	4
ahead 1	2,9068	2,719515	3,514897	3,439094
ahead 2	4,247564	3,955123	4,631042	4,101132
ahead 3	5,137302	4,920545	5,501999	5,38875
ahead 4	5,90867	5,900318	6,819834	6,490254
ahead 5	6,590004	6,487704	7,331173	7,12788
ahead 6	7,022727	6,948599	7,694757	8,925594

Tabella 4.23: Ecotexas VARForecaster 2.2 - Metrica (1), velocità del vento, $\alpha = 0.5$

	Smoothing $\alpha = 0.6$			
	1	2	3	4
ahead 1	2,964297	2,690527	3,181186	2,892368
ahead 2	4,22764	3,851252	4,287462	4,237999
ahead 3	5,140163	4,794959	5,434163	5,169286
ahead 4	5,646351	5,481132	6,529889	6,104721
ahead 5	5,952523	5,89235	7,077656	7,057257
ahead 6	6,099744	6,495151	7,710398	8,019449

Tabella 4.24: Ecotexas VARForecaster 2.2 - Metrica (1), velocità del vento, $\alpha = 0.6$

Attributo:Ozono

	Smoothing $\alpha = 0.4$			
	1	2	3	4
ahead 1	2,841519	2,457334	2,727729	2,410487
ahead 2	5,139587	4,746671	4,568687	4,689119
ahead 3	7,034836	7,497044	6,303611	6,795089
ahead 4	8,55406	9,42643	8,218017	9,785377
ahead 5	10,0661	10,82114	9,935751	13,15565
ahead 6	10,91466	11,64655	11,27033	16,05161

Tabella 4.25: Ecotexas VARForecaster 2.2 - Metrica (1), ozono, $\alpha = 0.4$

	Smoothing $\alpha = 0.5$			
	1	2	3	4
ahead 1	2,537652	2,550679	2,538546	2,617726
ahead 2	4,466039	4,762223	4,83846	5,324233
ahead 3	6,182669	7,020338	6,818731	7,833455
ahead 4	7,838081	8,945195	8,463908	10,06753
ahead 5	9,002074	10,54354	10,01062	12,69932
ahead 6	9,959309	11,5342	11,32749	14,90097

Tabella 4.26: Ecotexas VARForecaster 2.2 - Metrica (1), ozono, $\alpha = 0.5$

	Smoothing $\alpha = 0.6$			
	1	2	3	4
ahead 1	3,046583	2,579972	2,631889	2,420311
ahead 2	5,207337	4,677054	4,727009	4,861815
ahead 3	6,888374	6,741107	6,757137	7,211403
ahead 4	8,3138	8,434322	8,595274	9,574995
ahead 5	9,769092	10,40015	10,38367	11,78915
ahead 6	10,92063	11,37165	11,7609	13,75181

Tabella 4.27: Ecotexas VARForecaster 2.2 - Metrica (1), ozono, $\alpha = 0.6$

Attributo: Radiazioni solari

	Smoothing $\alpha = 0.4$			
	1	2	3	4
ahead 1	0,31253	0,314025	0,275783	0,279823
ahead 2	0,594081	0,585408	0,499732	0,539694
ahead 3	0,786514	0,758351	0,665763	0,778742
ahead 4	0,908335	0,863143	0,805663	1,00445
ahead 5	0,965063	0,91723	0,924908	1,296228
ahead 6	0,940639	0,92559	1,012066	1,47558

Tabella 4.28: Ecotexas VARForecaster 2.2 - Metrica (1), radiazioni solari, $\alpha = 0.4$

	Smoothing $\alpha = 0.5$			
	1	2	3	4
ahead 1	0,274211	0,289188	0,305464	0,301227
ahead 2	0,502168	0,539101	0,535453	0,5721111
ahead 3	0,661818	0,737995	0,733254	0,763821
ahead 4	0,745413	0,864035	0,870073	0,87816
ahead 5	0,788487	0,930862	0,921148	0,976739
ahead 6	0,833666	0,938316	0,951969	1,090629

Tabella 4.29: Ecotexas VARForecaster 2.2 - Metrica (1), radiazioni solari, $\alpha = 0.5$

	Smoothing $\alpha = 0.6$			
	1	2	3	4
ahead 1	0,277618	0,278853	0,325965	0,31052
ahead 2	0,488269	0,531682	0,574133	0,505346
ahead 3	0,65946	0,692652	0,713279	0,76566
ahead 4	0,775124	0,807942	0,858773	0,910662
ahead 5	0,839451	0,880856	0,952431	1,015012
ahead 6	0,877025	0,948436	1,046463	1,085741

Tabella 4.30: Ecotexas VARForecaster 2.2 - Metrica (1), radiazioni solari, $\alpha = 0.6$

Metrica 2: Deviazione standard dello RMSE per ogni istante di tempo predetto

Attributo: Temperatura

	Smoothing $\alpha = 0.4$			
	1	2	3	4
ahead 1	4,077296	4,044447	3,928355	4,569457
ahead 2	4,846355	5,826083	4,009214	4,81262
ahead 3	4,554923	5,293084	3,6910875	5,789415
ahead 4	5,106816	6,216603	4,689197	10,0349
ahead 5	5,273898	8,19382	5,436982	19,68997
ahead 6	6,020469	8,615091	6,397193	37,85011

Tabella 4.31: Ecotexas VARForecaster 2.2 - Metrica (2), temperatura, $\alpha = 0.4$

	Smoothing $\alpha = 0.5$			
	1	2	3	4
ahead 1	4,118029	2,800435	3,657462	3,843097
ahead 2	4,752247	4,730657	5,668529	6,39848
ahead 3	4,448051	5,868524	6,133957	6,182983
ahead 4	4,567702	6,125561	6,595879	6,671255
ahead 5	4,502047	5,552464	7,468099	10,02845
ahead 6	5,005777	5,358578	6,633261	13,63706

Tabella 4.32: Ecotexas VARForecaster 2.2 - Metrica (2), temperatura, $\alpha = 0.5$

	Smoothing $\alpha = 0.6$			
	1	2	3	4
ahead 1	4,030612	2,968118	3,092329	2,546804
ahead 2	5,123302	5,181413	3,756482	5,326826
ahead 3	5,978491	6,039783	4,17225	7,160659
ahead 4	5,707108	5,14015	4,903478	8,812901
ahead 5	5,067739	8,240017	5,937769	12,76287
ahead 6	5,49606	10,09353	6,219491	20,53561

Tabella 4.33: Ecotexas VARForecaster 2.2 - Metrica (2), temperatura, $\alpha = 0.6$

Attributo: Velocità del vento

	Smoothing $\alpha = 0.4$			
	1	2	3	4
ahead 1	1,062656	1,466069	1,388213	2,025632
ahead 2	1,478485	1,753358	1,520125	2,817031
ahead 3	1,747566	2,149486	1,947751	5,33027
ahead 4	2,098005	2,581738	2,423174	21,68157
ahead 5	2,314909	2,609462	2,518636	37,01619
ahead 6	2,425913	2,62624	2,615881	94,20118

Tabella 4.34: Ecotexas VARForecaster 2.2 - Metrica (2), velocità del vento, $\alpha = 0.4$

	Smoothing $\alpha = 0.5$			
	1	2	3	4
ahead 1	0,95298	0,994701	1,612795	1,934412
ahead 2	1,267171	1,362436	1,756117	1,498458
ahead 3	1,666224	1,814355	1,922674	2,293867
ahead 4	1,986398	2,311356	5,153206	3,930013
ahead 5	2,352991	2,280816	5,109815	3,347574
ahead 6	2,674071	2,266965	4,364921	7,485989

Tabella 4.35: Ecotexas VARForecaster 2.2 - Metrica (2), velocità del vento, $\alpha = 0.5$

	Smoothing $\alpha = 0.6$			
	1	2	3	4
ahead 1	0,89304	0,821859	1,147468	0,690529
ahead 2	1,544149	1,230087	1,712841	1,27699
ahead 3	1,758137	1,596534	2,036865	1,657636
ahead 4	1,788618	1,64779	2,411233	2,07283
ahead 5	1,853517	1,777519	2,705882	2,742409
ahead 6	1,848793	2,101822	2,893398	3,76378

Tabella 4.36: Ecotexas VARForecaster 2.2 - Metrica (2), velocità del vento, $\alpha = 0.6$

Attributo: Ozono

	Smoothing $\alpha = 0.4$			
	1	2	3	4
ahead 1	1,196652	1,404284	1,240929	1,146816
ahead 2	1,93283	2,169879	1,659448	2,070493
ahead 3	2,458792	3,962941	2,499137	2,534311
ahead 4	3,130589	4,831901	3,525059	6,540761
ahead 5	3,898874	5,229763	4,673315	15,61377
ahead 6	4,334237	5,577434	5,53449	22,54267

Tabella 4.37: Ecotexas VARForecaster 2.2 - Metrica (2), ozono, $\alpha = 0.4$

	Smoothing $\alpha = 0.5$			
	1	2	3	4
ahead 1	0,862032	1,593082	1,062665	1,934412
ahead 2	1,508812	2,276043	2,030614	3,182473
ahead 3	1,964188	2,804795	2,751584	4,677468
ahead 4	2,353101	3,58757	2,984804	7,266531
ahead 5	2,600296	4,203195	4,725577	11,78668
ahead 6	3,086139	4,894359	6,47474	19,83458

Tabella 4.38: Ecotexas VARForecaster 2.2 - Metrica (2), ozono, $\alpha = 0.5$

	Smoothing $\alpha = 0.6$			
	1	2	3	4
ahead 1	1,429323	1,662264	0,998025	1,027359
ahead 2	1,941008	2,396329	1,419518	2,268067
ahead 3	2,36319	2,688203	2,095818	3,49877
ahead 4	2,845079	2,998173	2,925058	4,796391
ahead 5	3,733283	4,176691	4,042586	6,371259
ahead 6	4,743409	4,127881	4,778812	8,71491

Tabella 4.39: Ecotexas VARForecaster 2.2 - Metrica (2), ozono, $\alpha = 0.6$

Attributo: Radiazioni solari

	Smoothing $\alpha = 0.4$			
	1	2	3	4
ahead 1	0,16017	0,125952	0,100207	0,07316
ahead 2	0,329092	0,260089	0,145163	0,156252
ahead 3	0,409201	0,334708	0,326419	0,317658
ahead 4	0,447045	0,371047	0,307191	0,582674
ahead 5	0,4516662	0,369892	0,409954	1,551824
ahead 6	0,389007	0,385203	0,504484	2,228718

Tabella 4.40: Ecotexas VARForecaster 2.2 - Metrica (2), radiazioni solari, $\alpha = 0.4$

	Smoothing $\alpha = 0.5$			
	1	2	3	4
ahead 1	0,119538	0,097008	0,140676	0,118323
ahead 2	0,241406	0,201262	0,237315	0,244777
ahead 3	0,282696	0,295507	0,269165	0,282236
ahead 4	0,263775	0,356124	0,294081	0,305658
ahead 5	0,25328	0,367895	0,281141	0,431126
ahead 6	0,298092	0,345249	0,307075	0,735505

Tabella 4.41: Ecotexas VARForecaster 2.2 - Metrica (2), radiazioni solari, $\alpha = 0.5$

	Smoothing $\alpha = 0.6$			
	1	2	3	4
ahead 1	0,125542	0,09652	0,176585	0,16404
ahead 2	0,261685	0,169013	0,238221	0,314165
ahead 3	0,326498	0,247133	0,280978	0,37018
ahead 4	0,308833	0,302848	0,333522	0,414247
ahead 5	0,309194	0,337822	0,38233	0,510328
ahead 6	0,326832	0,376449	0,449344	0,593846

Tabella 4.42: Ecotexas VARForecaster 2.2 - Metrica (2), radiazioni solari, $\alpha = 0.6$

Come per le valutazioni sui risultati ottenuti dalle sperimentazioni di VARForecaster 2.1, per ogni istante temporale previsto, per entrambe le metriche prima riportate, sono riportati in **grassetto** i valori migliori.

È proposto adesso un report generato per cercare di organizzare i risultati ottenuti con le metriche (1) e (2).

Tabella riassuntiva - AVG			
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6
Media + GO	5	7	7
Mediana + GO	7	17	15
Media + var	1	0	1
Mediana + var	11	0	1
Tabella riassuntiva - RMSE			
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6
Media + GO	2	6	9
Mediana + GO	12	17	7
Media + var	2	0	2
Mediana + var	8	1	6

Tabella 4.43: Ecotexas VARForecaster 2.2 - Tabella riassuntiva

Per meglio comprendere i risultati sopra elencati, si è preferito, come nel caso della versione VARForecaster 2.1, rappresentarli un'istante temporale alla volta.

Ahead = 1

Tabella riassuntiva - AVG				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Mediana + GO	0	2	1	3
Media + GO	2	2	2	6
Mediana + var	1	0	0	1
Media + var	1	0	1	2
Tabella riassuntiva - RMSE				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Mediana + GO	1	2	0	3
Media + GO	0	2	1	3
Mediana + var	1	0	1	2
Media + var	2	0	2	4
Tabella riassuntiva - Complessivo				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Mediana + GO	1	4	1	6
Media + GO	2	4	3	9
Mediana + var	2	0	1	3
Media + var	3	0	3	6

Tabella 4.44: Ecotexas VARForecaster 2.2 - Riassunto Ahead 1

Ahead = 2

Tabella riassuntiva - AVG				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Mediana + GO	1	3	1	5
Media + GO	1	1	2	4
Mediana + var	2	0	1	3
Media + var	0	0	0	0
Tabella riassuntiva - RMSE				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Mediana + GO	1	2	0	3
Media + GO	0	2	2	4
Mediana + var	3	0	2	5
Media + var	0	0	0	0
Tabella riassuntiva - Complessivo				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Mediana + GO	2	5	1	8
Media + GO	1	3	7	8
Mediana + var	5	0	3	8
Media + var	0	0	0	0

Tabella 4.45: Ecotexas VARForecaster 2.2 - Riassunto Ahead 2

Ahead = 3

Tabella riassuntiva - AVG				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Mediana + GO	1	3	3	7
Media + GO	0	1	1	2
Mediana + var	3	0	0	0
Media + var	0	0	0	0
Tabella riassuntiva - RMSE				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Mediana + GO	2	3	0	5
Media + GO	0	0	2	2
Mediana + var	2	0	2	5
Media + var	0	0	0	0
Tabella riassuntiva - Complessivo				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Mediana + GO	3	6	3	12
Media + GO	0	1	3	4
Mediana + var	5	0	2	7
Media + var	0	0	0	0

Tabella 4.46: Ecotexas VARForecaster 2.2 - Riassunto Ahead 4

Ahead = 4

Tabella riassuntiva - AVG				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Mediana + GO	1	3	3	7
Media + GO	0	1	1	2
Mediana + var	3	0	0	3
Media + var	0	0	0	0
Tabella riassuntiva - RMSE				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Mediana + GO	2	4	1	7
Media + GO	0	0	2	2
Mediana + var	2	0	1	3
Media + var	0	0	0	0
Tabella riassuntiva - Complessivo				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Mediana + GO	3	7	4	14
Media + GO	0	1	3	4
Mediana + var	5	0	1	6
Media + var	0	0	0	0

Tabella 4.47: Ecotexas VARForecaster 2.2 - Riassunto Ahead 4

Ahead = 5

Tabella riassuntiva - AVG				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Mediana + GO	2	3	3	8
Media + GO	1	1	1	3
Mediana + var	1	0	0	1
Media + var	0	0	0	0
Tabella riassuntiva - RMSE				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Mediana + GO	3	3	3	9
Media + GO	1	1	1	3
Mediana + var	0	0	0	0
Media + var	0	0	0	0
Tabella riassuntiva - Complessivo				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Mediana + GO	5	6	6	17
Media + GO	2	2	2	6
Mediana + var	1	0	0	1
Media + var	0	0	0	0

Tabella 4.48: Ecotexas VARForecaster 2.2 - Riassunto Ahead 5

Ahead = 6

Tabella riassuntiva - AVG				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Mediana + GO	2	3	4	9
Media + GO	1	1	0	2
Mediana + var	1	0	0	1
Media + var	0	0	0	0
Tabella riassuntiva - RMSE				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Mediana + GO	3	3	3	9
Media + GO	1	1	1	3
Mediana + var	0	0	0	0
Media + var	0	0	0	0
Tabella riassuntiva - Complessivo				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Mediana + GO	5	6	7	18
Media + GO	2	2	1	5
Mediana + var	1	0	0	1
Media + var	0	0	0	0

Tabella 4.49: Ecotexas VARForecaster 2.2 - Riassunto Ahead 6

Le tabelle sopra riportate indicano che, con un ahead = 1 c'è una certa incertezza nella individuazione della configurazione migliore mentre per gli istanti di tempo successivi la configurazione migliore sembra essere la 2, ovvero il calcolo dell'aggregato con l'utilizzo della mediana e indice di autocorrelazione spaziale Getis and Ord.

Metrica 3: Numero di cluster generati dall'algoritmo di clustering in ogni istante di tempo.

	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6
Mediana + GO	385	387	438
Mediana + var	432	412	452

Tabella 4.50: Ecotexas VARForecaster 2.2 - Metrica (3)

Per la metrica appena utilizzata si sono considerate solo le configurazioni che differiscono nel tipo di indice di autocorrelazione spaziale utilizzato, in

quanto la funzione utilizzata per il calcolo dell'aggregato non influisce sul numero di cluster generati durante il ri-apprendimento del CT .

Metrica 4: Tempo medio di computazione per la costruzione(/riapprendimento) del *CT*.

	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6
Mediana + GO	6,06	4,53	4,86
Media + GO	5,32	4,95	5,64
Mediana + var	5,25	4,96	4,51
Media + var	4,68	5,88	3,63

Tabella 4.51: Ecotexas VARForecaster 2.2 - Metrica (4)

Metrica 5: Tempo medio di computazione per l'apprendimento del modello VAR.

	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6
Mediana + GO	6123	5946	6900
Media + GO	6068	5960	6870
Mediana + var	6878	6469	6863
Media + var	6845	6384	6877

Tabella 4.52: Ecotexas VARForecaster 2.2 - Metrica (5)

Metrica 6: Tempo medio di computazione per la fase di previsione.

	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6
Mediana + GO	1,29	1,44	1,74
Media + GO	1,30	1,6	1,43
Mediana + var	2,02	1,14	1,43
Media + var	1,14	1,88	1

Tabella 4.53: Ecotexas VARForecaster 2.2 - Metrica (6)

Analizzando i risultati ottenuti per le metriche (4), (5) e (6) si nota che la fase che comporta maggior costi computazionali in termini di tempo è la fase di apprendimento del modello VAR, ovvero la metrica (5). Considerando tale metrica come la più importante si può notare che la configurazione migliore è quella con $\alpha = 0,5$.

Confronto

Dovendo valutare il rapporto tra accuratezza e efficienza della computazione realizzato con VARForecaster si confrontano le prestazioni di VARForecaster 2.1 e VARForecaster 2.2 con quelle di VARForecaster 1.0 e VARForecaster 2.0 ([1]).

Si rende necessaria quindi un'analisi comparativa sulla base delle previsioni effettuate dai 4 sistemi, mettendo a paragone gli *RMSE* delle previsioni, istante per istante, attributo per attributo.

Le configurazioni scelte sono:

- VARForecaster 2.1: Mediana + GO;
- VARForecaster 2.2: $\alpha = 0,5$ + mediana + GO.

Nelle colonne delle seguenti tabelle sono riportate in ordine:

- (1) VARForecaster 1.0;
- (2) VARForecaster 2.0;
- (3) VARForecaster 2.1;
- (4) VARForecaster 2.2.

Metrica 1: Media dello RMSE per ogni istante di tempo predetto

Attributo: Temperatura

	1	2	3	4
ahead 1	6,349867	9,533298	7,948522	9,09935
ahead 2	10,67049	15,26119	11,49216	12,0037
ahead 3	14,77069	19,70191	13,85234	13,53915
ahead 4	18,22525	24,57004	14,87442	14,42594
ahead 5	20,90827	33,05593	15,52931	15,03058
ahead 6	23,45926	41,86216	16,64003	15,5948

Tabella 4.54: Confronto versioni Ecotexas - Metrica (1), temperatura

Attributo: Velocità del vento

	1	2	3	4
ahead 1	2,796956	3,482482	3,04784	2,9068
ahead 2	4,135592	6,938546	4,121688	4,247564
ahead 3	5,260249	13,28893	5,153598	5,137302
ahead 4	6,105931	28,04672	5,828	5,90867
ahead 5	6,619951	70,26142	6,319675	6,590004
ahead 6	7,171572	198,5273	6,481377	7,022727

Tabella 4.55: Confronto versioni Ecotexas - Metrica (1), velocità del vento

Attributo: Ozono

	1	2	3	4
ahead 1	1,505395	4,10809	2,427748	2,537652
ahead 2	2,783558	10,10761	4,385498	4,466039
ahead 3	4,15487	23,3362	6,199482	6,182669
ahead 4	5,346249	58,43988	7,752754	7,838081
ahead 5	6,469884	171,1001	8,988501	9,002074
ahead 6	7,234199	562,7042	9,906673	9,959309

Tabella 4.56: Confronto versioni Ecotexas - Metrica (1), ozono

Attributo: Radiazioni solari

	1	2	3	4
ahead 1	0,198269	0,211488	0,258383	0,274211
ahead 2	0,300611	0,347483	0,461626	0,502178
ahead 3	0,401465	0,461639	0,641239	0,661818
ahead 4	0,484554	0,565454	0,744024	0,745413
ahead 5	0,56724	0,671419	0,790287	0,788487
ahead 6	0,621341	0,786026	0,808239	0,833666

Tabella 4.57: Confronto versioni Ecotexas - Metrica (1), radiazioni solari

Metrica 2: Deviazione standard dello RMSE per ogni istante di tempo predetto

Attributo: Temperatura

	1	2	3	4
ahead 1	1,445445	3,573893	2,529772	4,118029
ahead 2	2,374922	7,539562	3,811666	4,752247
ahead 3	3,271102	13,458024	4,746114	4,448051
ahead 4	4,740449	22,039755	5,066172	4,567702
ahead 5	6,479320	38,115992	6,327062	4,502047
ahead 6	8,679025	63,271299	7,59633	5,005777

Tabella 4.58: Confronto versioni Ecotexas - Metrica (2), temperatura

Attributo: Velocità del vento

	1	2	3	4
ahead 1	0,795525	1,452338	1,051378	0,95298
ahead 2	0,861215	5,254555	1,340969	1,267171
ahead 3	1,266828	15,638930	1,661901	1,66224
ahead 4	1,703228	48,722899	1,859191	1,986398
ahead 5	1,388394	155,621286	2,258222	2,352991
ahead 6	1,700507	518,118711	2,412196	2,674071

Tabella 4.59: Confronto versioni Ecotexas - Metrica (2), velocità del vento

Attributo: Ozono

	1	2	3	4
ahead 1	0,478407	2,053972	0,704212	0,862032
ahead 2	1,003515	7,730475	1,055576	1,508812
ahead 3	1,760290	33,825650	1,487432	1,964188
ahead 4	2,628319	123,897500	2,047489	2,353101
ahead 5	3,413358	458,971607	2,833415	2,600296
ahead 6	3,881410	1741,403078	3,706639	3,086139

Tabella 4.60: Confronto versioni Ecotexas - Metrica (2), ozono

Attributo: Radiazioni solari

	1	2	3	4
ahead 1	0,068651	0,082365	0,097816	0,119538
ahead 2	0,097834	0,118442	0,198805	0,241406
ahead 3	0,142673	0,197752	0,293015	0,282696
ahead 4	0,193042	0,299747	0,341056	0,263775
ahead 5	0,276917	0,438443	0,342398	0,25328
ahead 6	0,468938	0,652807	0,097816	0,298092

Tabella 4.61: Confronto versioni Ecotexas - Metrica (2), radiazioni solari

Metrica 4: Tempo medio di computazione per la costruzione(/riapprendimento) del CT

1	2	3	4
//	2,93	3,67	4,53

Tabella 4.62: Confronto versioni Ecotexas - Metrica (4)

Metrica 5: Tempo medio di computazione per l'apprendimento del modello VAR

1	2	3	4
39405	6837	6782	5946

Tabella 4.63: Confronto versioni Ecotexas - Metrica (5)

Metrica 6: Tempo medio di computazione per la fase di previsione

1	2	3	4
1,73	1,88	1,30	1,44

Tabella 4.64: Confronto versioni Ecotexas - Metrica (6)

Viene di seguito presentato un sommario, un istante di predizione alla volta, di quelle che sono le occorrenze delle migliori configurazioni.

Ahead = 1

	Totale				Metrica 1				Metrica 2			
Configurazioni	1	2	3	4	1	2	3	4	1	2	3	4
Occorrenze	8	0	0	0	4	0	0	0	4	0	0	0

Tabella 4.65: Sommario confronto ahead 1

Ahead = 2

	Totale				Metrica 1				Metrica 2			
Configurazioni	1	2	3	4	1	2	3	4	1	2	3	4
Occorrenze	7	0	1	0	3	0	1	0	4	0	0	0

Tabella 4.66: Sommario confronto ahead 2

Ahead = 3

	Totale				Metrica 1				Metrica 2			
Configurazioni	1	2	3	4	1	2	3	4	1	2	3	4
Occorrenze	5	0	1	2	2	0	0	2	3	0	1	0

Tabella 4.67: Sommario confronto ahead 3

Ahead = 4

	Totale				Metrica 1				Metrica 2			
Configurazioni	1	2	3	4	1	2	3	4	1	2	3	4
Occorrenze	4	0	2	2	2	0	1	1	2	0	1	1

Tabella 4.68: Sommario confronto ahead 4

Ahead = 5

	Totale				Metrica 1				Metrica 2			
Configurazioni	1	2	3	4	1	2	3	4	1	2	3	4
Occorrenze	3	0	1	4	2	0	1	1	1	0	0	3

Tabella 4.69: Sommario confronto ahead 5

Ahead = 6

	Totale				Metrica 1				Metrica 2			
Configurazioni	1	2	3	4	1	2	3	4	1	2	3	4
Occorrenze	3	0	2	3	2	0	1	1	1	0	1	2

Tabella 4.70: Sommario confronto ahead 6

Vengono ora riportati dei grafici in cui è rappresentata la serie degli RMSE, per ogni istante di previsione, per ogni attributo del dataset.

Sono segnati:

- in rosso la versione VARForecaster 1.0;
- in verde la versione VARForecaster 2.0;
- in nero la versione VARForecaster 2.1;
- in turchese la versione VARForecaster 2.2.

Attributo: Temperatura

Ahead = 1

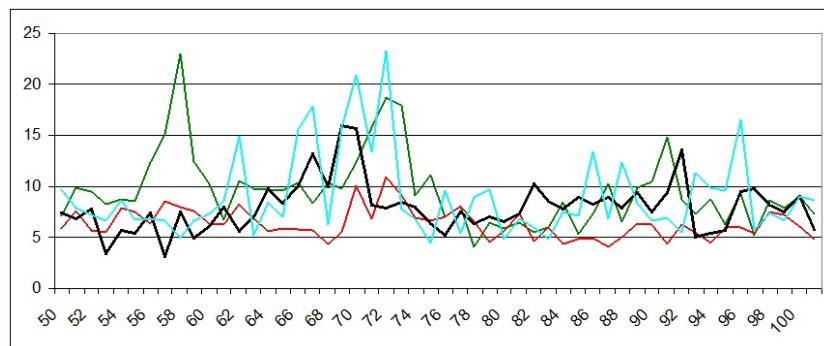


Figura 4.1: Temperatura ahead 1

Ahead = 2

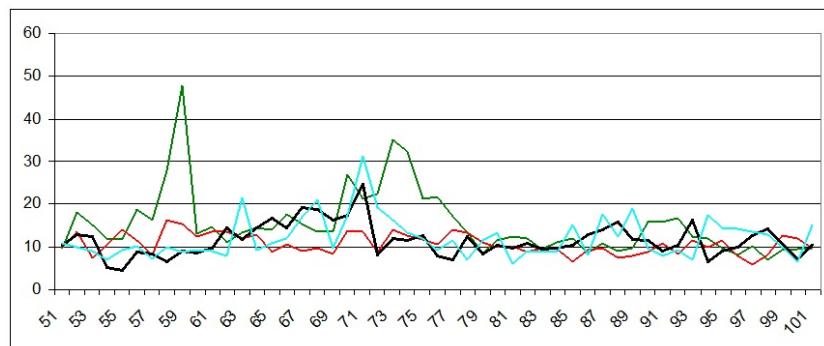


Figura 4.2: Temperatura ahead 2

Ahead = 3

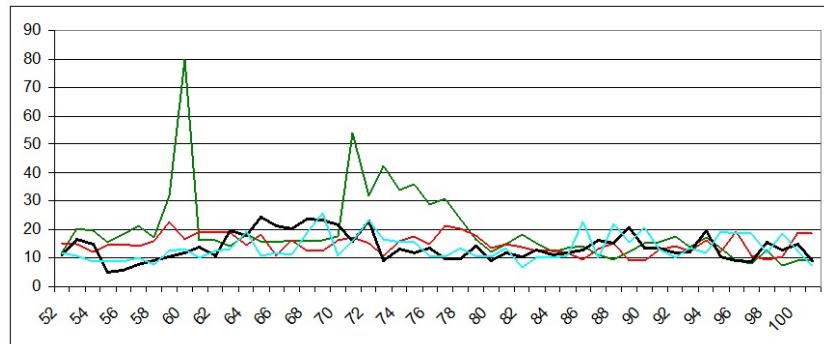


Figura 4.3: Temperatura ahead 3

Ahead = 4

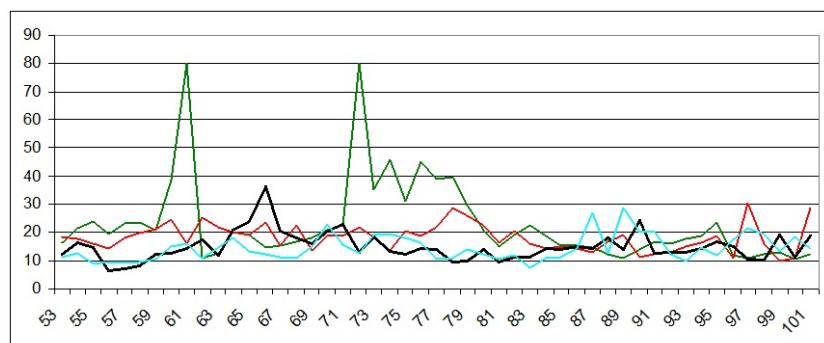


Figura 4.4: Temperatura ahead 4

Ahead = 5

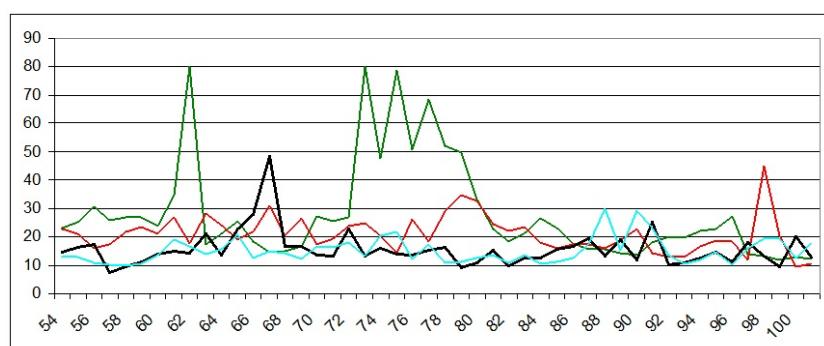


Figura 4.5: Temperatura ahead 5

Ahead = 6

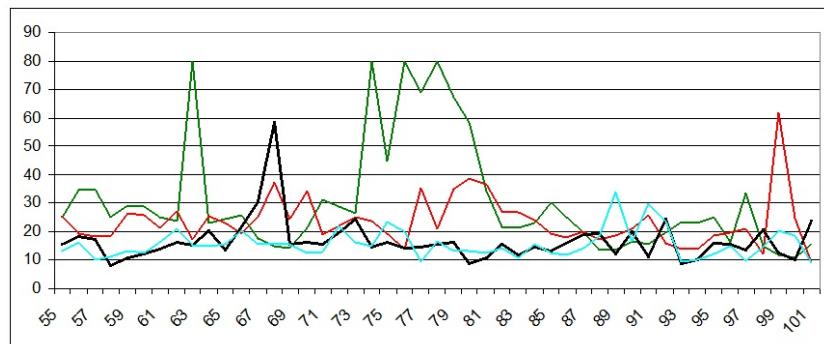


Figura 4.6: Temperatura ahead 6

Attributo: Velocità del vento

Ahead = 1

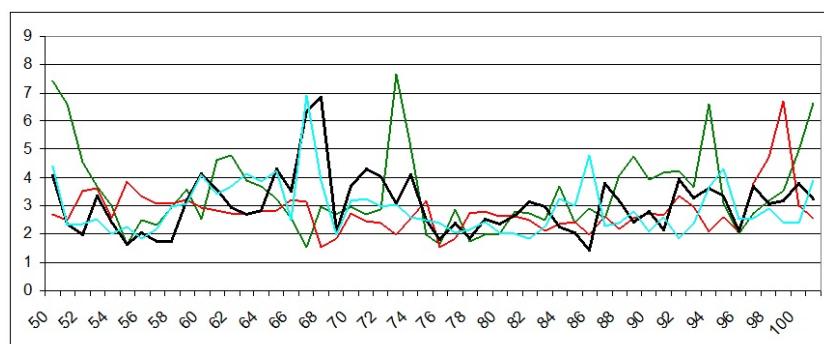


Figura 4.7: Velocità vento ahead 1

Ahead = 2

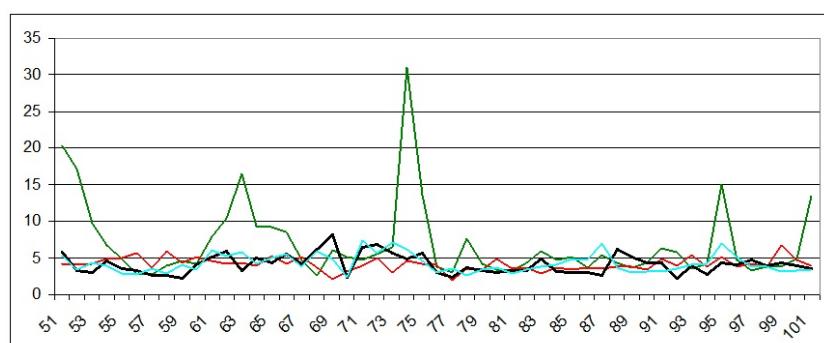


Figura 4.8: Velocità vento ahead 2

Ahead = 3

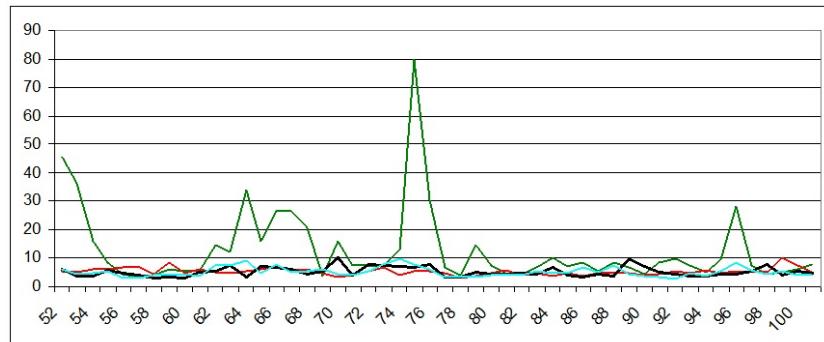


Figura 4.9: Velocità vento ahead 3

Ahead = 4

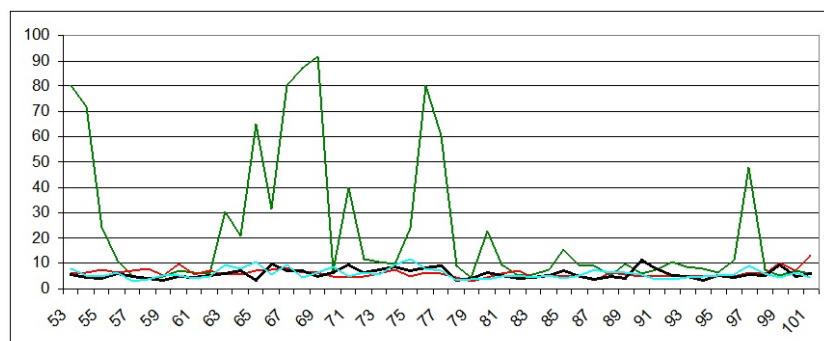


Figura 4.10: Velocità vento ahead 4

Ahead = 5

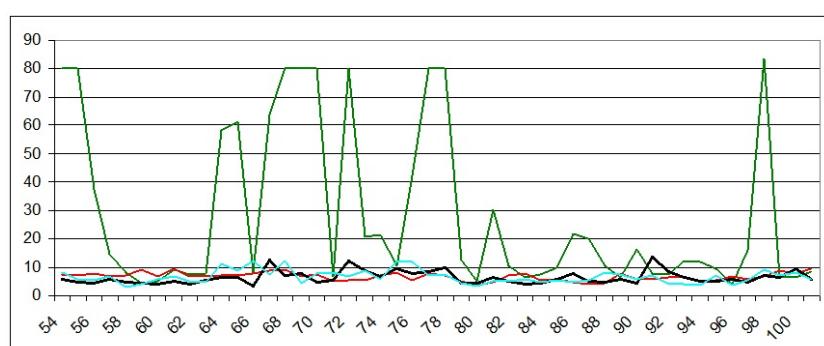


Figura 4.11: Velocità vento ahead 5

Ahead = 6

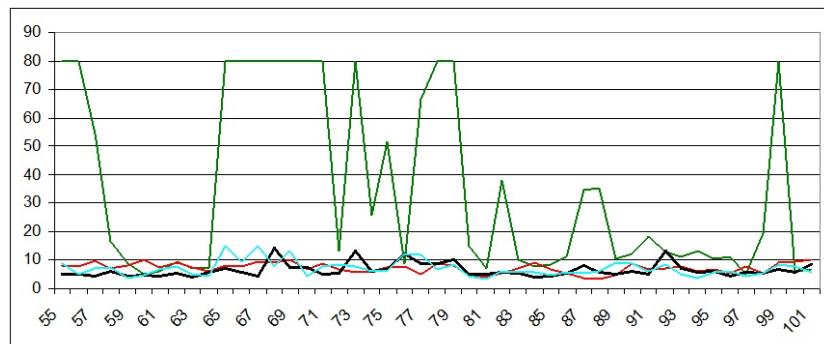


Figura 4.12: Velocità vento ahead 6

Attributo: Ozono

Ahead = 1

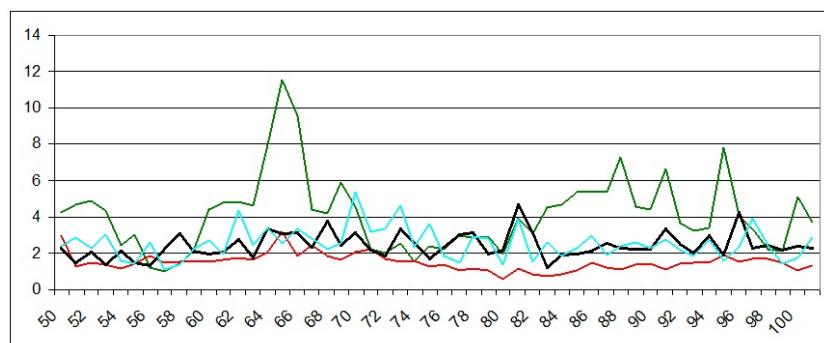


Figura 4.13: Ozono ahead 1

Ahead = 2

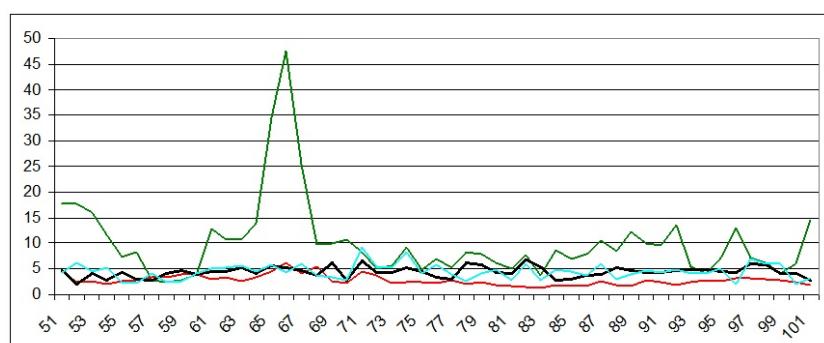


Figura 4.14: Ozono ahead 2

Ahead = 3

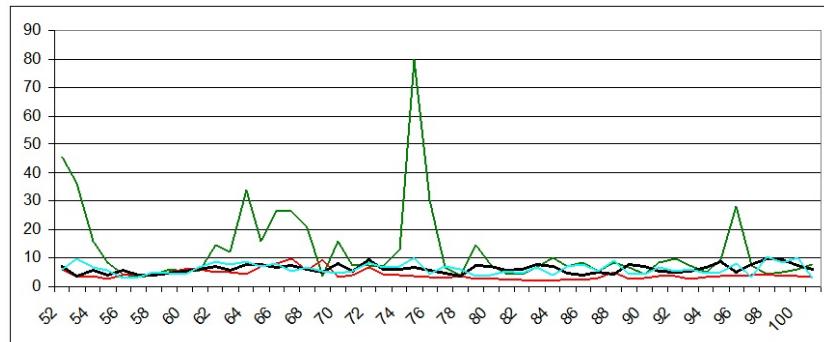


Figura 4.15: Ozono ahead 3

Ahead = 4

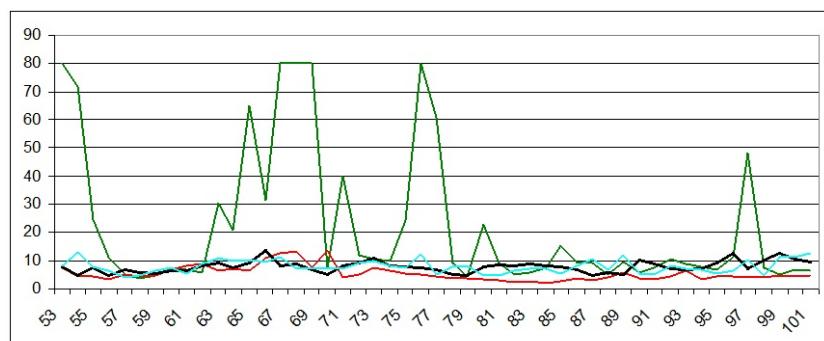


Figura 4.16: Ozono ahead 4

Ahead = 5

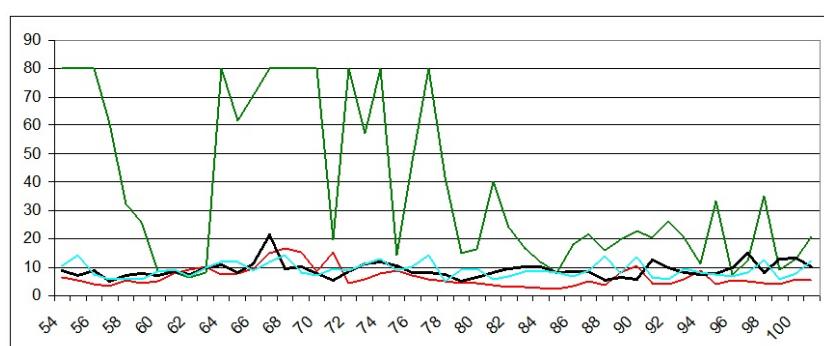


Figura 4.17: Ozono ahead 5

Ahead = 6

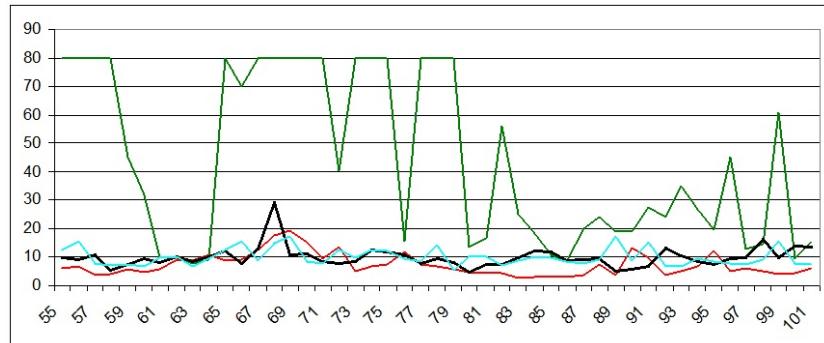


Figura 4.18: Ozono ahead 6

Attributo: Radiazioni solari

Ahead = 1

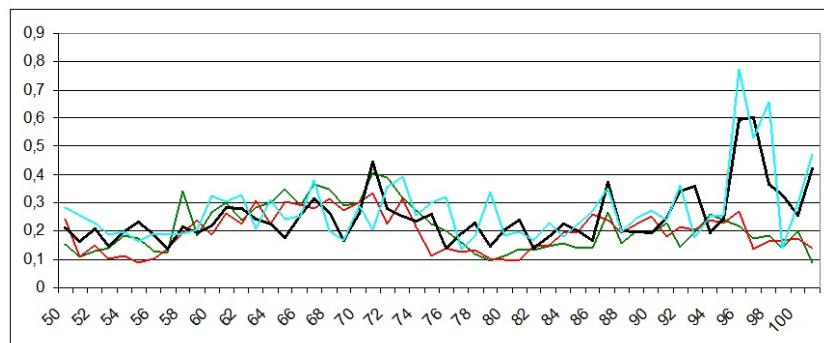


Figura 4.19: Radiazioni ahead 1

Ahead = 2

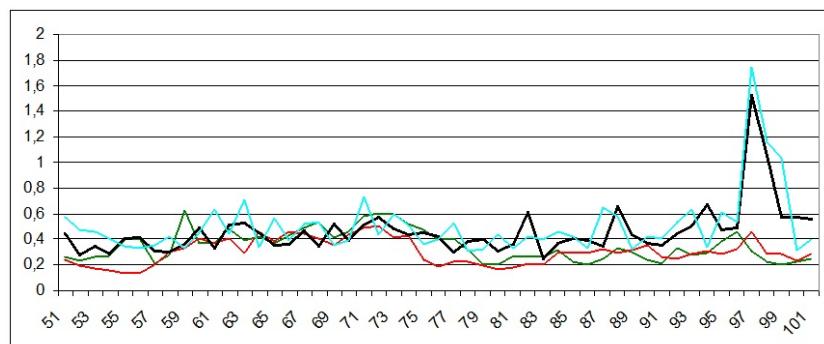


Figura 4.20: Radiazioni ahead 2

Ahead = 3

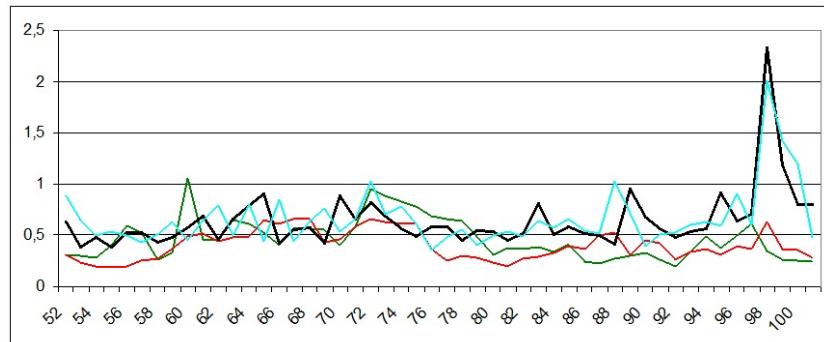


Figura 4.21: Radiazioni ahead 3

Ahead = 4

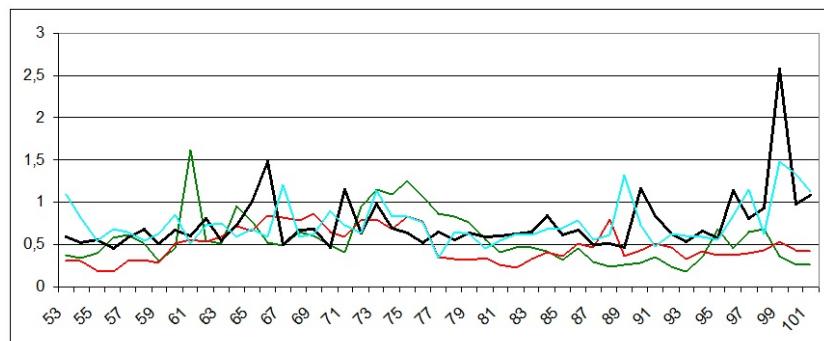


Figura 4.22: Radiazioni ahead 4

Ahead = 5

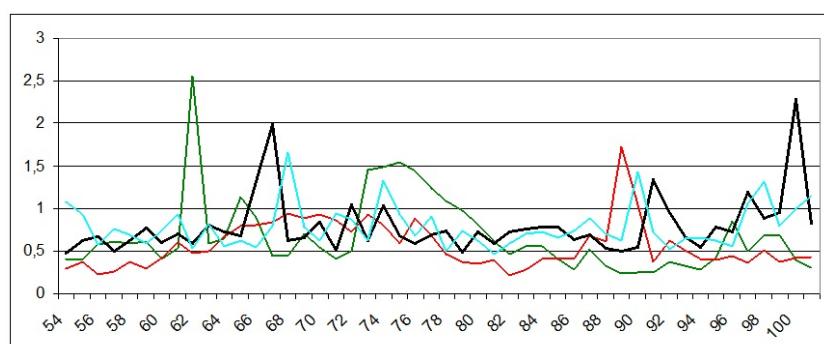


Figura 4.23: Radiazioni ahead 5

Ahead = 6

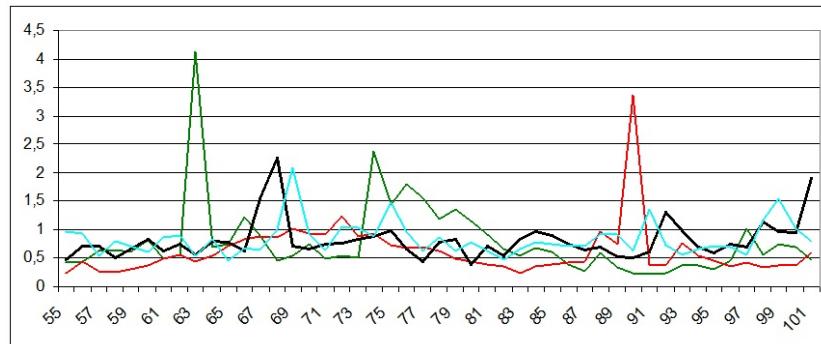


Figura 4.24: Radiazioni ahead 6

Come è possibile vedere da Fig. 4.1 a Fig. 4.24, gli RMSE generati dalle previsioni effettuate con le versioni VARForecaster 2.1 e VARForecaster 2.2 non si discostano molto da quelli generati dalla versione VARForecaster 1.0, soprattutto con l'aumentare della distanze nel tempo (ahead) con cui si effettua la previsione.

Questo mostra che le due versioni sopracitate realizzano l'obiettivo di costruire previsioni sufficientemente accurate, eseguendo la computazione in tempi ragionevoli.

4.3.2 UnitedStatesPacific

Per il dataset UnitedStatesPacific sono stati utilizzati i seguenti parametri:

Dimensione finestra temporale	48
bperc.	0.1f
lag.max	24
Season	NULL
Exogen	NULL
ic	ALL
type	ALL
n.ahead	6

Tabella 4.71: Parametri per UnitedStatesPacific

dove "ALL" indica che è il sistema a trovare il parametro ottimale tra quelli ammissibili per la costruzione del modello VAR.

VARForecaster 2.1

Come per il dataset Ecotexas, per la versione VARForecaster 2.1 ci sono quattro possibili configurazioni, ovvero:

- (1) Calcolo dell'aggregato con utilizzo della media e indice di autocorrelazione spaziale Getis and Ord;
- (2) Calcolo dell'aggregato con utilizzo della mediana e indice di autocorrelazione spaziale Getis and Ord;
- (3) Calcolo dell'aggregato con utilizzo della media e varianza;
- (4) Calcolo dell'aggregato con utilizzo della mediana e varianza;

Sono di seguito riportati i risultati avuti attraverso le valutazioni delle metriche (1) e (2) (definite in Sezione 4.1).

Metrica 1: Media dello RMSE per ogni istante di tempo predetto

Attributo: dewp

	Media+GO	Mediana+GO	Media+Var	Mediana+Var
ahead 1	10,35410	8,09983	8,49547	4,57026
ahead 2	21,61805	11,76371	13,28951	8,98220
ahead 3	45,65774	17,53932	15,10214	10,6661
ahead 4	102,77642	23,89249	22,33428	13,1286
ahead 5	253,97965	46,02549	33,96732	15,46501
ahead 6	696,45082	73,04417	43,15385	17,87788

Tabella 4.72: UnitedStatesPacific VARForecaster 2.1 - Metrica (1), dewp

Attributo: pres

	Media+GO	Mediana+GO	Media+Var	Mediana+Var
ahead 1	21,28281	20,75721	4,29425	3,50544
ahead 2	27,66193	26,17847	8,09658	6,21739
ahead 3	37,6824	33,0506	11,1886	7,80243
ahead 4	48,2233	28,368	17,60297	9,42102
ahead 5	111,7456	39,39191	22,80009	11,24487
ahead 6	282,6471	54,53949	33,8591	11,85886

Tabella 4.73: UnitedStatesPacific VARForecaster 2.1 - Metrica (1), pres

Attributo:temp

	Media+GO	Mediana+GO	Media+Var	Mediana+Var
ahead 1	15,44130	12,99331	17,00225	10,82273
ahead 2	33,28733	23,22106	33,9441	18,33721
ahead 3	69,6794	38,8886	39,2455	22,9628
ahead 4	157,924	57,0033	64,748	28,9879
ahead 5	384,654	113,0101	105,5124	35,12572
ahead 6	989,1974	186,4416	173,5766	41,29017

Tabella 4.74: UnitedStatesPacific VARForecaster 2.1 - Metrica (1), temp

Attributo: wind

	Media+GO	Mediana+GO	Media+Var	Mediana+Var
ahead 1	9,65734	7,80671	5,31065	4,38076
ahead 2	16,47911	11,33491	11,50816	7,804106
ahead 3	27,5363	12,3545	13,4658	8,44543
ahead 4	64,596	11,7299	17,3327	9,52957
ahead 5	156,9214	5,29247	27,69262	11,75549
ahead 6	403,6115	25,75966	44,38998	12,72086

Tabella 4.75: UnitedStatesPacific VARForecaster 2.1 - Metrica (1), wind

Metrica 2: Deviazione standard dello RMSE per ogni istante di tempo predetto

Attributo: dewp

	Media+GO	Mediana+GO	Media+Var	Mediana+Var
ahead 1	5,94495	2,16626	2,58476	1,56471
ahead 2	18,00577	4,07715	5,34757	2,65384
ahead 3	54,40966	14,23701	7,42695	3,41018
ahead 4	149,69459	26,32336	14,57913	4,49271
ahead 5	434,63121	127,65742	35,53876	6,16542
ahead 6	1520,89339	256,50925	60,91395	9,84278

Tabella 4.76: UnitedStatesPacific VARForecaster 2.1 - Metrica (2), dewp

Attributo: pres

	Media+GO	Mediana+GO	Media+Var	Mediana+Var
ahead 1	16,43563	16,62778	1,54870	1,17519
ahead 2	18,85916	19,19468	2,73254	1,75573
ahead 3	20,2104	19,5822	4,24635	2,72991
ahead 4	45,4935	18,2257	9,91846	3,5497
ahead 5	163,0839	56,70568	11,96975	6,70423
ahead 6	567,2065	134,0601	50,99903	8,51059

Tabella 4.77: UnitedStatesPacific VARForecaster 2.1 - Metrica (2), pres

Attributo: temp

	Media+GO	Mediana+GO	Media+Var	Mediana+Var
ahead 1	6,31481	3,27786	6,12472	4,61221
ahead 2	19,84917	8,63296	14,53473	5,97245
ahead 3	68,9712	27,2828	24,1208	8,71251
ahead 4	194,173	56,199	66,6488	12,4755
ahead 5	520,5953	242,3278	139,1948	8,23943
ahead 6	1644,085	525,6508	321,1888	29,11351

Tabella 4.78: UnitedStatesPacific VARForecaster 2.1 - Metrica (2), temp

Attributo: wind

	Media+GO	Mediana+GO	Media+Var	Mediana+Var
ahead 1	5,37025	5,18403	2,06998	2,16056
ahead 2	10,94917	6,84611	5,02589	3,63488
ahead 3	29,7911	5,89965	7,45265	3,80555
ahead 4	106,774	4,05948	16,011	4,99517
ahead 5	304,1241	9,96997	29,86768	5,47922
ahead 6	918,9793	16,76353	65,30511	7,00446

Tabella 4.79: UnitedStatesPacific VARForecaster 2.1 - Metrica (2), wind

Per entrambe le metriche sono riportati in **grassetto** gli RMSE più bassi ottenuti per ogni istante temporale previsto.

Per meglio comprendere questi risultati si riportano nel seguito le tabelle, una per ogni istante di tempo di previsione (ahead), riportanti il numero di volte che una configurazione è stata scelta come migliore.

Ahead = 1

	Totale				Metrica 1				Metrica 2			
Configurazioni	1	2	3	4	1	2	3	4	1	2	3	4
Occorrenze	0	0	1	7	0	0	0	4	0	0	1	3

Tabella 4.80: UnitedStatesPacific VARForecaster 2.1 - Riassunto Ahead 1

Ahead = 2

	Totale				Metrica 1				Metrica 2			
Configurazioni	1	2	3	4	1	2	3	4	1	2	3	4
Occorrenze	0	0	0	8	0	0	0	4	0	0	0	4

Tabella 4.81: UnitedStatesPacific VARForecaster 2.1 - Riassunto Ahead 2

Ahead = 3

	Totale				Metrica 1				Metrica 2			
Configurazioni	1	2	3	4	1	2	3	4	1	2	3	4
Occorrenze	0	0	0	8	0	0	0	4	0	0	0	4

Tabella 4.82: UnitedStatesPacific VARForecaster 2.1 - Riassunto Ahead 3

Ahead = 4

	Totale				Metrica 1				Metrica 2			
Configurazioni	1	2	3	4	1	2	3	4	1	2	3	4
Occorrenze	0	0	0	8	0	0	0	4	0	0	0	4

Tabella 4.83: UnitedStatesPacific VARForecaster 2.1 - Riassunto Ahead 4

Ahead = 5

	Totale				Metrica 1				Metrica 2			
Configurazioni	1	2	3	4	1	2	3	4	1	2	3	4
Occorrenze	0	1	0	7	0	1	0	3	0	0	0	4

Tabella 4.84: UnitedStatesPacific VARForecaster 2.1 - Riassunto Ahead 5

Ahead = 6

	Totale				Metrica 1				Metrica 2			
Configurazioni	1	2	3	4	1	2	3	4	1	2	3	4
Occorrenze	0	0	0	8	0	0	0	4	0	0	0	4

Tabella 4.85: UnitedStatesPacific VARForecaster 2.1 - Riassunto Ahead 6

In base alle metriche (1) e (2), utilizzate per valutare l'accuratezza del sistema, è possibile notare come la configurazione migliore (più accurata) è indubbiamente la 4, nonché **mediana + varianza**.

Metrica 4: Tempo medio di computazione per la costruzione(/riapprendimento) del CT.

Media+GO	Mediana+GO	Media+Var	Mediana+Var
4,44	5,35	29,71	36,10

Tabella 4.86: UnitedStatesPacific VARForecaster 2.1 - Metrica (4)

Metrica 5: Tempo medio di computazione per l'apprendimento del modello VAR.

Media+GO	Mediana+GO	Media+Var	Mediana+Var
18526	19324	16009	16237

Tabella 4.87: UnitedStatesPacific VARForecaster 2.1 - Metrica (5)

Metrica 6: Tempo medio di computazione per la fase di previsione.

Media+GO	Mediana+GO	Media+Var	Mediana+Var
3,49	4,28	3,87	4,02

Tabella 4.88: UnitedStatesPacific VARForecaster 2.1 - Metrica (6)

VARForecaster 2.2

Sono di seguito nuovamente elencate le configurazioni possibili per la versione VARForecaster 2.2:

- (1) Apprendimento dell'albero con algoritmo di smoothing utilizzando un $\alpha = 0.4$, calcolo dell'aggregato con la mediana e indice di autocorrelazione spaziale Getis and Ord.
- (2) Apprendimento dell'albero con algoritmo di smoothing utilizzando un $\alpha = 0.4$, calcolo dell'aggregato con la media e indice di autocorrelazione spaziale Getis and Ord.
- (3) Apprendimento dell'albero con algoritmo di smoothing utilizzando un $\alpha = 0.4$, calcolo dell'aggregato con la mediana e varianza.
- (4) Apprendimento dell'albero con algoritmo di smoothing utilizzando un $\alpha = 0.4$, calcolo dell'aggregato con la media e varianza.
- (5) Apprendimento dell'albero con algoritmo di smoothing utilizzando un $\alpha = 0.5$, calcolo dell'aggregato con la mediana e indice di autocorrelazione spaziale Getis and Ord.
- (6) Apprendimento dell'albero con algoritmo di smoothing utilizzando un $\alpha = 0.5$, calcolo dell'aggregato con la media e indice di autocorrelazione spaziale Getis and Ord.
- (7) Apprendimento dell'albero con algoritmo di smoothing utilizzando un $\alpha = 0.5$, calcolo dell'aggregato con la mediana e varianza.
- (8) Apprendimento dell'albero con algoritmo di smoothing utilizzando un $\alpha = 0.5$, calcolo dell'aggregato con la media e varianza.
- (9) Apprendimento dell'albero con algoritmo di smoothing utilizzando un $\alpha = 0.6$, calcolo dell'aggregato con la mediana e indice di autocorrelazione spaziale Getis and Ord.
- (10) Apprendimento dell'albero con algoritmo di smoothing utilizzando un $\alpha = 0.6$, calcolo dell'aggregato con la media e indice di autocorrelazione spaziale Getis and Ord.
- (11) Apprendimento dell'albero con algoritmo di smoothing utilizzando un $\alpha = 0.6$, calcolo dell'aggregato con la mediana e varianza.
- (12) Apprendimento dell'albero con algoritmo di smoothing utilizzando un $\alpha = 0.6$, calcolo dell'aggregato con la media e varianza.

Per le metriche (1) e (2) i risultati sono stati analizzati attributo per attributo. Le tabelle sono organizzate in base ai livelli α . Ogni tabella, inoltre, include le seguenti quattro colonne:

- (1) Calcolo dell'aggregato con utilizzo della media e indice di autocorrelazione spaziale Getis and Ord;
- (2) Calcolo dell'aggregato con utilizzo della mediana e indice di autocorrelazione spaziale Getis and Ord;
- (3) Calcolo dell'aggregato con utilizzo della media e varianza;
- (4) Calcolo dell'aggregato con utilizzo della mediana e varianza;

Sono di seguito riportati i risultati.

Metrica 1: Media dello RMSE per ogni istante di tempo predetto

Attributo: dewp

	Smoothing $\alpha = 0.4$			
	1	2	3	4
ahead 1	8,27904	6,38061	8,26531	5,27701
ahead 2	16,0298	10,5766	13,6887	9,31357
ahead 3	27,42677	14,69364	17,81315	12,46099
ahead 4	51,20479	16,5757	28,71257	15,34014
ahead 5	176,2468	19,39388	52,98369	18,94659
ahead 6	820,51833	22,73526	112,34935	21,90584

Tabella 4.89: UnitedStatesPacific VARForecaster 2.2 - Metrica (1), dewp, $\alpha = 0.4$

	Smoothing $\alpha = 0.5$			
	1	2	3	4
ahead 1	10,66219	8,07925	7,98354	5,09278
ahead 2	17,4688	12,1913	12,8452	9,21612
ahead 3	27,98501	17,7251	14,86977	11,62603
ahead 4	41,56125	20,13368	20,62609	14,61927
ahead 5	83,43031	22,61424	31,10648	18,14871
ahead 6	197,90215	24,96765	49,72840	21,25953

Tabella 4.90: UnitedStatesPacific VARForecaster 2.2 - Metrica (1), dewp, $\alpha = 0.5$

	Smoothing $\alpha = 0.6$			
	1	2	3	4
ahead 1	12,07665	12,05122	8,06145	,15736
ahead 2	22,1225	20,1751	13,1302	9,46835
ahead 3	36,67084	26,06997	14,58737	11,68703
ahead 4	67,92605	43,30007	20,00141	14,61657
ahead 5	171,3545	78,08391	31,71357	18,08502
ahead 6	570,41382	238,20854	55,43952	21,01571

Tabella 4.91: UnitedStatesPacific VARForecaster 2.2 - Metrica (1), dewp, $\alpha = 0.6$

Attributo: pres

	Smoothing $\alpha = 0.4$			
	1	2	3	4
ahead 1	16,92658	16,58831	4,27934	3,60989
ahead 2	24,1618	23,4025	8,4444	6,63054
ahead 3	21,03628	18,30415	12,22256	8,302075
ahead 4	27,64643	17,25246	18,27703	10,29753
ahead 5	61,18393	18,62148	23,13371	11,7856
ahead 6	203,96921	17,09940	29,04078	11,88881

Tabella 4.92: UnitedStatesPacific VARForecaster 2.2 - Metrica (1), pres, $\alpha = 0.4$

	Smoothing $\alpha = 0.5$			
	1	2	3	4
ahead 1	21,2399	20,78155	4,26267	3,45036
ahead 2	28,0996	27,3249	8,29079	6,077
ahead 3	25,33999	23,02857	11,54404	7,48301
ahead 4	27,67892	19,17569	17,2736	9,43111
ahead 5	36,72377	16,10743	22,88078	11,27574
ahead 6	72,55095	17,947	29,4564	11,54297

Tabella 4.93: UnitedStatesPacific VARForecaster 2.2 - Metrica (1), pres, $\alpha = 0.5$

	Smoothing $\alpha = 0.6$			
	1	2	3	4
ahead 1	29,63628	29,71818	4,36475	3,59517
ahead 2	26,4177	26,3579	8,34811	6,24176
ahead 3	24,72792	23,29762	11,37082	4,603795
ahead 4	43,03939	32,4199	17,44765	9,65899
ahead 5	101,0519	46,56281	22,39137	11,15838
ahead 6	362,18329	102,81672	25,82343	11,10552

Tabella 4.94: UnitedStatesPacific VARForecaster 2.2 - Metrica (1), pres, $\alpha = 0.6$

Attributo:temp

	Smoothing $\alpha = 0.4$			
	1	2	3	4
ahead 1	12,36206	11,42628	18,74542	11,51074
ahead 2	9,36371	5,94138	24,3968	7,70272
ahead 3	44,69455	32,11892	46,44071	25,02006
ahead 4	85,80132	44,62097	67,06124	32,47087
ahead 5	230,561	56,32052	103,2566	38,73074
ahead 6	921,5452	64,9213	183,35248	44,25375

Tabella 4.95: UnitedStatesPacific VARForecaster 2.2 - Metrica (1), temp, $\alpha = 0.4$

	Smoothing $\alpha = 0.5$			
	1	2	3	4
ahead 1	16,27052	11,53227	17,45441	11,58477
ahead 2	17,5606	8,87091	21,7589	7,34922
ahead 3	64,48934	42,85104	43,7311	24,07154
ahead 4	99,7284	59,6736	58,4439	30,78391
ahead 5	170,8852	73,55237	86,44128	36,62066
ahead 6	352,27301	81,07127	145,83875	42,34479

Tabella 4.96: UnitedStatesPacific VARForecaster 2.2 - Metrica (1), temp, $\alpha = 0.5$

	Smoothing $\alpha = 0.6$			
	1	2	3	4
ahead 1	16,30139	14,9276	18,06174	11,31821
ahead 2	18,9689	11,1877	21,4415	6,83391
ahead 3	84,01594	42,38011	42,82521	23,4737
ahead 4	239,247	70,30667	54,54914	30,15269
ahead 5	951,9507	110,8372	76,20901	36,96072
ahead 6	4724,37274	198,39152	126,65686	42,52642

Tabella 4.97: UnitedStatesPacific VARForecaster 2.2 - Metrica (1), temp, $\alpha = 0.6$

Attributo: wind

	Smoothing $\alpha = 0.4$			
	1	2	3	4
ahead 1	6,07391	5,70323	5,97786	5,11227
ahead 2	3,0769	2,74313	12,244	4,93367
ahead 3	14,0015	9,395732	17,97835	9,146756
ahead 4	23,06176	11,03524	24,73806	11,13321
ahead 5	55,22912	12,99234	41,2732	12,82012
ahead 6	116,701	14,45873	79,08570	12,98682

Tabella 4.98: UnitedStatesPacific VARForecaster 2.2 - Metrica (1), wind, $\alpha = 0.4$

	Smoothing $\alpha = 0.5$			
	1	2	3	4
ahead 1	7,52321	6,63368	5,86253	4,86708
ahead 2	6,28608	4,33382	10,0958	4,78144
ahead 3	17,70545	11,24401	16,44148	8,934127
ahead 4	27,07973	12,60431	20,23164	10,23597
ahead 5	55,83112	14,29877	30,1624	11,80704
ahead 6	130,73018	17,168838	46,21421	12,2569

Tabella 4.99: UnitedStatesPacific VARForecaster 2.2 - Metrica (1), wind, $\alpha = 0.5$

	Smoothing $\alpha = 0.6$			
	1	2	3	4
ahead 1	9,59845	9,28646	5,94993	4,65493
ahead 2	5,42531	3,18113	10,2218	4,35038
ahead 3	23,01827	12,45196	15,81068	8,422983
ahead 4	66,23017	19,21566	18,68297	9,68644
ahead 5	272,0654	32,82459	27,83789	11,75522
ahead 6	1384,5733	74,11397	46,00317	12,20324

Tabella 4.100: UnitedStatesPacific VARForecaster 2.2 - Metrica (1), wind, $\alpha = 0.6$

Metrica 2: Deviazione standard dello RMSE per ogni istante di tempo predetto

Attributo: dewp

	Smoothing $\alpha = 0.4$			
	1	2	3	4
ahead 1	3,62146	2,21437	2,69688	1,98897
ahead 2	9,90162	4,16068	4,30406	3,36315
ahead 3	33,2724	5,201349	9,779709	4,742231
ahead 4	159,51	5,16938	27,19474	5,57008
ahead 5	895,68387	6,80049	79,88217	8,580549
ahead 6	5051,54	10,81451	232,51391	12,32884

Tabella 4.101: UnitedStatesPacific VARForecaster 2.2 - Metrica (2), dewp, $\alpha = 0.4$

	Smoothing $\alpha = 0.5$			
	1	2	3	4
ahead 1	4,04506	3,84309	2,89746	1,88901
ahead 2	7,09878	4,55632	4,90044	3,37117
ahead 3	11,84762	6,938517	6,714971	4,476137
ahead 4	27,19841	8,65862	14,60174	5,44206
ahead 5	92,91261	10,01995	32,91812	8,33261
ahead 6	3226,15397	15,93889	98,92583	12,58244

Tabella 4.102: UnitedStatesPacific VARForecaster 2.2 - Metrica (2), dewp, $\alpha = 0.5$

	Smoothing $\alpha = 0.6$			
	1	2	3	4
ahead 1	4,23088	7,28793	2,82895	1,75402
ahead 2	6,65769	10,1984	4,66539	3,22088
ahead 3	21,26428	18,23092	6,969764	4,255774
ahead 4	80,49968	62,72078	14,82992	5,47233
ahead 5	305,9681	233,5263	38,5938	8,288871
ahead 6	1313,57	1021,419	120,9813	12,47698

Tabella 4.103: UnitedStatesPacific VARForecaster 2.2 - Metrica (2), dewp, $\alpha = 0.6$

Attributo: pres

	Smoothing $\alpha = 0.4$			
	1	2	3	4
ahead 1	10,10679	10,17143	1.57424	1.34531
ahead 2	10,876	11,1444	3,65176	2,18629
ahead 3	10,02448	8,394604	5,422072	2,743826
ahead 4	34,35737	8,07045	9,24993	3,04091
ahead 5	197,7867	11,96599	14,89458	3,00446
ahead 6	1120,36108	15,53281	3146606	2,83362

Tabella 4.104: UnitedStatesPacific VARForecaster 2.2 - Metrica (2), pres, $\alpha = 0.4$

	Smoothing $\alpha = 0.5$			
	1	2	3	4
ahead 1	14,29961	14,54385	1,66226	1,14218
ahead 2	13,56029	13,66938	3,70591	2,15068
ahead 3	13,33688	13,3792	5,71621	2,580855
ahead 4	14,87002	12,55843	9,70296	2,44914
ahead 5	28,51144	8,210878	17,13722	3,04571
ahead 6	87,23224	12,8405	48,78620	3,39392

Tabella 4.105: UnitedStatesPacific VARForecaster 2.2 - Metrica (2), pres, $\alpha = 0.5$

	Smoothing $\alpha = 0.6$			
	1	2	3	4
ahead 1	14,95718	14,84216	1,62101	1,19107
ahead 2	14,2077	14,2458	3,49222	2,07719
ahead 3	12,5982	13,634	5,184301	2,484297
ahead 4	35,53256	26,68161	8,54327	2,75254
ahead 5	211,2549	98,8837	12,85933	2,9217141
ahead 6	1247,48033	430,17849	26,67878	2,81822

Tabella 4.106: UnitedStatesPacific VARForecaster 2.2 - Metrica (2), pres, $\alpha = 0.6$

Attributo: temp

	Smoothing $\alpha = 0.4$			
	1	2	3	4
ahead 1	4,10482	3,96802	9,77958	6,90039
ahead 2	9,36371	5,94138	24,3968	7,70272
ahead 3	31,50488	10,64093	40,88731	10,70116
ahead 4	160,9352	16,02986	73,00546	13,49229
ahead 5	900,7356	23,49446	121,0862	14,91076
ahead 6	5101,30368	28,43041	276,60418	18,64702

Tabella 4.107: UnitedStatesPacific VARForecaster 2.2 - Metrica (2), temp, $\alpha = 0.4$

	Smoothing $\alpha = 0.5$			
	1	2	3	4
ahead 1	8,72256	5,56245	8,41391	6,45043
ahead 2	17,5606	8,87091	21,7589	7,34922
ahead 3	36,16275	19,58464	38,16128	10,53871
ahead 4	88,20375	28,84006	68,16989	13,44913
ahead 5	301,7233	34,82981	103,5987	14,87945
ahead 6	1071,57389	37,90779	238,40214	18,58829

Tabella 4.108: UnitedStatesPacific VARForecaster 2.2 - Metrica (2), temp, $\alpha = 0.5$

	Smoothing $\alpha = 0.6$			
	1	2	3	4
ahead 1	6,32258	6,80657	8,25089	5,73471
ahead 2	18,9689	11,1877	21,4415	6,83391
ahead 3	92,77529	20,5015	36,53973	8,929867
ahead 4	577,8787	53,78613	62,23817	12,12332
ahead 5	3388,358	124,1951	88,62212	14,16961
ahead 6	19784,33	500,0136	177,37617	18,19872

Tabella 4.109: UnitedStatesPacific VARForecaster 2.2 - Metrica (2), temp, $\alpha = 0.6$

Attributo: wind

	Smoothing $\alpha = 0.4$			
	1	2	3	4
ahead 1	2,33563	2,04721	2,46309	3,42228
ahead 2	3,0769	2,74313	12,244	4,93367
ahead 3	10,85776	3,169839	17,28207	5,102848
ahead 4	32,83868	3,854333	29,86333	7,119454
ahead 5	137,2906	5,91256	56,14314	5,82955
ahead 6	477,09495	5,78572	141,36287	4,8236

Tabella 4.110: UnitedStatesPacific VARForecaster 2.2 - Metrica (2), wind, $\alpha = 0.4$

	Smoothing $\alpha = 0.5$			
	1	2	3	4
ahead 1	2,94515	2,93728	2,62926	3,21827
ahead 2	6,28608	4,33381	10,0958	4,78144
ahead 3	10,40562	3,942356	15,43549	4,86086
ahead 4	26,91828	4,136585	2606117	6,602587
ahead 5	86,24081	4,17396	39,3418	5,50416
ahead 6	268,95739	6,94423	77,38897	4,8708

Tabella 4.111: UnitedStatesPacific VARForecaster 2.2 - Metrica (2), wind, $\alpha = 0.5$

	Smoothing $\alpha = 0.6$			
	1	2	3	4
ahead 1	3,76778	3,55963	2,67171	2,97208
ahead 2	5,42531	3,18113	10,2218	4,35038
ahead 3	26,5976	5,0748	14,70863	4,070677
ahead 4	174,3689	17,22958	23,98991	5,826746
ahead 5	1017,648	67,86876	37,4537	5,05873
ahead 6	5950,309	286,7333	81,27753	4,37529

Tabella 4.112: UnitedStatesPacific VARForecaster 2.2 - Metrica (2), wind, $\alpha = 0.6$

Al fine di valutare al meglio i risultati ottenuti con le metriche (1) e (2) si propone di seguito un sommario a livello generale.

Tabella riassuntiva - AVG			
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6
Media + GO	0	0	0
Mediana + GO	2	0	0
Media + var	0	0	0
Mediana + var	0	8	14

Tabella riassuntiva - RMSE			
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6
Media + GO	0	0	0
Mediana + GO	9	1	0
Media + var	0	0	0
Mediana + var	0	2	12

Tabella 4.113: Ecotexas VARForecaster 2.2 - Tabella riassuntiva

In quanto con il dataset Ecotexas si è avuta la riprova che dividere i risultati un'istante temporale alla volta è utile per meglio comprenderli, si propone un riepilogo di questi un'istante di predizione alla volta.

Ahead = 1

Tabella riassuntiva - AVG				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Media + GO	0	0	0	
Mediana + GO	1	1	0	2
Media + var	0	0	0	0
Mediana + var	3	3	4	10
Tabella riassuntiva - RMSE				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Media + GO	0	0	0	
Mediana + GO	2	2	0	4
Media + var	0	0	1	1
Mediana + var	2	2	3	7
Tabella riassuntiva - Complessivo				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Media + GO	0	0	0	0
Mediana + GO	3	3	0	6
Media + var	0	0	1	1
Mediana + var	5	5	7	17

Tabella 4.114: UnitedStatesPacific VARForecaster 2.2 - Riassunto Ahead 1

Ahead = 2

Tabella riassuntiva - AVG				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Media + GO	0	0	0	0
Mediana + GO	2	1	1	4
Media + var	0	0	0	0
Mediana + var	2	3	3	8
Tabella riassuntiva - RMSE				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Media + GO	0	0	0	0
Mediana + GO	2	1	1	4
Media + var	0	0	0	0
Mediana + var	2	3	3	8
Tabella riassuntiva - Complessivo				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Media + GO	0	0	0	0
Mediana + GO	4	2	2	8
Media + var	0	0	0	0
Mediana + var	4	6	6	16

Tabella 4.115: UnitedStatesPacific VARForecaster 2.2 - Riassunto Ahead 2

Ahead = 3

Tabella riassuntiva - AVG				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Media + GO	0	0	0	0
Mediana + GO	0	0	0	0
Media + var	0	0	0	0
Mediana + var	4	4	4	12
Tabella riassuntiva - RMSE				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Media + GO	0	0	0	0
Mediana + GO	2	1	0	3
Media + var	0	0	0	0
Mediana + var	2	3	4	9
Tabella riassuntiva - Complessivo				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Media + GO	0	0	0	0
Mediana + GO	2	1	0	3
Media + var	0	0	0	0
Mediana + var	6	7	8	21

Tabella 4.116: UnitedStatesPacific VARForecaster 2.2 - Riassunto Ahead 4

Ahead = 4

Tabella riassuntiva - AVG				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Media + GO	0	0	0	0
Mediana + GO	1	0	0	0
Media + var	0	0	0	0
Mediana + var	3	4	4	11
Tabella riassuntiva - RMSE				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Media + GO	0	0	0	0
Mediana + GO	2	1	0	3
Media + var	0	0	0	0
Mediana + var	2	3	4	9
Tabella riassuntiva - Complessivo				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Media + GO	0	0	0	0
Mediana + GO	3	1	0	4
Media + var	0	0	0	0
Mediana + var	5	7	8	20

Tabella 4.117: UnitedStatesPacific VARForecaster 2.2 - Riassunto Ahead 4

Ahead = 5

Tabella riassuntiva - AVG				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Media + GO	0	0	0	0
Mediana + GO	0	0	0	0
Media + var	0	0	0	0
Mediana + var	4	4	4	12
Tabella riassuntiva - RMSE				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Media + GO	0	0	0	0
Mediana + GO	1	1	0	2
Media + var	0	0	0	0
Mediana + var	3	3	4	10
Tabella riassuntiva - Complessivo				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Media + GO	0	0	0	0
Mediana + GO	1	1	0	2
Media + var	0	0	0	0
Mediana + var	7	7	8	22

Tabella 4.118: UnitedStatesPacific VARForecaster 2.2 - Riassunto Ahead 5

Ahead = 6

Tabella riassuntiva - AVG				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Media + GO	0	0	0	0
Mediana + GO	0	0	0	0
Media + var	0	0	0	0
Mediana + var	4	4	4	12
Tabella riassuntiva - RMSE				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Media + GO	0	0	0	0
Mediana + GO	1	0	0	0
Media + var	0	0	0	0
Mediana + var	3	4	4	11
Tabella riassuntiva - Complessivo				
	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6	Compl.
Media + GO	0	0	0	0
Mediana + GO	1	0	0	0
Media + var	0	0	0	0
Mediana + var	7	8	8	23

Tabella 4.119: UnitedStatesPacific VARForecaster 2.2 - Riassunto Ahead 6

Il sommario appena riportato conferma i risultati della versione VARForecaster 2.1, ovvero che la configurazione migliore è indubbiamente la (11), cioè calcolo dell'aggregato tramite mediana con utilizzo della varianza e $\alpha = 0,6$.

Metrica 3: Numero di cluster generati dall'algoritmo di clustering in ogni istante di tempo.

	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6
Mediana + GO	385	387	438
Mediana + var	432	412	452

Tabella 4.120: Ecotexas VARForecaster 2.2 - Metrica (3)

Per la metrica appena utilizzata si sono considerate solo le configurazioni che differiscono nel tipo di indice di autocorrelazione spaziale utilizzato, in quanto la funzione utilizzata per il calcolo dell'aggregato non influisce sul numero di cluster generati durante il ri-apprendimento del *CT*.

Metrica 4: Tempo medio di computazione per la costruzione(/riapprendimento) del *CT*.

	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6
Mediana + GO	6,06	4,53	4,86
Media + GO	5,32	4,95	5,64
Mediana + var	5,25	4,96	4,51
Media + var	4,68	5,88	3,63

Tabella 4.121: Ecotexas VARForecaster 2.2 - Metrica (4)

Metrica 5: Tempo medio di computazione per l'apprendimento del modello VAR.

	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6
Mediana + GO	6123	5946	6900
Media + GO	6068	5960	6870
Mediana + var	6878	6469	6863
Media + var	6845	6384	6877

Tabella 4.122: Ecotexas VARForecaster 2.2 - Metrica (5)

Metrica 6: Tempo medio di computazione per la fase di previsione.

	Smoothing 0.4	Smoothing 0.5	Smoothing 0.6
Mediana + GO	1,29	1,44	1,74
Media + GO	1,30	1,6	1,43
Mediana + var	2,02	1,14	1,43
Media + var	1,14	1,88	1

Tabella 4.123: Ecotexas VARForecaster 2.2 - Metrica (6)

Analizzando i risultati ottenuti per le metriche (4), (5) e (6) si nota che la fase che comporta maggior costi computazionali in termini di tempo è la fase di apprendimento del modello VAR, ovvero la metrica (5). Considerando tale metrica come la più importante si può notare che la configurazione migliore è quella con $\alpha = 0,5$.

Confronto

Capitolo 5

Conclusioni

Capitolo 6

Appendice

6.1 Guida per l'esecuzione di VARForecaster 2.1/2.2

Bibliografia

- [1] D. Mastropasqua. *Apprendimento di cluster spazio-temporali per l'apprendimento di un modello VAR*, 2016: Tesi di laurea in Algoritmi e Strutture Dati, Uniba.
- [2] G. Data, P. Mariani. *Market Access nel settore healthcare – Strategie, attori, attività e processi*, 2015: FrancoAngeli Editori.
- [3] C. Alexander. *Market Risk Analysis, Value at Risk Models*, 2009: Wiley.
- [4] N. Fanizzi. *Corso di Apprendimento Automatico*, 2009: Laurea Magistrale in Informatica, Uniba.
- [5] H. Arsham. *Forecasting by Smoothing Techniques*, 2015.
- [6] M. Brett. *Corso di Apprendimento Automatico*, 2013 : MRC Cognition and Brain Sciences Unit.
- [7] R.J. Hyndman, G. Athanasopoulos. *Forecasting: principles and practice*, 2013.
- [8] G. Righini. *Corso di Logistica*, 2013: Laurea Magistrale in Informatica, Unimi.
- [9] C.A. Sims. *Macroeconomics and Reality*, 1980.
- [10] J.D. Hamilton. *Time Series Analysis*, 1994: Princeton University Press.
- [11] D. Buono. *Analisi econometrica dinamica del settore Agricoltura*, 2007: Tesi di dottorato in Scienze Economiche, Unina.
- [12] <https://www.r-project.org/about.html>.
- [13] V. Fanelli. *Uso di modelli VAR nella previsione di modelli di regressione in una rete di sensori multi-variati*, 2015: Tesi di laurea in Metodi Avanzati di Programmazione, Uniba.

- [14] <https://it.wikipedia.org/wiki/Outlier>.
- [15] M. Ross Sheldon. *Introduzione alla statistica*, 2014, Maggioli Editore.
- [16] L. Bing. *Web Data Mining Exploring Hyperlinks, Contents, and Usage Data*, 2011, par. 4.1.
- [17] L. Bing. *Web Data Mining Exploring Hyperlinks, Contents, and Usage Data*, 2011, par. 4.2.
- [18] L. Bing. *Web Data Mining Exploring Hyperlinks, Contents, and Usage Data*, 2011, par. 4.3.
- [19] A. Appice, D. Malerba *Leveraging the power of local spatial autocorrelation in geophysical interpolative clustering*, *Data Mining and Knowledge Discovery*, 2014, cap. 2.
- [20] <https://cran.r-project.org/web/packages/vars/vars.pdf>.

Ringraziamenti